
Машинное обучение

Курс лекций

Лекции 1–8

Труфанов Н. Н., ст. преп. каф. ФН1

Версия конспекта 0.1

11 августа 2026 г.

Содержание

Содержание курса	1
1 Лекция 1. Математическая постановка задачи обучения. Данные и модель	3
1.1 Объекты, признаки, обучающая выборка	3
1.2 Типы задач по природе ответов	4
1.3 Модель алгоритмов и метод обучения	4
1.4 Напоминание из теории вероятностей	5
1.5 Функция потерь, эмпирический и истинный риск	6
1.6 Практический приём: матричное дифференцирование	7
1.7 Пример: метод наименьших квадратов как ERM	9
2 Лекция 2. Линейные модели: градиентный спуск и регуляризация	11
2.1 Метод градиентного спуска	11
2.2 Мультиколлинеарность и обусловленность	13
2.3 Гребневая регрессия (Ridge, L_2 -регуляризация)	14
2.4 Байесовская интерпретация: апостериорный максимум	14
2.5 LASSO (L_1 -регуляризация)	15
3 Лекция 3. Линейная классификация: логистическая регрессия и SVM	17
3.1 Логистическая регрессия	17
3.2 Метод опорных векторов: жёсткий зазор	19
3.3 Мягкий зазор	21
3.4 Ядра	21
4 Лекция 4. Переобучение и обобщающая способность	23
4.1 Переобучение	23
4.2 Разложение смещение–разброс	23
4.3 Скользящий контроль	25
4.4 VC-размерность	26
4.5 Принцип структурной минимизации риска	27
5 Лекция 5. Решающие деревья и композиции алгоритмов	29
5.1 Решающее дерево	29
5.2 Переобучение и стрижка	31
5.3 Бэггинг и случайный лес	32
5.4 Бустинг	33
6 Лекция 6. Метрические и байесовские методы классификации	35
6.1 Обобщённый метрический классификатор	35
6.2 Выбор параметров скользящим контролем	35
6.3 Отступ и отбор эталонов (STOLP)	36
6.4 Байесовское решающее правило	37
6.5 Наивный байесовский классификатор	37
6.6 Нормальный дискриминантный анализ	39
7 Лекция 7. Кластеризация и EM-алгоритм	41
7.1 Метод K -средних	41
7.2 Смеси распределений и EM-алгоритм	42
7.3 Иерархическая кластеризация	44

8	Лекция 8. Метод главных компонент и сингулярное разложение	47
8.1	Постановка: максимизация дисперсии проекции	47
8.2	Вывод через собственные векторы	47
8.3	Численный пример	49
8.4	Сингулярное разложение: вывод через PCA	50
8.5	Многомерное шкалирование	51

Машинное обучение

Лекция 1 — Математическая постановка задачи обучения. Данные и модель

Мотивация

Пусть для конечного набора объектов известен набор их измеримых характеристик, а для части объектов дополнительно известна некоторая связанная с ними величина. Требуется, опираясь на известные характеристики, предсказывать эту величину и для остальных, ещё не размеченных объектов. Чтобы решать подобные задачи не для одной конкретной величины, а в общем виде, необходима математическая постановка задачи обучения по прецедентам — ей посвящена эта лекция.

1 Объекты, признаки, обучающая выборка

Определение 1.1 (Прецедент, обучающая выборка). Пусть $\mathcal{X}$ — множество объектов, $\mathcal{Y}$ — множество допустимых ответов, и существует целевая функция $y^* : \mathcal{X} \rightarrow \mathcal{Y}$, значения которой $y_i = y^*(x_i)$ известны только на конечном подмножестве объектов $\{x_1, \dots, x_\ell\} \subset \mathcal{X}$. Пара «объект–ответ» (x_i, y_i) называется прецедентом, а совокупность пар $X^\ell = (x_i, y_i)_{i=1}^\ell$ — обучающей выборкой.

Задача обучения по прецедентам заключается в том, чтобы по выборке X^ℓ построить алгоритм $a : \mathcal{X} \rightarrow \mathcal{Y}$, приближающий y^* не только на объектах выборки, но и на всём $\mathcal{X}$.

Определение 1.2 (Признак). Признаком объекта называется отображение $f : \mathcal{X} \rightarrow D_f$, где D_f — множество допустимых значений признака. В зависимости от природы D_f признаки делятся на четыре типа:

Тип	D_f
бинарный	$\{0, 1\}$
номинальный	конечное неупорядоченное множество
порядковый	конечное упорядоченное множество
количественный	$\mathbb{R}$

Набор признаков $f_1, \dots, f_n$ задаёт признаковое описание объекта $x \mapsto (f_1(x), \dots, f_n(x))$; далее мы отождествляем объект с его признаковым описанием, полагая $\mathcal{X} = D_{f_1} \times \dots \times D_{f_n}$. Таблицу признаковых описаний всех объектов выборки называют матрицей объектов–признаков:

$$F = \|f_j(x_i)\|_{\ell \times n} = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \vdots & \ddots & \vdots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix}.$$

Пример 1.3 (Типы признаков). Индикатор некоторого свойства объекта — бинарный признак ($D_f = \{0, 1\}$); принадлежность к одной из нескольких категорий без отношения порядка между ними — номинальный (D_f конечно, порядок не определён); степень выраженности некоторого свойства — порядковый (D_f конечно и линейно упорядочено);

физическая величина – количественный ($D_f = \mathbb{R}$).

Пример 1.4 (Обучающая выборка). Пусть $\mathcal{X}$ – множество кошек, и для каждой известны два количественных признака: $f_1(x)$ – число банок корма, съедаемых в день, и $f_2(x)$ – возраст в годах; $\mathcal{Y} = \mathbb{R}$, $y(x)$ – вес в кг. Обучающая выборка из $\ell = 8$ наблюдений:

i	$f_1(x_i)$	$f_2(x_i)$	y_i
1	1	1	3.0
2	2	2	4.2
3	2	3	4.5
4	3	5	5.5
5	2	7	4.8
6	3	10	6.0
7	1	2	3.4
8	4	8	6.6

Матрица объектов–признаков F – это столбцы f_1, f_2 данной таблицы. Эта выборка используется также в примерах 3.2 и 7.2.

2 Типы задач по природе ответов

В зависимости от множества $\mathcal{Y}$ задачи обучения по прецедентам делятся на типы. Если $\mathcal{Y} = \mathbb{R}$ – это задача восстановления регрессии. Если $\mathcal{Y} = \{1, \dots, M\}$ – это задача классификации на M классов.

Пример 2.1 (Классификация). Пусть $\mathcal{X} = \mathbb{R}^2$, и по координатам точки $x = (x_1, x_2)$ требуется определить, по какую сторону от прямой $x_2 = x_1$ она расположена: $\mathcal{Y} = \{0, 1\}$, $y = 1$, если $x_2 > x_1$, и $y = 0$ иначе. Это задача классификации на два класса; в примере 3.2 такие задачи решаются линейной моделью.

Замечание 2.2. Задачи ранжирования и прогнозирования по структуре $\mathcal{Y}$ сводятся к классификации или регрессии и здесь отдельно не рассматриваются.

3 Модель алгоритмов и метод обучения

Определение 3.1 (Модель алгоритмов). Моделью алгоритмов называется параметрическое семейство отображений $A = \{g(x, \theta) \mid \theta \in \Theta\}$, где $g : \mathcal{X} \times \Theta \rightarrow \mathcal{Y}$ – заданная функция, Θ – пространство параметров.

Пример 3.2 (Линейная модель). Для признаков $f_1, \dots, f_n : \mathcal{X} \rightarrow \mathbb{R}$ и параметров $\theta = (\theta_0, \theta_1, \dots, \theta_n) \in \mathbb{R}^{n+1}$:

$$g(x, \theta) = \theta_0 + \sum_{j=1}^n \theta_j f_j(x) \quad - \text{ для регрессии,}$$

$$g(x, \theta) = \text{sign} \left(\theta_0 + \sum_{j=1}^n \theta_j f_j(x) \right) \quad - \text{ для классификации.}$$

Для выборки из примера 1.4 ($n = 2$) это $g(x, \theta) = \theta_0 + \theta_1 f_1(x) + \theta_2 f_2(x)$. Признаками для линейной модели могут служить и функции от исходных данных: если положить $f_j(x) = x^{j-1}$, та же формула задаёт полином степени $n - 1$.

Определение 3.3 (Метод обучения). Методом обучения называется отображение $\mu : (\mathcal{X} \times \mathcal{Y})^\ell \rightarrow A$, которое по обучающей выборке X^ℓ строит алгоритм $a = \mu(X^\ell) \in A$.

Различаются два этапа: на этапе обучения метод μ по выборке X^ℓ строит алгоритм a ; на этапе применения алгоритм a для нового объекта x выдаёт ответ $a(x)$.




Рис. 1: Этап обучения (сверху) и этап применения (снизу)

4 Напоминание из теории вероятностей

Для корректного введения понятия риска в следующем параграфе потребуется минимальный набор фактов теории вероятностей.

Будем считать, что на множестве $\mathcal{X} \times \mathcal{Y}$ задано (неизвестное нам) совместное распределение $p(x, y)$, и обучающая выборка – это набор наблюдений, случайно и независимо извлечённых из этого распределения.

Определение 4.1 (Простая выборка). Выборка $X^\ell = (x_i, y_i)_{i=1}^\ell$ называется простой (независимой одинаково распределённой), если пары (x_i, y_i) – независимые случайные величины с одним и тем же распределением $p(x, y)$.

Для случайных величин ξ, η и констант $\alpha, \beta \in \mathbb{R}$ математическое ожидание линейно: $\mathbb{E}[\alpha\xi + \beta\eta] = \alpha\mathbb{E}[\xi] + \beta\mathbb{E}[\eta]$; этот факт используется ниже.

Замечание 4.2. Вероятностная постановка – это способ формализовать неточность и неполноту реальных данных: одному и тому же x на практике могут соответствовать разные y (например, из-за погрешностей измерений), и вместо функциональной зависимости $y^*(x)$ удобнее говорить о распределении $p(x, y)$.

Предположим, что распределение $p(x, y)$ (точнее, его плотность) моделируется параметрическим семейством $\varphi(x, y, \theta)$, $\theta \in \Theta$, – так же, как модель алгоритмов $g(x, \theta)$ аппроксимирует целевую функцию y^* . Требуется по выборке X^ℓ подобрать параметр θ , при котором плотность $\varphi(\cdot, \cdot, \theta)$ наилучшим образом согласуется с данными.

Определение 4.3 (Функция правдоподобия). Пусть $X^\ell = (x_i, y_i)_{i=1}^\ell$ – простая выборка из распределения с плотностью $\varphi(x, y, \theta)$. Функцией правдоподобия называется

$$L(\theta, X^\ell) = \prod_{i=1}^{\ell} \varphi(x_i, y_i, \theta).$$

(Совместная плотность независимых наблюдений равна произведению плотностей.)

Определение 4.4 (Принцип максимума правдоподобия). Оценкой максимального правдоподобия (ММП) называется

$$\theta_{\text{ML}} = \arg \max_{\theta \in \Theta} L(\theta, X^\ell).$$

Поскольку логарифм монотонно возрастает, максимизация $L(\theta, X^\ell)$ равносильна минимизации $-\ln L(\theta, X^\ell)$; а поскольку логарифм произведения равен сумме логарифмов,

$$\theta_{\text{ML}} = \arg \min_{\theta \in \Theta} (-\ln L(\theta, X^\ell)) = \arg \min_{\theta \in \Theta} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta)).$$

5 Функция потерь, эмпирический и истинный риск

Определение 5.1 (Функция потерь). Функцией потерь называется неотрицательная функция $\mathcal{L}(a, x, y)$, характеризующая величину ошибки алгоритма a на объекте x с истинным ответом y . Стандартные примеры при $\mathcal{Y} \subseteq \mathbb{R}$:

$$\begin{aligned} \mathcal{L}(a, x, y) &= [a(x) \neq y] && \text{(классификация),} \\ \mathcal{L}(a, x, y) &= |a(x) - y|, \\ \mathcal{L}(a, x, y) &= (a(x) - y)^2 && \text{(регрессия).} \end{aligned}$$

Определение 5.2 (Эмпирический риск). Эмпирическим риском алгоритма a на выборке X^ℓ называется

$$Q(a, X^\ell) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(a, x_i, y_i).$$

Определение 5.3 (Истинный риск). Истинным (или ожидаемым) риском алгоритма a называется

$$R(a) = \mathbb{E}_{(x,y) \sim p} \mathcal{L}(a, x, y).$$

Величина $R(a)$ характеризует качество работы a на новых, ещё не виденных объектах. Но $R(a)$ вычислить нельзя, так как $p(x, y)$ неизвестно; вместо этого мы умеем считать $Q(a, X^\ell)$ по имеющимся данным.

Утверждение 5.4. Если X^ℓ – простая выборка, то $\mathbb{E}[Q(a, X^\ell)] = R(a)$.

Доказательство. По определению эмпирического риска и линейности математического ожидания,

$$\mathbb{E}[Q(a, X^\ell)] = \mathbb{E}\left[\frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(a, x_i, y_i)\right] = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbb{E}[\mathcal{L}(a, x_i, y_i)].$$

Поскольку выборка простая, все пары (x_i, y_i) распределены одинаково – как $(x, y) \sim p$, поэтому каждое слагаемое равно $\mathbb{E}[\mathcal{L}(a, x_i, y_i)] = \mathbb{E}_{(x,y) \sim p} \mathcal{L}(a, x, y) = R(a)$, и

$$\mathbb{E}[Q(a, X^\ell)] = \frac{1}{\ell} \sum_{i=1}^{\ell} R(a) = \frac{1}{\ell} \cdot \ell \cdot R(a) = R(a). \quad \square$$

Утверждение 5.4 объясняет, почему разумно заменить минимизацию недоступного $R(a)$ минимизацией вычислимого $Q(a, X^\ell)$: в среднем по всем случайным выборкам Q равен R .

Определение 5.5 (Принцип минимизации эмпирического риска (ERM)).

$$\mu(X^\ell) = \arg \min_{a \in A} Q(a, X^\ell).$$

Утверждение 5.6 (Связь ERM и ММП). Пусть модель алгоритмов $A = \{a_\theta \mid \theta \in \Theta\}$ и вероятностная модель $\varphi(x, y, \theta)$ используют один и тот же параметр θ . Если положить функцию потерь $\mathcal{L}(a_\theta, x, y) = -\ln \varphi(x, y, \theta)$, то принцип ERM для этой потери совпадает с принципом максимума правдоподобия:

$$\arg \min_{\theta \in \Theta} Q(a_\theta, X^\ell) = \theta_{\text{ML}}.$$

Доказательство. По определению эмпирического риска для указанной потери,

$$Q(a_\theta, X^\ell) = \frac{1}{\ell} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta)).$$

Умножение на положительную константу $1/\ell$ не меняет точку минимума по θ , поэтому

$$\arg \min_{\theta} Q(a_\theta, X^\ell) = \arg \min_{\theta} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta)) = \theta_{\text{ML}},$$

где последнее равенство – это в точности определение 4.4 в форме, полученной в конце §4. $\square$

6 Практический приём: матричное дифференцирование

Практический приём: матричное дифференцирование. Для скалярной функции $f(w)$ векторного аргумента $w \in \mathbb{R}^n$ градиентом называется вектор $\nabla_w f(w) = (\partial f / \partial w_1, \dots, \partial f / \partial w_n)^\top$. Потребуется два тождества:

$$\nabla_w (a^\top w) = a, \quad \nabla_w (w^\top A w) = (A + A^\top)w.$$

Утверждение 6.1 (Градиент линейной формы). Для $a \in \mathbb{R}^n$ и $f(w) = a^\top w = \sum_{i=1}^n a_i w_i$ верно $\nabla_w f(w) = a$.

Доказательство. Зафиксируем $k \in \{1, \dots, n\}$. Слагаемое $a_k w_k$ – единственное в сумме $\sum_i a_i w_i$, зависящее от w_k , поэтому $\partial f / \partial w_k = a_k$. Это верно для каждого k , значит $\nabla_w f(w) = (a_1, \dots, a_n)^\top = a$. $\square$

Утверждение 6.2 (Градиент квадратичной формы). Для $A \in \mathbb{R}^{n \times n}$ и $f(w) = w^\top A w = \sum_{i=1}^n \sum_{j=1}^n A_{ij} w_i w_j$ верно $\nabla_w f(w) = (A + A^\top)w$.

Доказательство. Зафиксируем k . В двойной сумме от w_k зависят только слагаемые с $i = k$ или $j = k$:

$$f(w) = A_{kk} w_k^2 + w_k \sum_{j \neq k} A_{kj} w_j + w_k \sum_{i \neq k} A_{ik} w_i + (\text{члены, не содержащие } w_k).$$

Дифференцируя по w_k (первое слагаемое даёт $2A_{kk}w_k$ по правилу дифференцирования степенной функции),

$$\frac{\partial f}{\partial w_k} = 2A_{kk}w_k + \sum_{j \neq k} A_{kj}w_j + \sum_{i \neq k} A_{ik}w_i = \sum_{j=1}^n A_{kj}w_j + \sum_{i=1}^n A_{ik}w_i = (Aw)_k + (A^T w)_k.$$

Так как равенство верно для каждого k , $\nabla_w f(w) = Aw + A^T w = (A + A^T)w$. $\square$

Пример 6.3. Проверим обе формулы при $n = 2$ для $f(w) = a^T w + w^T A w$, $a = (2, -1)^T$, $A = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix}$. Раскрывая f напрямую и дифференцируя,

$$f(w) = (2w_1 - w_2) + (w_1^2 + w_1w_2 + 2w_2^2), \quad \frac{\partial f}{\partial w_1} = 2 + 2w_1 + w_2, \quad \frac{\partial f}{\partial w_2} = -1 + w_1 + 4w_2.$$

По предложениям 6.1 и 6.2, $A + A^T = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}$ и

$$\nabla_w f(w) = a + (A + A^T)w = \begin{pmatrix} 2 \\ -1 \end{pmatrix} + \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \end{pmatrix} = \begin{pmatrix} 2 + 2w_1 + w_2 \\ -1 + w_1 + 4w_2 \end{pmatrix},$$

что совпадает с прямым вычислением.

Выведем формулу для градиента нормы невязки, которая понадобится в следующем параграфе. Раскрывая скобки,

$$\|Xw - y\|^2 = (Xw - y)^T (Xw - y) = w^T X^T X w - 2y^T X w + y^T y.$$

Первое слагаемое – квадратичная форма с матрицей $X^T X$ (симметричной), второе – линейная форма с вектором $-2X^T y$ (поскольку $y^T X w = (X^T y)^T w$), третье от w не зависит. Применяя предложения 6.1 и 6.2 почленно,

$$\nabla_w \|Xw - y\|^2 = (X^T X + (X^T X)^T)w - 2X^T y = 2X^T X w - 2X^T y = 2X^T (Xw - y).$$

Эта формула используется в следующем параграфе, а также в дальнейшем изложении.

Рассмотренные тождества касаются дифференцирования по вектору. Аналогично определяется дифференцирование скалярной функции по матрице: для $f : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$ градиентом $\nabla_A f(A)$ называется матрица тех же размеров, что и A , с элементами $(\nabla_A f(A))_{ij} = \partial f / \partial A_{ij}$. Типичный пример такой функции – определитель.

Утверждение 6.4 (Градиент определителя). Пусть $A \in \mathbb{R}^{n \times n}$ невырождена. Тогда

$$\nabla_A \det A = \det(A) (A^{-1})^T.$$

Доказательство. Разложим определитель по i -й строке: $\det A = \sum_{k=1}^n A_{ik} C_{ik}$, где $C_{ik} = (-1)^{i+k} M_{ik}$ – алгебраическое дополнение элемента A_{ik} , а минор M_{ik} – определитель матрицы, полученной вычёркиванием строки i и столбца k из A . Минор M_{ik} не содержит ни одного элемента строки i , в частности не зависит от A_{ij} ни при каком j . Поэтому в сумме $\sum_k A_{ik} C_{ik}$ от A_{ij} зависит только слагаемое с $k = j$, и

$$\frac{\partial \det A}{\partial A_{ij}} = C_{ij}.$$

Это верно для любых i, j , поэтому $\nabla_A \det A = (C_{ij})$ – транспонированная матрица алгебраических дополнений, называемая присоединённой матрицей: $(C_{ij}) = \text{adj}(A)^T$. Из формулы обратной матрицы $A^{-1} = \det(A)^{-1} \text{adj}(A)$ получаем $\text{adj}(A) = \det(A) A^{-1}$, откуда $\nabla_A \det A = \text{adj}(A)^T = \det(A) (A^{-1})^T$. $\square$

Пример 6.5. При $n = 2$, $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$, $\det A = ad - bc$, откуда непосредственным дифференцированием

$$\nabla_A \det A = \begin{pmatrix} \partial(\det A)/\partial a & \partial(\det A)/\partial b \\ \partial(\det A)/\partial c & \partial(\det A)/\partial d \end{pmatrix} = \begin{pmatrix} d & -c \\ -b & a \end{pmatrix}.$$

С другой стороны, $A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$, так что $\det(A)(A^{-1})^\top = \begin{pmatrix} d & -c \\ -b & a \end{pmatrix}$ – формулы совпадают.

Замечание 6.6. Градиент определителя используется, например, при работе с плотностью многомерного нормального распределения, куда определитель ковариационной матрицы входит через нормировочный множитель.

7 Пример: метод наименьших квадратов как ERM

Рассмотрим линейную модель $g(x, \theta) = \theta_0 + \sum_{j=1}^n \theta_j f_j(x)$ с квадратичной функцией потерь, как в определении 5.1. Обозначим через $X \in \mathbb{R}^{\ell \times (n+1)}$ матрицу объектов–признаков с добавленным первым столбцом из единиц (под свободный член θ_0), через $y \in \mathbb{R}^\ell$ – вектор ответов. Тогда

$$Q(\theta) = \frac{1}{\ell} \sum_{i=1}^{\ell} (g(x_i, \theta) - y_i)^2 = \frac{1}{\ell} \|X\theta - y\|^2,$$

и минимизация $Q(\theta)$ равносильна минимизации $\|X\theta - y\|^2$, так как множитель $1/\ell$ не влияет на точку минимума.

Теорема 7.1 (Нормальные уравнения МНК). Если $X^\top X$ невырождена, то $\theta^* = \arg \min_{\theta} \|X\theta - y\|^2$ единствен и равен

$$\theta^* = (X^\top X)^{-1} X^\top y.$$

Доказательство. По формуле для градиента нормы невязки из §6, $\nabla_{\theta} \|X\theta - y\|^2 = 2X^\top(X\theta - y)$. В точке минимума градиент обращается в ноль:

$$2X^\top(X\theta - y) = 0 \iff X^\top X\theta = X^\top y,$$

откуда при невырожденности $X^\top X$ следует $\theta = (X^\top X)^{-1} X^\top y$, и эта точка единственна. Матрица Гессе равна $\nabla_{\theta}^2 \|X\theta - y\|^2 = 2X^\top X$; она всегда положительно полуопределена, так как $w^\top (X^\top X) w = \|Xw\|^2 \geq 0$ для любого w , а при невырожденности $X^\top X$ – положительно определена (иначе нашёлся бы $w \neq 0$ с $Xw = 0$ и $X^\top Xw = 0$, противоречие). Значит, $\|X\theta - y\|^2$ выпукла, и найденная стационарная точка – глобальный минимум. $\square$

Пример 7.2. Применим теорему 7.1 к выборке из примера 1.4: $X \in \mathbb{R}^{8 \times 3}$ (со столбцом единиц под θ_0) и $y \in \mathbb{R}^8$ составлены по данным таблицы этого примера. Решение системы нормальных уравнений $X^\top X\theta = X^\top y$ (вычисления, как в теореме 7.1, опускаем) даёт

$$\theta^* \approx (2.201, 0.893, 0.114),$$

то есть $g(x, \theta^*) \approx 2.201 + 0.893f_1(x) + 0.114f_2(x)$.

Пример 7.3 (Вероятностная интерпретация МНК). Предположим дополнительно, что $y = g(x, \theta) + \varepsilon$, где шум $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ независим для разных наблюдений и не зависит от x . Тогда при фиксированном x ответ y распределён как $\mathcal{N}(g(x, \theta), \sigma^2)$, и

$$\varphi(x, y, \theta) = p(x) \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - g(x, \theta))^2}{2\sigma^2}\right).$$

Логарифмируя,

$$-\ln \varphi(x, y, \theta) = \underbrace{-\ln p(x) + \frac{1}{2} \ln(2\pi\sigma^2)}_{C, \text{ не зависит от } \theta} + \frac{1}{2\sigma^2} (g(x, \theta) - y)^2.$$

По предложению 5.6, $\theta_{\text{ML}} = \arg \min_{\theta} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta))$. Слагаемое ℓC от θ не зависит, а положительный множитель $1/(2\sigma^2)$ на точку минимума не влияет, поэтому

$$\theta_{\text{ML}} = \arg \min_{\theta} \sum_{i=1}^{\ell} (g(x_i, \theta) - y_i)^2 = \arg \min_{\theta} \|X\theta - y\|^2 = \theta^*.$$

Иными словами, найденное в примере 7.2 решение нормальных уравнений – это в точности оценка максимального правдоподобия для линейной модели с независимым гауссовским шумом постоянной дисперсии.

Заключение

Замечание 7.4. Вне рассмотрения остались две темы. Во-первых, минимизация эмпирического риска до нуля не гарантирует малости истинного риска – это явление переобучения. Во-вторых, нормальные уравнения – не единственный способ решать $\arg \min_{\theta} Q(\theta)$; в следующей лекции тот же результат получен итеративно, методом градиентного спуска, и линейная регрессия разобрана подробнее.

Машинное обучение

Лекция 2 — Линейные модели: градиентный спуск и регуляризация

Мотивация

В Лекции 1 для линейной модели $g(x, \theta) = \theta_0 + \sum_{j=1}^n \theta_j f_j(x)$ и квадратичной функции потерь была получена явная формула $\theta^* = (X^T X)^{-1} X^T y$ и на конкретной выборке (восемь объектов, признаки f_1, f_2) вычислен ответ. У этой формулы есть два недостатка. Во-первых, обращение матрицы $X^T X$ размера $(n+1) \times (n+1)$ требует $O(n^3)$ операций, что дорого при большом числе признаков. Во-вторых, формула вовсе не работает, если $X^T X$ вырождена, и работает плохо, если $X^T X$ близка к вырожденной, — это происходит при почти линейной зависимости между признаками. В этой лекции разбираются два независимых способа справиться с этими проблемами: итерационный метод (градиентный спуск, не требующий обращения матрицы) и регуляризация (модификация функционала, гарантирующая невырожденность).

1 Метод градиентного спуска

Функционал $Q(\theta) = \|X\theta - y\|^2$ выпуклый (Лекция 1, Теорема о нормальных уравнениях), поэтому его стационарная точка — глобальный минимум. Вместо решения уравнения $\nabla Q(\theta) = 0$ в явном виде можно искать минимум итерационно.

Определение 1.1 (Градиентный спуск). Методом градиентного спуска для минимизации дифференцируемого функционала $Q(\theta)$ называется итерационная процедура

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla Q(\theta^{(t)}), \quad t = 0, 1, 2, \dots,$$

где $\theta^{(0)}$ — начальное приближение, $\eta_t > 0$ — шаг (learning rate).

Направление $-\nabla Q(\theta^{(t)})$ — это направление наискорейшего локального убывания Q , поэтому при достаточно малом η_t выполняется $Q(\theta^{(t+1)}) \leq Q(\theta^{(t)})$. Следующее утверждение уточняет, при каких $\eta_t \equiv \eta$ (постоянный шаг) последовательность $\theta^{(t)}$ сходится к минимуму для нашего квадратичного функционала.

Утверждение 1.2 (Сходимость градиентного спуска). Пусть $X^T X$ невырождена, $\theta^* = (X^T X)^{-1} X^T y$, и пусть $\lambda_{\max}$ — наибольшее собственное число матрицы $X^T X$. Если шаг постоянен, $\eta_t \equiv \eta$, и $0 < \eta < 1/\lambda_{\max}$, то $\theta^{(t)} \rightarrow \theta^*$ при $t \rightarrow \infty$ для любого начального приближения $\theta^{(0)}$.

Доказательство. Так как $X^T X \theta^* = X^T y$ (нормальные уравнения),

$$\nabla Q(\theta) = 2X^T(X\theta - y) = 2X^T X\theta - 2X^T y = 2X^T X(\theta - \theta^*) = H(\theta - \theta^*),$$

где $H = 2X^T X$ — симметричная положительно определённая матрица (при невырожденности $X^T X$). Обозначим $e_t = \theta^{(t)} - \theta^*$. Тогда

$$e_{t+1} = \theta^{(t+1)} - \theta^* = e_t - \eta H e_t = (I - \eta H) e_t, \quad \text{откуда} \quad e_t = (I - \eta H)^t e_0.$$

Пусть $v_1, \dots, v_n$ – ортонормированный базис из собственных векторов H с собственными числами $\mu_1, \dots, \mu_n > 0$ ($\mu_{\max} = 2\lambda_{\max}$), и $e_0 = \sum_i c_i v_i$. Матрица $I - \eta H$ имеет тот же базис собственных векторов с числами $1 - \eta\mu_i$, поэтому

$$e_t = \sum_i c_i (1 - \eta\mu_i)^t v_i, \quad \|e_t\|^2 = \sum_i c_i^2 (1 - \eta\mu_i)^{2t}.$$

Каждое слагаемое стремится к нулю при $t \rightarrow \infty$ тогда и только тогда, когда $|1 - \eta\mu_i| < 1$, то есть $0 < \eta < 2/\mu_i$. Это верно для всех i одновременно при $0 < \eta < 2/\mu_{\max} = 1/\lambda_{\max}$, значит $\|e_t\| \rightarrow 0$. $\square$

Пример 1.3. При $n = 1$, $Q(\theta) = \theta^2$ ($H = 2$, $\lambda_{\max}$ для этой модели играет число 1), шаг $\theta^{(t+1)} = \theta^{(t)} - \eta \cdot 2\theta^{(t)} = (1 - 2\eta)\theta^{(t)}$, так что $\theta^{(t)} = (1 - 2\eta)^t \theta^{(0)}$. Ряд сходится к $0 = \theta^*$ при $0 < \eta < 1$, расходится при $\eta > 1$ и колеблется не убывая при $\eta = 1$ ($\theta^{(t)} = \pm \theta^{(0)}$) – ровно то, что предсказывает предложение 1.2.




Рис. 1: Схематический путь градиентного спуска на квадратичном Q с вытянутыми (не круговыми) линиями уровня – отношение полуосей эллипсов равно $\sqrt{\lambda_{\max}/\lambda_{\min}}$. Чем сильнее вытянуты эллипсы (хуже обусловленность), тем заметнее «зигзаг»: шаг, хороший вдоль направления $\lambda_{\min}$, слишком велик вдоль направления $\lambda_{\max}$.

Замечание 1.4 (Скорость сходимости). Доказательство показывает больше, чем сходимость: медленнее всего убывают компоненты с собственными числами, ближайшими к границам спектра, а точная скорость (при оптимальном выборе η) определяется числом обусловленности $\text{cond}(X^T X) = \lambda_{\max}/\lambda_{\min}$ – отношением наибольшего и наименьшего собственных чисел. Чем ближе $\lambda_{\min}$ к нулю (то есть чем ближе $X^T X$ к вырожденной), тем медленнее сходится градиентный спуск. Это тот же параметр $\lambda_{\min}$, что вызывает неустойчивость нормальных уравнений – см. §2.

Определение 1.5 (Стохастический градиентный спуск). Пусть $Q(\theta) = \frac{1}{\ell} \sum_{i=1}^{\ell} Q_i(\theta)$, где $Q_i(\theta) = \mathcal{L}(a_\theta, x_i, y_i)$ – потеря на одном объекте. Стохастическим градиентным спуском (SGD) называется процедура

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla Q_{i_t}(\theta^{(t)}),$$

где на каждом шаге индекс i_t выбирается случайно (равномерно на $\{1, \dots, \ell\}$ или последовательным проходом по перемешанной выборке).

В отличие от обычного (batch) градиентного спуска, здесь каждый шаг требует $O(n)$, а не $O(n\ell)$ операций – это существенно при больших ℓ . Платой за это является шум:

$\nabla Q_{i_t}(\theta)$ – лишь несмещённая оценка $\nabla Q(\theta)$ (в смысле, аналогичном утверждению 5.4 из Лекции 1 – матожидание по случайному индексу i_t равно $\nabla Q(\theta)$), и последовательность $\theta^{(t)}$ не сходится к θ^* при постоянном шаге, а колеблется в его окрестности. Чтобы добиться сходимости, шаг обычно берут убывающим, $\eta_t \rightarrow 0$; общепринятое (Роббинс–Монро, 1951) достаточное условие –

$$\sum_{t=0}^{\infty} \eta_t = \infty, \quad \sum_{t=0}^{\infty} \eta_t^2 < \infty$$

(например, $\eta_t \sim 1/t$) – шаги должны убывать, но не слишком быстро, чтобы суммарно можно было пройти любое расстояние. На практике используют мини-пакеты (mini-batch): усредняют ∇Q_i по небольшой случайной группе объектов, получая компромисс между точностью batch-градиента и дешёвизной SGD.

2 Мультиколлинеарность и обусловленность

Определение 2.1 (Мультиколлинеарность). Признаки $f_1, \dots, f_n$ называются мультиколлинеарными, если столбцы матрицы X (почти) линейно зависимы. В этом случае матрица $X^T X$ (почти) вырождена: у неё есть собственное число $\lambda_{\min}$, близкое к нулю.

Пример 2.2. Пусть $\ell = 3$ и признак f_2 пропорционален f_1 : $f_2 = 2f_1$, со значениями $f_1 = (1, 2, 3)^T$. Без учёта свободного члена,

$$X = \begin{pmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{pmatrix}, \quad X^T X = \begin{pmatrix} 14 & 28 \\ 28 & 56 \end{pmatrix}, \quad \det(X^T X) = 14 \cdot 56 - 28^2 = 0.$$

Матрица вырождена: второй столбец $X^T X$ равен удвоенному первому, так как $f_2 = 2f_1$. Нормальные уравнения либо не имеют решения, либо имеют их бесконечно много (вдоль направления $(2, -1)$, на котором $X^T X$ обращается в нуль).

Утверждение 2.3 (Неустойчивость решения). Пусть $A = X^T X$ невырождена, с наименьшим и наибольшим собственными числами $\lambda_{\min}, \lambda_{\max} > 0$, $b = X^T y$, $\theta = A^{-1}b$. Если b возмущён на δb , то решение $\theta + \delta\theta = A^{-1}(b + \delta b)$ удовлетворяет

$$\frac{\|\delta\theta\|}{\|\theta\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|}, \quad \text{cond}(A) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Доказательство. Так как A симметрична, для любого v верно $\|Av\| \leq \lambda_{\max} \|v\|$ и $\|Av\| \geq \lambda_{\min} \|v\|$ (раскладывая v по ортонормированному базису собственных векторов). Из $\delta\theta = A^{-1}\delta b$ и первого неравенства, применённого к A^{-1} (с собственными числами $1/\lambda_i$), получаем $\|\delta\theta\| \leq \|\delta b\| / \lambda_{\min}$. Из $b = A\theta$ и второго неравенства – $\|b\| \geq \lambda_{\min} \|\theta\|$... точнее, применяя оценку сверху к $b = A\theta$: $\|\theta\| \geq \|b\| / \lambda_{\max}$. Комбинируя,

$$\frac{\|\delta\theta\|}{\|\theta\|} \leq \frac{\|\delta b\| / \lambda_{\min}}{\|b\| / \lambda_{\max}} = \frac{\lambda_{\max}}{\lambda_{\min}} \cdot \frac{\|\delta b\|}{\|b\|}. \quad \square$$

Итак, чем больше $\text{cond}(X^T X)$ – тем сильнее шум в данных (например, погрешности измерений, входящие в y , а значит и в $b = X^T y$) раскачивает решение θ^* , и тем медленнее (замечание к предложению 1.2) сходится градиентный спуск. Оба явления – следствие малости $\lambda_{\min}$. Способ гарантированно отодвинуть $\lambda_{\min}$ от нуля – регуляризация.

3 Гребневая регрессия (Ridge, L_2 -регуляризация)

Свободный член θ_0 регуляризовать нежелательно: прибавление константы ко всем y_i должно просто сдвигать θ_0 на ту же константу, а штраф за величину θ_0 этому препятствовал бы. Введём матрицу $D = \text{diag}(0, 1, \dots, 1) \in \mathbb{R}^{(n+1) \times (n+1)}$, обнуляющую вклад θ_0 .

Определение 3.1 (Гребневая регрессия). При параметре регуляризации $\lambda > 0$ регуляризованным эмпирическим риском называется

$$Q_\lambda(\theta) = \|X\theta - y\|^2 + \lambda \theta^\top D \theta = \|X\theta - y\|^2 + \lambda \sum_{j=1}^n \theta_j^2,$$

а гребневой регрессией – метод $\theta_\lambda^* = \arg \min_\theta Q_\lambda(\theta)$.

Практический приём: матричное дифференцирование (Лекция 1). Напомним два факта из Лекции 1: для симметричной A верно $\nabla_\theta(\theta^\top A \theta) = 2A\theta$, и $\nabla_\theta \|X\theta - y\|^2 = 2X^\top(X\theta - y)$.

Теорема 3.2 (Нормальные уравнения гребневой регрессии). Для любого $\lambda > 0$ матрица $X^\top X + \lambda D$ положительно определена (в частности, невырождена, даже если $X^\top X$ вырождена), и

$$\theta_\lambda^* = (X^\top X + \lambda D)^{-1} X^\top y.$$

Доказательство. По формулам из практического приёма, $\nabla_\theta Q_\lambda(\theta) = 2X^\top(X\theta - y) + 2\lambda D\theta$. Приравнявая нулю, $(X^\top X + \lambda D)\theta = X^\top y$.

Проверим положительную определённость. Пусть $v \neq 0$ и $v^\top(X^\top X + \lambda D)v = 0$. Так как оба слагаемых $\|Xv\|^2 = v^\top X^\top X v$ и $\lambda v^\top D v$ неотрицательны, оба должны быть равны нулю. Из $v^\top D v = \sum_{j \geq 1} v_j^2 = 0$ следует $v_1 = \dots = v_n = 0$, то есть $v = (v_0, 0, \dots, 0)$ с $v_0 \neq 0$. Но первый столбец X – это столбец из единиц, поэтому $Xv = v_0 \mathbf{1} \neq 0$ (так как $\ell \geq 1$), и $\|Xv\|^2 = \ell v_0^2 > 0$ – противоречие. Значит, $X^\top X + \lambda D$ положительно определена, и найденная стационарная точка – единственный глобальный минимум Q_λ (выпуклой функции). $\square$

Замечание 3.3. При $\lambda \rightarrow 0$ формула переходит в обычные нормальные уравнения (Лекция 1); при $\lambda \rightarrow \infty$ решение $\theta_\lambda^* \rightarrow (\theta_0, 0, \dots, 0)$ – все веса, кроме свободного члена, стягиваются к нулю (можно проверить, переписав $\theta_\lambda^* = (X^\top X / \lambda + D)^{-1} X^\top y / \lambda$ и устремив $\lambda \rightarrow \infty$). Промежуточные значения λ дают компромисс: увеличение λ увеличивает смещение (bias) решения, но уменьшает его разброс (variance) и, как показано выше, устраняет неустойчивость при мультиколлинеарности.

4 Байесовская интерпретация: апостериорный максимум

В Лекции 1 было показано, что θ^* (обычные нормальные уравнения) – это оценка максимума правдоподобия (ММП) для линейной модели с независимым гауссовским шумом $\varepsilon \sim \mathcal{N}(0, \sigma^2)$: $\theta_{\text{ML}} = \arg \min_\theta \|X\theta - y\|^2$. Байесовский подход добавляет априорное распределение на параметр – θ также считается случайным, с известной плотностью $p(\theta)$ до наблюдения данных.

Определение 4.1 (Апостериорный максимум (МАР)). Пусть $p(\theta)$ – априорная плотность параметра, $L(\theta, X^\ell)$ – функция правдоподобия (Лекция 1). По формуле Байеса апостериорная плотность $p(\theta | X^\ell) \propto L(\theta, X^\ell) p(\theta)$. Оценкой апостериорного максимума называется

$$\theta_{\text{МАР}} = \arg \max_{\theta} L(\theta, X^\ell) p(\theta) = \arg \min_{\theta} (-\ln L(\theta, X^\ell) - \ln p(\theta)).$$

Утверждение 4.2 (Связь МАР и гребневой регрессии). Пусть шум гауссовский, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, как в Лекции 1, а априорное распределение – независимое гауссовское на нерегуляризуемых координатах: $\theta_j \sim \mathcal{N}(0, \tau^2)$ независимо для $j = 1, \dots, n$, θ_0 имеет несобственное (равномерное) априорное распределение. Тогда

$$\theta_{\text{МАР}} = \theta_{\lambda}^*, \quad \lambda = \sigma^2 / \tau^2.$$

Доказательство. Из Лекции 1, $-\ln L(\theta, X^\ell) = \ell C + \frac{1}{2\sigma^2} \|X\theta - y\|^2$, где C от θ не зависит. Далее,

$$-\ln p(\theta) = \sum_{j=1}^n \left(\frac{1}{2} \ln(2\pi\tau^2) + \frac{\theta_j^2}{2\tau^2} \right) = \frac{n}{2} \ln(2\pi\tau^2) + \frac{1}{2\tau^2} \theta^\top D \theta$$

(слагаемое для θ_0 отсутствует ввиду несобственного априорного распределения). Сумма даёт

$$-\ln L(\theta, X^\ell) - \ln p(\theta) = \text{const} + \frac{1}{2\sigma^2} \|X\theta - y\|^2 + \frac{1}{2\tau^2} \theta^\top D \theta.$$

Умножая на положительную константу $2\sigma^2$ (аргумент минимума не меняется),

$$\theta_{\text{МАР}} = \arg \min_{\theta} \left(\|X\theta - y\|^2 + \frac{\sigma^2}{\tau^2} \theta^\top D \theta \right) = \theta_{\lambda}^*, \quad \lambda = \sigma^2 / \tau^2. \quad \square$$

Замечание 4.3. Чем увереннее априорное предположение о малости весов (меньше τ^2), тем сильнее эффективная регуляризация $\lambda = \sigma^2 / \tau^2$. Аналогичная связь есть и для L_1 -регуляризации из следующего параграфа: если положить θ_j независимыми с плотностью Лапласа $p(\theta_j) \propto \exp(-|\theta_j|/b)$, то $-\ln p(\theta)$ содержит слагаемое $\sum |\theta_j|/b$, и МАР-оценка совпадает с LASSO.

5 LASSO (L_1 -регуляризация)

Определение 5.1 (LASSO). При $\lambda > 0$ LASSO (least absolute shrinkage and selection operator) – это метод

$$\theta_{\lambda}^* = \arg \min_{\theta} \left(\|X\theta - y\|^2 + \lambda \sum_{j=1}^n |\theta_j| \right).$$

В отличие от гребневой регрессии, здесь штраф $\sum |\theta_j|$ не дифференцируем при $\theta_j = 0$, и явной формулы для θ_{λ}^* не существует; решение находят численно (покоординатный спуск, субградиентные методы). Качественно же LASSO ведёт себя иначе, чем ridge: при достаточно большом λ решение θ_{λ}^* – разреженное, то есть часть координат обращается в точности в ноль, а не просто становится малой. Это делает LASSO инструментом отбора признаков.




Рис. 2: Схематическая иллюстрация: минимум квадратичного Q на L_1 -шаре типично достигается в вершине (разреженное решение); на L_2 -шаре (круге) выделенных направлений нет, и решение обычно не разрежено.

Замечание 5.2. Геометрическая причина: множество уровня $\{\theta : \sum |\theta_j| \leq c\}$ – многогранник с вершинами на координатных осях (там, где часть координат равна нулю), тогда как $\{\theta : \sum \theta_j^2 \leq c\}$ – шар, гладкий и без выделенных направлений. У выпуклой задачи минимизации гладкого Q на выпуклом множестве решение часто попадает на границу; для многогранника это преимущественно вершины и рёбра (разреженные точки), для шара – произвольная точка сферы (плотное решение).

Заключение

Замечание 5.3. Вне рассмотрения остались: линейные модели классификации (логистическая регрессия, метод опорных векторов) – предмет следующей лекции; строгая теория сходимости SGD (условия Роббинса–Монро приведены без доказательства); способы выбора параметра λ по данным (скользящий контроль, рассмотренный в общих чертах в Лекции о переобучении).

Машинное обучение

Лекция 3 — Линейная классификация: логистическая регрессия и метод опорных векторов

Мотивация

В Лекции 1 линейный классификатор был введён формулой $a(x) = \text{sign}(\theta_0 + \sum_{j=1}^n \theta_j f_j(x))$ (Пример 3.2), а в качестве функции потерь для классификации — индикатор ошибки $\mathcal{L}(a, x, y) = [a(x) \neq y]$. У этой потери есть техническая проблема: как функция параметра θ она кусочно-постоянна, её градиент почти всюду равен нулю, и градиентный спуск (Лекция 2) к ней неприменим. В этой лекции разбираются два независимых способа обойти эту проблему: заменить индикатор гладкой функцией потерь, допускающей вероятностную интерпретацию (логистическая регрессия), или отказаться от градиентного подхода в пользу геометрической идеи максимального отступа, приводящей к задаче выпуклой оптимизации с ограничениями (метод опорных векторов, SVM).

1 Логистическая регрессия

Рассмотрим задачу классификации на два класса, $\mathcal{Y} = \{0, 1\}$ (Пример 2.1: $y = 1$, если $x_2 > x_1$, и $y = 0$ иначе). Вместо того чтобы сразу предсказывать y , логистическая регрессия моделирует вероятность $p(y = 1 | x)$.

Определение 1.1 (Логистическая (сигмоидная) функция).

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z \in \mathbb{R}.$$

Функция σ монотонно возрастает от 0 до 1, $\sigma(0) = 1/2$, и удовлетворяет удобному тождеству $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ (проверяется прямым дифференцированием $\sigma(z) = (1 + e^{-z})^{-1}$).




Рис. 1: График логистической функции

Определение 1.2 (Модель логистической регрессии). $g(x, \theta) = \sigma(\theta_0 + \sum_{j=1}^n \theta_j f_j(x))$ моделирует $p(y = 1 | x, \theta)$; предсказание $a(x) = [g(x, \theta) \geq 1/2]$.

Обозначим $h_i = g(x_i, \theta)$ (как и раньше, θ включает свободный член, а x_i — соответствующий столбец единиц). Поскольку $y_i \in \{0, 1\}$, удобно записать вероятность одной формулой: $p(y_i | x_i, \theta) = h_i^{y_i} (1 - h_i)^{1-y_i}$. Функция правдоподобия (Лекция 1) — $L(\theta, X^\ell) = \prod_{i=1}^\ell h_i^{y_i} (1 - h_i)^{1-y_i}$, и

Определение 1.3 (Логистическая функция потерь).

$$\mathcal{L}(a_\theta, x, y) = -y \ln g(x, \theta) - (1 - y) \ln(1 - g(x, \theta)).$$

По построению $-\ln L(\theta, X^\ell) = \sum_i \mathcal{L}(a_\theta, x_i, y_i)$, так что принцип ERM для логистической потери – это в точности ММП (предложение о связи ERM и ММП, Лекция 1).

Утверждение 1.4 (Градиент логистической потери). Пусть $Q(\theta) = \sum_{i=1}^\ell \mathcal{L}(a_\theta, x_i, y_i)$. Тогда

$$\nabla_\theta Q(\theta) = \sum_{i=1}^\ell (h_i - y_i) x_i = X^\top (h - y),$$

где $h = (h_1, \dots, h_\ell)^\top$.

Доказательство. Обозначим $z_i = \theta^\top x_i$, так что $h_i = \sigma(z_i)$. По правилу дифференцирования сложной функции и тождеству $\sigma' = \sigma(1 - \sigma)$,

$$\frac{\partial \mathcal{L}_i}{\partial z_i} = -y_i \frac{\sigma'(z_i)}{\sigma(z_i)} + (1 - y_i) \frac{\sigma'(z_i)}{1 - \sigma(z_i)} = -y_i(1 - h_i) + (1 - y_i)h_i = h_i - y_i.$$

Так как $\partial z_i / \partial \theta = x_i$, по цепному правилу $\nabla_\theta \mathcal{L}_i = (h_i - y_i) x_i$. Суммируя по i , получаем утверждение. $\square$

Замечание 1.5. Формула $\nabla Q(\theta) = X^\top (h - y)$ имеет в точности ту же форму, что и градиент квадратичной потери из Лекции 1, $\nabla \|X\theta - y\|^2 = 2X^\top (X\theta - y)$ – в обоих случаях это «матрица объектов–признаков», умноженная на вектор разностей (предсказание минус ответ). Разница лишь в том, что предсказание $h = \sigma(X\theta)$ здесь нелинейно по θ .

Утверждение 1.6 (Выпуклость). $Q(\theta)$ выпукла.

Доказательство. Дифференцируя формулу предложения 1.4 ещё раз по θ (с учётом $\partial h_i / \partial \theta = h_i(1 - h_i)x_i$), получаем матрицу Гессе

$$\nabla_\theta^2 Q(\theta) = \sum_{i=1}^\ell h_i(1 - h_i) x_i x_i^\top = X^\top S X, \quad S = \text{diag}(h_1(1 - h_1), \dots, h_\ell(1 - h_\ell)).$$

Так как $h_i \in (0, 1)$, диагональные элементы S неотрицательны, и для любого v , $v^\top X^\top S X v = \sum_i s_i (x_i^\top v)^2 \geq 0$ – матрица Гессе положительно полуопределена, Q выпукла (тот же приём, что и для $X^\top X$ в Лекции 1). $\square$

В отличие от линейной регрессии, уравнение $\nabla Q(\theta) = 0$ здесь трансцендентно и не решается в явном виде; но выпуклость (предложение 1.6) гарантирует, что градиентный спуск (Лекция 2) сходится к глобальному минимуму.

Пример 1.7 (Один шаг градиентного спуска вручную). Пусть $n = 1$ (единственный признак $f_1(x) = x$), три объекта: $x_1 = 1, y_1 = 0$; $x_2 = 2, y_2 = 1$; $x_3 = 3, y_3 = 1$. Начнём с $\theta^{(0)} = (\theta_0, \theta_1) = (0, 0)$. Тогда для всех трёх объектов $z_i = \theta_0 + \theta_1 x_i = 0$, и, так как $\sigma(0) = 1/2$, $h_i = 1/2$ одинаково для всех i . По предложению 1.4,

$$\begin{aligned} \nabla Q(\theta^{(0)}) &= X^\top (h - y), \quad X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \quad h - y = \begin{pmatrix} 0.5 \\ -0.5 \\ -0.5 \end{pmatrix}, \\ \nabla Q(\theta^{(0)}) &= \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 0.5 \\ -0.5 \\ -0.5 \end{pmatrix} = \begin{pmatrix} 0.5 - 0.5 - 0.5 \\ 0.5 - 1 - 1.5 \end{pmatrix} = \begin{pmatrix} -0.5 \\ -2 \end{pmatrix}. \end{aligned}$$

При шаге $\eta = 0.5$: $\theta^{(1)} = \theta^{(0)} - \eta \nabla Q(\theta^{(0)}) = (0, 0) - 0.5(-0.5, -2) = (0.25, 1)$ – уже после одного шага $\theta_1 > 0$, то есть модель начинает верно улавливать, что большим x соответствует класс 1.




Рис. 2: Выборка примера 1.7: требуется отделить x_1 (класс 0) от x_2, x_3 (класс 1)

2 Метод опорных векторов: жёсткий зазор

В этом параграфе удобнее использовать обозначения $\mathcal{Y} = \{-1, +1\}$ вместо $\{0, 1\}$ (Пример 2.1 переразмечается: $y = +1$, если $x_2 > x_1$, и $y = -1$ иначе) и явно выписывать свободный член: классификатор ищется в виде $a(x) = \text{sign}(w^\top x + b)$, $w \in \mathbb{R}^n$, $b \in \mathbb{R}$ (x здесь без добавленной единицы).

Определение 2.1 (Отступ). Отступом (margin) объекта (x_i, y_i) относительно гиперплоскости $w^\top x + b = 0$ называется $\gamma_i = y_i(w^\top x_i + b) / \|w\|$. Если $\gamma_i > 0$, объект классифицирован верно. Отступом выборки называется $\gamma = \min_i \gamma_i$.

Величина γ_i – это (со знаком) евклидово расстояние от x_i до гиперплоскости. Идея метода опорных векторов – выбрать (w, b) , максимизирующие отступ γ , то есть разделяющую полосу максимальной ширины между классами. Пара (w, b) определена с точностью до положительного масштабирования (умножение обоих на $c > 0$ не меняет $\text{sign}(w^\top x + b)$ и не меняет γ_i), поэтому можно наложить нормировку $\min_i y_i(w^\top x_i + b) = 1$; тогда $\gamma = 1 / \|w\|$, и максимизация γ равносильна минимизации $\|w\|$.

Определение 2.2 (Прямая задача SVM).

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{при условиях} \quad y_i(w^\top x_i + b) \geq 1, \quad i = 1, \dots, \ell.$$

Это задача выпуклого квадратичного программирования (выпуклая квадратичная цель, линейные ограничения); при линейно разделимой выборке решение существует и единственно.

Практический приём: множители Лагранжа. Для задачи $\min_w f(w)$ при ограничениях $c_i(w) \geq 0$ вводится функция Лагранжа $L(w, \alpha) = f(w) - \sum_i \alpha_i c_i(w)$, $\alpha_i \geq 0$. В точке минимума выполнены условия стационарности $\nabla_w L = 0$ и условия дополняющей нежёсткости $\alpha_i c_i(w) = 0$ (либо ограничение не активно, $c_i(w) > 0$, и тогда $\alpha_i = 0$; либо оно активно, $c_i(w) = 0$). При выпуклой f и линейных c_i (наш случай) эти условия достаточны для оптимальности, а подстановка стационарной точки обратно в L даёт эквивалентную двойственную задачу $\max_{\alpha \geq 0} \min_w L(w, \alpha)$.

Функция Лагранжа для задачи 2.2 (перепишем ограничения как $c_i(w, b) = y_i(w^\top x_i + b) - 1 \geq 0$):

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^{\ell} \alpha_i [y_i(w^\top x_i + b) - 1], \quad \alpha_i \geq 0.$$

Утверждение 2.3 (Стационарность). В точке минимума по (w, b) выполнено

$$w = \sum_{i=1}^{\ell} \alpha_i y_i x_i, \quad \sum_{i=1}^{\ell} \alpha_i y_i = 0.$$

Доказательство. $\nabla_w L = w - \sum_i \alpha_i y_i x_i = 0$ и $\partial L / \partial b = -\sum_i \alpha_i y_i = 0$. $\square$

Теорема 2.4 (Двойственная задача SVM). Подстановка предложения 2.3 в $L(w, b, \alpha)$ даёт

$$\max_{\alpha} \sum_{i=1}^{\ell} \alpha_i - \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \alpha_i \alpha_j y_i y_j (x_i^{\top} x_j) \quad \text{при} \quad \alpha_i \geq 0, \sum_{i=1}^{\ell} \alpha_i y_i = 0.$$

Доказательство. Подставляя $w = \sum_i \alpha_i y_i x_i$ в L ,

$$\frac{1}{2} \|w\|^2 = \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j,$$

$$\sum_i \alpha_i y_i w^{\top} x_i = \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j, \quad \sum_i \alpha_i y_i b = b \sum_i \alpha_i y_i = 0.$$

Собирая,

$$L = \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j - \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j + \sum_i \alpha_i = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j. \quad \square$$

Двойственная задача – тоже выпуклое квадратичное программирование, но теперь с ℓ переменными α_i и простыми ограничениями (в отличие от прямой задачи с $n + 1$ переменными). Решив её (численно, здесь не обсуждается), восстанавливаем $w^* = \sum_i \alpha_i^* y_i x_i$, а b^* – из любого i с $\alpha_i^* > 0$, для которого ограничение активно: $y_i(w^{*\top} x_i + b^*) = 1 \Rightarrow b^* = y_i - w^{*\top} x_i$ (используем $y_i^2 = 1$).

Определение 2.5 (Опорные векторы). Объекты x_i с $\alpha_i^* > 0$ называются опорными векторами. По условию дополняющей нежёсткости для них $y_i(w^{*\top} x_i + b^*) = 1$ – они лежат ровно на границе полосы. Для объектов с $\alpha_i^* = 0$ ограничение неактивно; они не влияют на решение – ни на w^* (сумма по опорным векторам), ни, следовательно, на классификатор $a(x) = \text{sign}(\sum_i \alpha_i^* y_i x_i^{\top} x + b^*)$.




Рис. 3: Разделяющая прямая (сплошная), границы полосы отступа (пунктир) и опорные векторы (выделены кружком) для примера 2.1 – схематически.

3 Мягкий зазор

Если выборка линейно неразделима (или разделима, но с очень узким отступом из-за выбросов), задача 2.2 не имеет допустимых решений. Вводятся переменные зазора (slack) $\xi_i \geq 0$, допускающие нарушение отступа за плату:

Определение 3.1 (Прямая задача SVM с мягким зазором).

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^{\ell} \xi_i \quad \text{при} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0,$$

где $C > 0$ – параметр, задающий компромисс между шириной полосы и суммарным нарушением отступа.

Утверждение 3.2 (Двойственная задача с мягким зазором). Двойственная задача имеет тот же вид, что и в теореме 2.4, с дополнительным ограничением $\alpha_i \leq C$:

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{при} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0.$$

Доказательство. Лагранжиан теперь $L = \frac{1}{2} \|w\|^2 + C \sum \xi_i - \sum_i \alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i$, $\alpha_i, \mu_i \geq 0$. Условия стационарности по w, b те же, что в предложении 2.3; по ξ_i : $\partial L / \partial \xi_i = C - \alpha_i - \mu_i = 0$, откуда $\mu_i = C - \alpha_i$. Так как $\mu_i \geq 0$, получаем $\alpha_i \leq C$. Слагаемые с ξ_i в L сокращаются: $C\xi_i - \alpha_i\xi_i - \mu_i\xi_i = (C - \alpha_i - \mu_i)\xi_i = 0$, и оставшаяся часть подстановки в точности повторяет вычисление из теоремы 2.4. $\square$

Замечание 3.3. При $C \rightarrow \infty$ нарушения отступа становятся сколь угодно дорогими, и задача сходится к жёсткому зазору. Малые C допускают больше нарушений ради более широкой полосы – ещё один параметр регуляризации, в духе Лекции 2: увеличение C уменьшает смещение и увеличивает разброс решения.

4 Ядра

И двойственная задача (теорема 2.4), и итоговый классификатор зависят от объектов только через скалярные произведения $x_i^\top x_j$ (соответственно $x_i^\top x$). Это позволяет обучать нелинейные разделяющие поверхности, не меняя алгоритм: достаточно заменить скалярное произведение на функцию, вычисляющую скалярное произведение в некотором другом (обычно более многомерном) пространстве признаков.

Определение 4.1 (Ядро). Функция $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ называется ядром, если существует отображение $\varphi : \mathcal{X} \rightarrow H$ в некоторое пространство со скалярным произведением, такое что $K(x, x') = \langle \varphi(x), \varphi(x') \rangle$ для всех $x, x' \in \mathcal{X}$.

Замечание 4.2 (Критерий Мерсера). K является ядром тогда и только тогда, когда для любого конечного набора точек $x_1, \dots, x_\ell$ матрица $\|K(x_i, x_j)\|_{\ell \times \ell}$ симметрична и положительно полуопределена. Мы не доказываем этот факт; достаточно уметь проверять его для конкретных K .

Пример 4.3 (Квадратичное ядро). При $x = (x_1, x_2) \in \mathbb{R}^2$ положим $\varphi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$. Тогда

$$\langle \varphi(x), \varphi(x') \rangle = x_1^2 x_1'^2 + 2x_1 x_2 x_1' x_2' + x_2^2 x_2'^2 = (x_1 x_1' + x_2 x_2')^2 = (x^\top x')^2,$$

то есть $K(x, x') = (x^\top x')^2$ – ядро, соответствующее явному отображению в пространство квадратичных мономов. Более общий факт: для любого $d \in \mathbb{N}$ и $c \geq 0$, $K(x, x') = (x^\top x' + c)^d$ – полиномиальное ядро степени d (соответствующий φ выписывается явно, но громоздок при больших d).

Пример 4.4 (Гауссово (RBF) ядро).

$$K(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right).$$

Соответствующее пространство H бесконечномерно (явного конечномерного φ не существует); тем не менее K вычисляется за $O(n)$ и удовлетворяет критерию Мерсера.

С ядром двойственная задача (теорема 2.4) принимает вид

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad \text{при} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0,$$

а классификатор – $a(x) = \text{sign}(\sum_i \alpha_i^* y_i K(x_i, x) + b^*)$: во всех формулах $x_i^\top x_j$ заменено на $K(x_i, x_j)$ («kernel trick»), явно вычислять φ не требуется.

Заключение

Замечание 4.5. Вне рассмотрения остались: многоклассовое обобщение SVM (один-против-всех или один-против-одного); численные методы решения двойственной задачи (SMO – Sequential Minimal Optimization); выбор C и параметров ядра по данным (скользящий контроль); связь SVM с ERM для потери hinge $\mathcal{L}(a, x, y) = \max(0, 1 - y a(x))$, которая приводит к прямой задаче 3.1 напрямую, без геометрии отступа. Логистическая регрессия и SVM с линейным ядром решают структурно похожую задачу разными методами (гладкая оптимизация против квадратичного программирования) и на практике часто дают близкие разделяющие поверхности.

Машинное обучение

Лекция 4 — Переобучение и обобщающая способность

Мотивация

В Лекции 1 было показано, что $\mathbb{E}[Q(a, X^\ell)] = R(a)$ для простой выборки: эмпирический риск в среднем равен истинному. Это утверждение – о среднем по случайным выборкам, а не о конкретной выборке X^ℓ , на которой алгоритм $a = \mu(X^\ell)$ ещё и сам зависит от X^ℓ . Крайний пример: алгоритм, запоминая обучающую выборку и выдающий на новом объекте произвольный ответ, имеет $Q(a, X^\ell) = 0$, но $R(a)$ может быть сколь угодно велико. Значит, малость $Q(a, X^\ell)$ сама по себе ничего не говорит о качестве a на новых данных. В этой лекции разбираются: количественное описание разрыва между Q и R (разложение смещение–разброс), практический способ его оценить, не имея доступа к R (скользящий контроль), и теоретическая граница, связывающая разрыв со сложностью модели (VC-размерность).

1 Переобучение

Определение 1.1 (Переобучение). Метод μ переобучается на выборке X^ℓ , если построенный им алгоритм $a = \mu(X^\ell)$ имеет малый эмпирический риск $Q(a, X^\ell)$, но существенно больший истинный риск $R(a)$: $R(a) - Q(a, X^\ell) \gg 0$.

Замечание 1.2. Переобучение – следствие того, что a подбирается по той же выборке, на которой затем измеряется Q : минимизация $Q(a, X^\ell)$ по $a \in A$ находит алгоритм, наилучшим образом согласующийся не только с закономерностью, но и со случайным шумом конкретной выборки. Чем богаче (сложнее) модель A , тем точнее она способна подстроиться под шум – и тем больше типичный разрыв $R(a) - Q(a, X^\ell)$.




Рис. 1: Типичная зависимость эмпирического и истинного риска от сложности модели: Q монотонно убывает, R имеет минимум – разрыв $R(a) - Q(a, X^\ell)$ (переобучение) нарастает правее оптимума.

2 Разложение смещение–разброс

Зафиксируем объект x и рассмотрим регрессию с квадратичной потерей. Пусть истинная зависимость $y = f(x) + \varepsilon$, где шум ε не зависит от x и от обучающей выборки, $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$ (ср. вероятностную модель Лекции 1). Обучающая выборка X^ℓ сама случайна, поэтому построенный по ней алгоритм $a(x) = a_{X^\ell}(x)$ – тоже случайная величина (при фиксированном x , случайность – по X^ℓ).

Теорема 2.1 (Разложение смещение–разброс).

$$\mathbb{E}_{X^\ell, \varepsilon}[(y - a(x))^2] = \underbrace{(f(x) - \mathbb{E}_{X^\ell}[a(x)])^2}_{\text{смещение}^2} + \underbrace{\text{Var}_{X^\ell}(a(x))}_{\text{разброс}} + \underbrace{\sigma^2}_{\text{шум}}.$$

Доказательство. Так как ε не зависит от X^ℓ (а значит, и от $a(x)$) и $\mathbb{E}[\varepsilon] = 0$,

$$\begin{aligned} \mathbb{E}[(y - a(x))^2] &= \mathbb{E}[(f(x) - a(x) + \varepsilon)^2] \\ &= \mathbb{E}[(f(x) - a(x))^2] + 2\mathbb{E}[f(x) - a(x)]\mathbb{E}[\varepsilon] + \mathbb{E}[\varepsilon^2] \\ &= \mathbb{E}[(f(x) - a(x))^2] + \sigma^2. \end{aligned}$$

Обозначим $\bar{a} = \mathbb{E}_{X^\ell}[a(x)]$. Добавляя и вычитая $\bar{a}$,

$$\mathbb{E}[(f(x) - a(x))^2] = \mathbb{E}[(f(x) - \bar{a})^2] + 2(f(x) - \bar{a})\mathbb{E}[\bar{a} - a(x)] + \mathbb{E}[(\bar{a} - a(x))^2].$$

Первое слагаемое – константа $(f(x) - \bar{a})^2$ (смещение в квадрате); среднее слагаемое равно нулю, так как $\mathbb{E}[\bar{a} - a(x)] = \bar{a} - \bar{a} = 0$; последнее – по определению $\text{Var}_{X^\ell}(a(x))$. Складывая с σ^2 , получаем утверждение. $\square$

Замечание 2.2. Смещение (bias) измеряет систематическую ошибку модели: даже усреднив предсказание по всем возможным обучающим выборкам, $\bar{a}$ может не совпадать с $f(x)$ (например, если истинная зависимость нелинейна, а модель линейна). Разброс (variance) измеряет чувствительность $a(x)$ к конкретной обучающей выборке. Простые модели (мало параметров) обычно имеют большое смещение и малый разброс; сложные модели – малое смещение и большой разброс. Переобучение (определение 1.1) – это режим большого разброса: алгоритм точно подстраивается под каждую конкретную выборку, поэтому сильно от неё зависит.

Пример 2.3. Вернёмся к регрессии веса кота по признакам из примера 1.4 Лекции 1. Модель-константа $g(x, \theta) = \theta_0$ имеет малый разброс (её значение слабо зависит от конкретной выборки), но большое смещение, если вес всё же зависит от рациона и возраста. На другом краю – модель высокой степени (например, полином высокой степени от обоих признаков): она способна точно пройти через все восемь точек обучающей выборки ($Q = 0$), но её значение в новой точке сильно зависит от того, какие именно восемь котов попали в выборку, – большой разброс. Линейная модель из примера 7.2 – промежуточный случай.

Пример 2.4 (Численный пример: две крайности). Пусть истинная зависимость – константа, $f(x) \equiv 4$, шум $\varepsilon \in \{-1, +1\}$ равновероятно (в частности, $\mathbb{E}[\varepsilon] = 0$, $\sigma^2 = \mathbb{E}[\varepsilon^2] = 1$), обучающая выборка состоит из одного наблюдения $y_1 = 4 + \varepsilon_1 \in \{3, 5\}$. Сравним два «игрушечных» метода.

Метод А («запомнить»): $a(x) = y_1$ при любом x . Тогда $\mathbb{E}[a(x)] = \mathbb{E}[y_1] = 4 = f(x)$ – смещение равно 0; а $\text{Var}(a(x)) = \text{Var}(y_1) = \text{Var}(\varepsilon_1) = 1$ – весь разброс перешёл от данных к алгоритму. По теореме 2.1, $\mathbb{E}[(y - a(x))^2] = 0^2 + 1 + 1 = 2$.

Метод В («игнорировать данные»): $a(x) = 0$ при любом x , каким бы ни было y_1 . Тогда $\mathbb{E}[a(x)] = 0$, смещение $f(x) - \mathbb{E}[a(x)] = 4$, а $\text{Var}(a(x)) = 0$ (алгоритм детерминирован, от выборки не зависит). По той же теореме, $\mathbb{E}[(y - a(x))^2] = 4^2 + 0 + 1 = 17$.

Метод А выигрывает у метода В ($2 < 17$): здесь маленький разброс метода В не окупает его огромного смещения. Ни один из этих двух крайних методов не оптимален в общем случае – разумный компромисс (например, усреднение по нескольким наблюдениям вместо одного) уменьшает разброс, почти не увеличивая смещение; управление этим компромиссом явно – в точности роль параметра регуляризации λ из Лекции 2.

3 Скользящий контроль

Разложение смещение–разброс объясняет природу переобучения, но не даёт способа обнаружить его на практике: $f(x)$ и распределение X^ℓ неизвестны, вычислить смещение и разброс нельзя. Работающий на практике приём – не использовать всю выборку для обучения.

Определение 3.1 (Отложенная выборка). Выборка X^L случайно делится на обучающую X^ℓ ($\ell < L$) и контрольную $X^k = X^L \setminus X^\ell$ ($k = L - \ell$). Алгоритм $a = \mu(X^\ell)$ строится только по X^ℓ , а его качество оценивается величиной $Q(a, X^k)$ – эмпирическим риском на объектах, не участвовавших в обучении.

Поскольку X^k не использовалась при построении a , оценка $Q(a, X^k)$ несмещена относительно $R(a)$ в том же смысле, что и утверждение 5.4 Лекции 1 (примененное к паре независимых выборок). Недостаток отложенной выборки – часть данных (X^k) не участвует в обучении, а оценка зависит от случайного разбиения.

Определение 3.2 (k -кратный скользящий контроль). Выборка X^L случайно разбивается на q примерно равных непересекающихся блоков $X_1, \dots, X_q$. Для каждого $n = 1, \dots, q$ строится алгоритм $a_n = \mu(X^L \setminus X_n)$ (обучение на всех блоках, кроме n -го) и вычисляется $Q(a_n, X_n)$. Оценкой скользящего контроля называется

$$\text{CV}(\mu, X^L) = \frac{1}{q} \sum_{n=1}^q Q(a_n, X_n).$$

Пример 3.3 (LOO вручную). Пусть $\mathcal{Y} = \mathbb{R}$, признаков нет ($n = 0$, модель – константа $g(\theta) = \theta_0$, метод – выборочное среднее), выборка из четырёх ответов $y = (2, 4, 6, 8)$, потеря квадратичная. При исключении объекта i метод А предсказывает среднее оставшихся трёх:

исключён	среднее остальных	ошибка ²
$y_1 = 2$	$(4+6+8)/3 = 6$	$(2 - 6)^2 = 16$
$y_2 = 4$	$(2+6+8)/3 \approx 5.33$	$(4 - 5.33)^2 \approx 1.78$
$y_3 = 6$	$(2+4+8)/3 \approx 4.67$	$(6 - 4.67)^2 \approx 1.78$
$y_4 = 8$	$(2+4+6)/3 = 4$	$(8 - 4)^2 = 16$

LOO(метод А) = $(16 + 1.78 + 1.78 + 16)/4 \approx 8.89$. Для сравнения, метод Б, всегда предсказывающий 0 независимо от данных (как в примере 2.4), даёт ошибки $2^2, 4^2, 6^2, 8^2$ на исключённых объектах, LOO(метод Б) = $(4 + 16 + 36 + 64)/4 = 30$. Скользящий контроль, не зная истинного $R(a)$, тем не менее верно улавливает, что метод А (учитывающий данные) лучше метода Б – ровно та же качественная картина, что и точный расчёт через теорему 2.1 в примере 2.4.

Замечание 3.4. При $q = L$ каждый блок состоит из одного объекта – это контроль по отдельным объектам (leave-one-out, LOO); он даёт наименее смещённую, но самую дорогую по вычислениям (нужно построить L алгоритмов) и высокодисперсную оценку. На практике обычно берут $q \in [5, 10]$: каждый алгоритм a_n обучается на достаточно большой части выборки, а оценка усредняется по нескольким разбиениям, что снижает разброс по сравнению с одной отложенной выборкой.

Практический приём: скользящий контроль как инструмент выбора модели. Если модель зависит от гиперпараметра (степень полинома, λ в гребневой регрессии из Лекции 2, C и ядро в SVM из Лекции 3), его выбирают, перебирая сетку значений и находя минимум $CV(\mu_\lambda, X^L)$ по λ – это и есть общая процедура, на которую ссылались Лекции 2 и 3.

4 VC-размерность

Скользящий контроль оценивает обобщающую способность экспериментально. Теоретический вопрос – существуют ли верхние границы на разрыв $R(a) - Q(a, X^\ell)$, зависящие только от сложности модели A и объёма выборки ℓ , но не от неизвестного распределения $p(x, y)$. Первые такие оценки получены В. Н. Вапником и А. Я. Червоненкисом.

Определение 4.1 (Разбиение множеством классификаторов). Пусть A – множество бинарных классификаторов $a : \mathcal{X} \rightarrow \{0, 1\}$. Говорят, что A разбивает (shatters) конечное множество точек $x_1, \dots, x_d \in \mathcal{X}$, если для любой разметки $(y_1, \dots, y_d) \in \{0, 1\}^d$ найдётся $a \in A$ с $a(x_i) = y_i$ при всех i – то есть все 2^d разметок реализуемы.

Определение 4.2 (VC-размерность). VC-размерностью $VCdim(A)$ называется наибольшее d , для которого найдётся набор из d точек, разбиваемый A (или ∞ , если такое d не ограничено).

Пример 4.3. Пусть $\mathcal{X} = \mathbb{R}^2$, A – множество линейных классификаторов $a(x) = [w^\top x + b \geq 0]$ (ср. Лекцию 3). Тогда $VCdim(A) = 3$.

Три точки общего положения (не лежащие на одной прямой) разбиваются: для каждой из $2^3 = 8$ разметок нетрудно провести прямую, отделяющую точки одного класса от другого (включая вырожденные случаи «все одного класса» – прямая, не пересекающая треугольник). Четыре точки разбить нельзя: если одна из них лежит внутри треугольника, образованного тремя другими, то разметка «внутренняя точка – одного класса, все три внешние – другого» нереализуема прямой (внутренняя точка – выпуклая комбинация внешних, и для любой прямой $w^\top x + b$ линейна, значит принимает на внутренней точке значение между значениями на внешних – не может быть строго противоположного знака сразу всем трём). Если же четыре точки в общем положении образуют выпуклый четырёхугольник, не реализуется «разметка крест-накрест» (противоположные вершины одного цвета) – классический пример XOR.

Замечание 4.4 (Теорема Вапника–Червоненкиса, без доказательства). Если $VCdim(A) = d < \infty$, то с вероятностью не менее $1 - \eta$ по случайной простой выборке X^ℓ одновременно для всех $a \in A$

$$R(a) \leq Q(a, X^\ell) + O\left(\sqrt{\frac{d \ln(\ell/d) + \ln(1/\eta)}{\ell}}\right).$$

Мы не доказываем эту оценку (доказательство существенно опирается на комбинаторную лемму Шелаха–Заура и требует отдельного развития), но подчеркнём качественный




Рис. 2: Слева: одна из восьми разметок трёх точек и разделяющая прямая (пунктир) – реализуемы все восемь. Справа: разметка «крест-накрест» четырёх точек – ни одна прямая не отделяет закрашенные вершины от незакрашенных.

смысл: разрыв между R и Q равномерно по всей модели A убывает с ростом ℓ и растёт с ростом $\text{VCdim}(A)$. Модель с бесконечной VC-размерностью (например, алгоритм, запоминающий выборку) не даёт гарантий обобщения ни при каком ℓ – в точности пример из мотивации.

Утверждение 4.5 (VC-размерность конечной модели). Если модель A конечна, то $\text{VCdim}(A) \leq \log_2 |A|$.

Доказательство. Пусть A разбивает набор из d точек. Тогда каждой из 2^d разметок соответствует хотя бы один алгоритм $a \in A$, реализующий её на этих точках, причём разным разметкам – разные алгоритмы (иначе один и тот же a не мог бы одновременно давать два разных набора ответов на одних и тех же точках). Значит, $|A| \geq 2^d$, откуда $d \leq \log_2 |A|$. Так как это верно для наибольшего разбиваемого d , $\text{VCdim}(A) \leq \log_2 |A|$. $\square$

Замечание 4.6. Это объясняет, почему конечные (или зависящие от небольшого числа дискретных решений) модели обобщаются лучше: решающее дерево глубины не более D с n бинарными признаками – конечная модель, и оценка предложения 4.5 даёт нетривиальную (хотя обычно грубую) границу VC-размерности через D и n – пригодится в Лекции 5, где ограничение глубины дерева – один из способов борьбы с переобучением.

5 Принцип структурной минимизации риска

Замечание о теореме Вапника–Червоненкиса подсказывает практическую стратегию выбора не только параметров внутри одной модели (как в скользящем контроле), но и самой модели – если есть несколько моделей разной сложности на выбор.

Определение 5.1 (Структурная минимизация риска). Пусть $A_1 \subset A_2 \subset \dots \subset A_M$ – вложенные модели возрастающей сложности, $\text{VCdim}(A_1) \leq \dots \leq \text{VCdim}(A_M)$. Принцип структурной минимизации риска (structural risk minimization, SRM) состоит в том, чтобы для каждого m найти $a_m = \arg \min_{a \in A_m} Q(a, X^\ell)$, а затем выбрать

$$m^* = \arg \min_{m=1, \dots, M} \left(Q(a_m, X^\ell) + \text{penalty}(\text{VCdim}(A_m), \ell) \right),$$

где penalty – граница из замечания о теореме Вапника–Червоненкиса (или её аналог), растущая по VC-размерности и убывающая по ℓ .

Замечание 5.2. SRM формализует рисунок 1: вместо того чтобы минимизировать только эмпирический риск Q (что всегда приводит к самой сложной модели A_M , так как $Q(a_m, X^\ell)$ не возрастает по m – более широкая модель может только уменьшить минимум), минимизируется верхняя оценка на R , явно штрафующая сложность. Гребневая

регрессия и LASSO (Лекция 2) реализуют похожую идею иначе: вместо дискретного набора вложенных моделей $A_1, \dots, A_M$ они штрафуют норму θ непрерывно, одним параметром λ , так что рост λ играет роль убывания эффективной сложности модели. Оба подхода – частные случаи одной идеи: компенсировать неизвестное $R(a)$ вычислимой величиной, штрафующей сложность.

Заключение

Замечание 5.3. Вне рассмотрения остались: точное доказательство VC-оценки; более точные современные границы (Rademacher complexity, PAC-Bayes); связь регуляризации (Лекция 2) со смещением и разбросом – параметр λ явно управляет компромиссом между ними, что теперь можно связать с теоремой 2.1 количественно. В следующих лекциях скользящий контроль будет систематически использоваться для выбора гиперпараметров моделей: глубины дерева (Лекция 5), ширины окна и числа соседей (Лекция 6).

Машинное обучение

Лекция 5 — Решающие деревья и композиции алгоритмов

Мотивация

Все модели, рассмотренные до сих пор (Лекции 1–3), были параметрическими и линейными: $g(x, \theta)$ – линейная (или сигмоидная от линейной) функция признаков. Это ограничивает форму разделяющей поверхности или регрессионной зависимости. Решающее дерево – модель другой природы: не формула от θ , а последовательность вопросов об объекте, кусочно-постоянная на итоге. Она умеет представлять сколь угодно сложные зависимости, но именно поэтому особенно склонна к переобучению (Лекция 4) – вопрос борьбы с этим проходит через всю лекцию: сначала для одного дерева (стрижка), затем для композиций многих деревьев (бэггинг, бустинг).

1 Решающее дерево

Определение 1.1 (Решающее дерево). Решающим деревом называется бинарное дерево, в каждой внутренней вершине v которого стоит предикат $[f_{j(v)}(x) < t_v]$ по одному признаку $f_{j(v)}$ с порогом $t_v \in \mathbb{R}$ (для количественного признака) или предикат вида $[f_{j(v)}(x) \in S_v]$ (для номинального), а в каждом листе – прогноз: класс (для классификации) или число (для регрессии). Алгоритм $a(x)$ спускается от корня к листу, на каждой вершине проверяя предикат и переходя в левое или правое поддерево, и возвращает прогноз найденного листа.

Модель дерева фиксированной структуры (заданное дерево с порогом) – кусочно-постоянная функция $x \mapsto \mathcal{Y}$, а множество всех деревьев не параметризуется конечномерным $\theta \in \Theta$ в смысле определения 3.1 Лекции 1 – это модель переменной структуры; методы обучения для неё жадные, не сводятся к ERM в чистом виде.

1.1 Критерии информативности

Пусть R – множество объектов обучающей выборки, попавших в вершину (или лист), $|R|$ – их число.

Определение 1.2 (Энтропийный критерий). Для классификации на K классов пусть $p_k = |\{i \in R : y_i = k\}|/|R|$. Энтропией множества R называется

$$H(R) = - \sum_{k=1}^K p_k \ln p_k$$

(с соглашением $0 \ln 0 = 0$).

Определение 1.3 (Критерий Джини).

$$\text{Gini}(R) = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2.$$

Обе величины неотрицательны и равны нулю тогда и только тогда, когда все объекты R одного класса («чистое» множество); обе максимальны при равномерном распределении классов. Для регрессии аналогом служит дисперсия:

Определение 1.4 (Критерий дисперсии).

$$D(R) = \frac{1}{|R|} \sum_{i \in R} (y_i - \bar{y}_R)^2, \quad \bar{y}_R = \frac{1}{|R|} \sum_{i \in R} y_i.$$

Определение 1.5 (Прирост информации). Пусть предикат в вершине с множеством объектов R разбивает его на $R = R_L \sqcup R_R$. Приростом информации для критерия $\Phi \in \{H, \text{Gini}, D\}$ называется

$$\text{Gain}(R, R_L, R_R) = \Phi(R) - \frac{|R_L|}{|R|} \Phi(R_L) - \frac{|R_R|}{|R|} \Phi(R_R).$$

Утверждение 1.6 (Неотрицательность прироста). Для энтропии и критерия Джини $\text{Gain}(R, R_L, R_R) \geq 0$ для любого разбиения.

Набросок доказательства. Обе функции $\Phi(p) = -\sum p_k \ln p_k$ и $\Phi(p) = 1 - \sum p_k^2$ строго вогнуты по вектору частот $p = (p_1, \dots, p_K)$. Частоты в R – это выпуклая комбинация частот в R_L, R_R с весами $|R_L|/|R|, |R_R|/|R|$ (простая проверка: числа объектов класса k в R равны сумме чисел в R_L и R_R). По определению вогнутости, $\Phi(\frac{|R_L|}{|R|} p^{(L)} + \frac{|R_R|}{|R|} p^{(R)}) \geq \frac{|R_L|}{|R|} \Phi(p^{(L)}) + \frac{|R_R|}{|R|} \Phi(p^{(R)})$, что в точности означает $\text{Gain} \geq 0$. $\square$

1.2 Построение дерева

Дерево строится жадно и рекурсивно: в каждой вершине перебираются все пары (признак, порог), выбирается разбиение, максимизирующее прирост информации, и рекурсия продолжается в обеих ветвях, пока не выполнен критерий останова.

Algorithm 1 Построение дерева (BuildTree)

```

1: procedure BuildTree( $R$ )
2:   if критерий останова выполнен для  $R$  then ▷ напр.,  $|R| < n_{\min}$ , глубина  $\geq d_{\max}$ ,
     или  $\Phi(R) = 0$ 
3:     return лист с прогнозом (класс большинства или  $\bar{y}_R$ )
4:   end if
5:   найти  $(j, t) = \arg \max_{j,t} \text{Gain}(R, R_L(j, t), R_R(j, t))$ , где  $R_L(j, t) = \{x \in R : f_j(x) < t\}$ 
6:   return вершину с предикатом  $[f_j(x) < t]$ , левое поддерево  $\text{BuildTree}(R_L)$ , правое
      $\text{BuildTree}(R_R)$ 
7: end procedure

```

Пример 1.7 (Прирост информации вручную). Пусть в вершине R восемь объектов двух классов: пять «+» и три «-», $p_+ = 5/8$, $p_- = 3/8$. Бинарный признак делит их на R_L

(четыре объекта: три «+», один «-») и R_R (четыре объекта: два «+», два «-»). По критерию Джини:

$$\text{Gini}(R) = 1 - \left(\frac{5}{8}\right)^2 - \left(\frac{3}{8}\right)^2 = 1 - 0.3906 - 0.1406 = 0.4688,$$

$$\text{Gini}(R_L) = 1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2 = 1 - 0.5625 - 0.0625 = 0.375, \quad \text{Gini}(R_R) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5.$$

$$\text{Gain} = 0.4688 - \frac{4}{8} \cdot 0.375 - \frac{4}{8} \cdot 0.5 = 0.4688 - 0.1875 - 0.25 = 0.0313 > 0,$$

как и предсказывает предложение 1.6. Аналогично (с натуральными логарифмами) считается энтропийный критерий: $H(R) \approx 0.661$, $H(R_L) \approx 0.562$, $H(R_R) = \ln 2 \approx 0.693$, прирост $\approx 0.661 - 0.5 \cdot 0.562 - 0.5 \cdot 0.693 \approx 0.034 > 0$ – тот же знак, хотя и другое число.




Рис. 1: Разбиение из примера 1.7: корень и два листа

2 Переобучение и стрижка

По предложению 1.6 прирост информации неотрицателен, и без критерия остановки дерево растёт, пока в каждом листе не останется один объект (или объекты с одинаковыми признаками) – эмпирический риск $Q(a, X^\ell)$ становится равен нулю. Это ровно определение 1.1 Лекции 4: неограниченное дерево – модель с (потенциально) неограниченной сложностью, предельный случай «запоминания выборки».

Замечание 2.1 (Предварительная и последующая стрижка). Предварительная стрижка (pre-pruning) останавливает рост дерева по эвристике: ограничение глубины $d_{\max}$, минимальное число объектов в листе $n_{\min}$, минимальный прирост информации. Недостаток – жадность: разбиение с малым локальным приростом может открывать путь к разбиениям с большим приростом глубже. Последующая стрижка (post-pruning) сначала строит полное дерево, затем отсекает поддеревья, если это не ухудшает (или допустимо ухудшает) качество на контрольной выборке – скользящий контроль из Лекции 4 применяется напрямую: перебираются поддеревья-кандидаты, и выбирается то, что минимизирует CV.

Определение 2.2 (Стрижка по цене сложности). Для полностью выращенного дерева T и параметра $\alpha \geq 0$ ценой сложности называется

$$Q_\alpha(T) = Q(T, X^\ell) + \alpha |\text{leaves}(T)|,$$

где $|\text{leaves}(T)|$ – число листьев. Стрижка по цене сложности выбирает поддерево $T' \subseteq T$, минимизирующее $Q_\alpha(T')$ среди всех поддеревьев с корнем в корне T .

Замечание 2.3. Это в точности принцип структурной минимизации риска (определение 5.1 Лекции 4), применённый к вложенному семейству поддеревьев T , упорядоченных по числу листьев: штраф $\alpha |\text{leaves}(T)|$ играет роль $\text{penalty}(\text{VCdim}, \ell)$ там. Параметр α ,

как и λ в гребневой регрессии (Лекция 2), выбирается скользящим контролем; $\alpha = 0$ не штрафует сложность вовсе (возвращает исходное дерево T), большие α агрессивно стригут дерево вплоть до одного листа (константный прогноз).

3 Бэггинг и случайный лес

Одно дерево, выбранное под конкретную выборку, имеет большой разброс (Лекция 4). Идея бэггинга – усреднить много таких моделей, обученных на слегка разных выборках, чтобы уменьшить разброс, не увеличивая смещение.

Определение 3.1 (Бутстреп). Бутстреп-выборкой размера ℓ называется выборка, полученная из X^ℓ независимым равновероятным выбором ℓ объектов с возвращением (объекты могут повторяться).

Определение 3.2 (Бэггинг). Бэггинг (bagging, bootstrap aggregating) строит B бутстреп-выборок $X_1^\ell, \dots, X_B^\ell$, на каждой обучает алгоритм $a_b = \mu(X_b^\ell)$ (в типичном случае – дерево, дерево не подрезается специально, чтобы иметь малое смещение), и возвращает

$$a(x) = \frac{1}{B} \sum_{b=1}^B a_b(x) \quad (\text{регрессия}), \quad a(x) = \arg \max_k |\{b : a_b(x) = k\}| \quad (\text{классификация, голосование}).$$

Утверждение 3.3 (Разброс усреднённого предсказания). Пусть $a_1(x), \dots, a_B(x)$ – одинаково распределённые случайные величины (по случайности бутстрепа) с $\text{Var}(a_b(x)) = \sigma^2$ и попарной корреляцией $\rho = \text{corr}(a_b(x), a_c(x))$, $b \neq c$, одной и той же для всех пар. Тогда для $\bar{a}(x) = \frac{1}{B} \sum_b a_b(x)$

$$\text{Var}(\bar{a}(x)) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

Доказательство.

$$\text{Var}(\bar{a}(x)) = \frac{1}{B^2} \left(\sum_b \text{Var}(a_b(x)) + \sum_{b \neq c} \text{Cov}(a_b(x), a_c(x)) \right) = \frac{1}{B^2} (B\sigma^2 + B(B-1)\rho\sigma^2) = \frac{\sigma^2}{B} + \frac{B-1}{B}\rho\sigma^2,$$

что и требовалось (перегруппировка слагаемых). $\square$

Пример 3.4. Пусть отдельное дерево имеет разброс $\sigma^2 = 4$ (в единицах y^2), а корреляция между деревьями бэггинга $\rho = 0.5$. При $B = 4$ деревьях

$$\text{Var}(\bar{a}(x)) = 0.5 \cdot 4 + \frac{1-0.5}{4} \cdot 4 = 2 + 0.5 = 2.5,$$

то есть усреднение четырёх деревьев снижает разброс с 4 до 2.5 – заметно, но не в 4 раза (как было бы при $\rho = 0$). Если случайный лес снижает корреляцию до $\rho = 0.2$, тот же расчёт даёт $\text{Var} = 0.2 \cdot 4 + \frac{0.8}{4} \cdot 4 = 0.8 + 0.8 = 1.6$ – дополнительный выигрыш от декоррелированности деревьев.

Замечание 3.5. При $B \rightarrow \infty$ разброс убывает не до нуля, а до $\rho\sigma^2$: полностью устранить его усреднением нельзя, так как деревья a_b , обученные на пересекающихся бутстреп-выборках из одних и тех же данных, коррелированы. Это мотивирует случайный лес (random forest): помимо бутстрепа объектов, в каждой вершине дерева признак для разбиения (шаг 3 алгоритма BuildTree) выбирается не из всех n признаков, а из случайного

подмножества размера $m < n$ (типично $m \approx \sqrt{n}$). Это уменьшает корреляцию ρ между деревьями (заставляя их иногда использовать разные признаки), а значит по предположению 3.3 уменьшает и итоговый разброс, ценой небольшого увеличения смещения отдельных деревьев.

4 Бустинг

Бэггинг строит независимые (по обучающим подвыборкам) модели и усредняет их – уменьшает разброс. Бустинг строит модели последовательно, каждая следующая исправляет ошибки предыдущих, – уменьшает смещение.

Рассмотрим классификацию, $\mathcal{Y} = \{-1, +1\}$ (как в Лекции 3). Пусть $b_1, \dots, b_T$ – слабые классификаторы (каждый лишь немного лучше случайного угадывания), и итоговый алгоритм ищется в виде $a(x) = \text{sign}(\sum_{t=1}^T \alpha_t b_t(x))$.

Определение 4.1 (Экспоненциальная потеря).

$$\mathcal{L}(a, x, y) = e^{-y F(x)}, \quad F(x) = \sum_{t=1}^T \alpha_t b_t(x).$$

AdaBoost минимизирует эмпирический риск для этой потери жадно, пошагово (forward stagewise): на шаге t уже построенная сумма $F_{t-1}(x) = \sum_{s < t} \alpha_s b_s(x)$ не меняется, и ищутся только новые α_t, b_t .

Теорема 4.2 (Вес слабого классификатора в AdaBoost). Пусть на шаге t веса объектов $w_i = \exp(-y_i F_{t-1}(x_i))$, слабый классификатор b_t фиксирован, и $\text{err}_t = \sum_{i: b_t(x_i) \neq y_i} w_i / \sum_{i=1}^{\ell} w_i$ – его взвешенная частота ошибок. Тогда $\alpha_t = \arg \min_{\alpha} \sum_i w_i e^{-\alpha y_i b_t(x_i)}$ равен

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \text{err}_t}{\text{err}_t}.$$

Доказательство. Обозначим $W = \sum_i w_i$. Так как $y_i b_t(x_i) \in \{-1, +1\}$, сумма разбивается на верно и неверно классифицированные объекты:

$$\sum_i w_i e^{-\alpha y_i b_t(x_i)} = e^{-\alpha} \sum_{i: b_t(x_i)=y_i} w_i + e^{\alpha} \sum_{i: b_t(x_i) \neq y_i} w_i = W[(1 - \text{err}_t)e^{-\alpha} + \text{err}_t e^{\alpha}].$$

Дифференцируя по α и приравнивая нулю: $-(1 - \text{err}_t)e^{-\alpha} + \text{err}_t e^{\alpha} = 0 \Rightarrow e^{2\alpha} = (1 - \text{err}_t)/\text{err}_t$, откуда следует утверждение (вторая производная $W[(1 - \text{err}_t)e^{-\alpha} + \text{err}_t e^{\alpha}] > 0$ – это минимум). $\square$

Замечание 4.3. Формула осмысленна при $\text{err}_t < 1/2$ (это и есть требование «слабости» – чуть лучше случайного угадывания): тогда $\alpha_t > 0$, и чем точнее b_t , тем больше его вес в сумме. После вычисления α_t веса объектов обновляются, $w_i \leftarrow w_i \exp(-\alpha_t y_i b_t(x_i))$ (с последующей нормировкой $\sum w_i = 1$) – ошибочно классифицированные b_t объекты получают больший вес, и следующий слабый классификатор b_{t+1} обучается уделять им больше внимания.

Пример 4.4 (Один шаг AdaBoost вручную). Три точки на прямой: $x_1 = 1, y_1 = +1$; $x_2 = 2, y_2 = -1$; $x_3 = 3, y_3 = +1$, начальные веса равномерны: $w_1 = w_2 = w_3 = 1/3$. Пусть слабый классификатор $b_1(x) = \text{sign}(x - 2.5)$ (то есть -1 при $x < 2.5$ и $+1$ при

$x \geq 2.5$). Тогда $b_1(1) = -1$ (неверно, истинный класс $+1$), $b_1(2) = -1$ (верно), $b_1(3) = +1$ (верно) – ошибается только на x_1 , значит $\text{err}_1 = w_1/(w_1+w_2+w_3) = 1/3$. По теореме 4.2,

$$\alpha_1 = \frac{1}{2} \ln \frac{1 - 1/3}{1/3} = \frac{1}{2} \ln 2 \approx 0.347.$$

Обновление весов, $w_i \leftarrow w_i \exp(-\alpha_1 y_i b_1(x_i))$: для x_1 (ошибка) множитель $e^{\alpha_1} = \sqrt{2}$, для x_2, x_3 (верно) множитель $e^{-\alpha_1} = 1/\sqrt{2}$. До нормировки: $w_1 = \frac{1}{3}\sqrt{2}$, $w_2 = w_3 = \frac{1}{3} \cdot \frac{1}{\sqrt{2}}$, сумма $= \frac{1}{3}(\sqrt{2} + \sqrt{2}) = \frac{2\sqrt{2}}{3}$. После нормировки – на удивление круглые числа:

$$w_1 = \frac{\sqrt{2}/3}{2\sqrt{2}/3} = \frac{1}{2}, \quad w_2 = w_3 = \frac{1/(3\sqrt{2})}{2\sqrt{2}/3} = \frac{1}{4}.$$

Вес единственного ошибочно классифицированного объекта x_1 вырос с $1/3$ до $1/2$: следующий слабый классификатор b_2 будет вынужден уделить ему больше внимания.

Замечание 4.5 (Градиентный бустинг). AdaBoost – частный случай общей схемы: на шаге t ищется b_t , приближающий антиградиент функции потерь по текущим предсказаниям $F_{t-1}(x_i)$ (для экспоненциальной потери это в точности эквивалентно теореме 4.2; в общем случае деревья b_t обучаются приближать $-\partial \mathcal{L}(F_{t-1}(x_i), y_i)/\partial F_{t-1}(x_i)$ методом наименьших квадратов). Это градиентный спуск (Лекция 2) не в пространстве параметров θ , а в пространстве функций F : каждый шаг $F_t = F_{t-1} + \alpha_t b_t$ сдвигает F в направлении убывания эмпирического риска.

Заключение

Замечание 4.6. Вне рассмотрения остались: точный вывод градиентного бустинга для произвольной гладкой потери; практические ускорения (гистограммные методы, регуляризация числа листьев – XGBoost, LightGBM); важность признаков (feature importance) как побочный продукт обучения леса. В следующей лекции – метрические методы классификации, где, в отличие от деревьев, вовсе нет явно обучаемых параметров.

Машинное обучение

Лекция 6 — Метрические и байесовские методы классификации

Мотивация

Линейные модели (Лекции 1–3) и деревья (Лекция 5) явно обучают параметры (веса θ или структуру дерева) по выборке, а затем применяют полученный алгоритм к новым объектам, уже не обращаясь к обучающей выборке напрямую. В этой лекции – два принципиально иных подхода. Метрические методы (§§1–3) вовсе не обучают параметры: решение для нового объекта x принимается непосредственно по обучающим объектам, ближайшим к x , в предположении, что близкие объекты имеют близкие ответы. Байесовские методы (§§4–6), напротив, обучают не разделяющую границу, а полную вероятностную модель данных $p(x, y)$, из которой граница – лишь следствие.

1 Обобщённый метрический классификатор

Пусть на $\mathcal{X}$ задана метрика $\rho(x, x')$. Для объекта x упорядочим обучающую выборку по возрастанию расстояния до x : $\rho(x, x_{(1)}) \leq \dots \leq \rho(x, x_{(\ell)})$, где $x_{(i)}$ – объект на i -м месте (с ответом $y_{(i)}$).

Определение 1.1 (Обобщённый метрический классификатор).

$$\Gamma_y(x) = \sum_{i=1}^{\ell} [y_{(i)} = y] w(i, x), \quad a(x) = \arg \max_{y \in \mathcal{Y}} \Gamma_y(x),$$

где $w(i, x) \geq 0$ – вес, убывающий по i .

Пример 1.2 (Частные случаи). k ближайших соседей (k NN): $w(i, x) = [i \leq k]$. Метод окна Парзена: $w(i, x) = K(\rho(x, x_{(i)})/h)$, где $h > 0$ – ширина окна, K – невозрастающая на $[0, \infty)$ функция ядра (например, $K(r) = [r \leq 1]$ – прямоугольное окно, или $K(r) = e^{-r^2/2}$ – гауссовское). Вариант переменной ширины: $w(i, x) = K(\rho(x, x_{(i)})/\rho(x, x_{(k+1)}))$ – ширина подстраивается под локальную плотность объектов. Метод потенциальных функций суммирует по всем объектам с обучаемыми весами («зарядами») $\gamma_i \geq 0$: $w(i, x) = \gamma_i K(\rho(x, x_i)/h)$; заряды подбираются итеративно (штраф $\gamma_i \leftarrow \gamma_i + 1$ при ошибке на x_i).

2 Выбор параметров скользящим контролем

Качество k NN и окна Парзена существенно зависит от k (или h): малые k – сложная модель с малым смещением и большим разбросом (переобучение, Лекция 4); большие k – простая модель, сглаживающая границу вплоть до предсказания самого частого класса при $k = \ell$. Оптимальное значение выбирается по скользящему контролю (определение 3.2 Лекции 4), как правило – контролем с исключением объектов по одному (LOO).

Практический приём: эффективное вычисление LOO для k NN. Наивно LOO требует ℓ раз заново находить k ближайших соседей – $O(\ell^2)$ на одно значение k . Но если заранее для каждого x_i отсортировать остальные объекты по расстоянию, ответ k NN при исключении x_i

для всех k одновременно вычисляется по этому списку за $O(\ell)$ – LOO(k) для всех $k = 1, \dots, \ell$ считается за $O(\ell^2)$ суммарно.

Пример 2.1. Пять обучающих точек на плоскости (Пример 2.1 Лекции 1: $y = 1$, если $x_2 > x_1$): $x_1 = (1, 3), y_1=1$; $x_2 = (0, 1), y_2=0$; $x_3 = (2, 2.5), y_3=1$; $x_4 = (3, 1), y_4=0$; $x_5 = (1, 0.5), y_5=0$. Классифицируем $x = (1.5, 2)$ методом 3NN с евклидовой метрикой: $\rho(x, x_1) \approx 1.12$, $\rho(x, x_2) \approx 1.80$, $\rho(x, x_3) \approx 0.71$, $\rho(x, x_4) \approx 1.80$, $\rho(x, x_5) \approx 1.58$. Три ближайших – x_3, x_1, x_5 с ответами 1, 1, 0; большинство – класс 1, значит $a(x) = 1$ (верно: $2 > 1.5$).




Рис. 1: Пример 2.1: окружность радиуса $\rho(x, x_5) \approx 1.58$ отделяет трёх ближайших соседей (x_3, x_1 – класс 1; x_5 – класс 0) от остальных

3 Отступ и отбор эталонов (STOLP)

Определение 3.1 (Отступ). Отступом объекта x_i называется $M(x_i) = \Gamma_{y_i}(x_i) - \max_{y \neq y_i} \Gamma_y(x_i)$, где $\Gamma_y(x_i)$ вычисляется по всем объектам выборки, кроме самого x_i (leave-one-out).

Объекты с $M(x_i) < 0$ – шумовые (среди объектов чужого класса, вероятно выбросы); с $M(x_i)$, близким к нулю сверху, – пограничные (информативны для границы); с большим $M(x_i) > 0$ – избыточные (глубоко внутри класса).

Пример 3.2. Посчитаем отступ объекта $x_2 = (0, 1), y_2 = 0$ из примера 2.1 при $k = 3$. Расстояния от x_2 до остальных: $\rho(x_2, x_5) \approx 1.12$, $\rho(x_2, x_1) \approx 2.24$, $\rho(x_2, x_3) \approx 2.50$, $\rho(x_2, x_4) = 3$. Три ближайших (без x_2) – x_5 (класс 0), x_1, x_3 (класс 1), так что $\Gamma_0(x_2) = 1$, $\Gamma_1(x_2) = 2$, и

$$M(x_2) = \Gamma_0(x_2) - \Gamma_1(x_2) = 1 - 2 = -1 < 0.$$

Отрицательный отступ означает, что при $k = 3$ ближайшие соседи x_2 чаще относятся к чужому классу – на первом шаге STOLP такой объект был бы удалён как шумовой (или как лежащий глубоко на территории соседнего класса).

Замечание 3.3. STOLP одновременно чистит выборку от шума и сжимает её: эталонное множество Ω обычно много меньше исходной выборки, но даёт то же качество – это существенно ускоряет применение метрических методов, где классификация нового объекта требует хранить и перебирать всю обучающую выборку (в отличие от линейных моделей, где достаточно вектора θ).

Algorithm 1 STOLP (отбор эталонных объектов)

```

1: удалить объекты с  $M(x_i) < 0$  (шум);  $\Omega \leftarrow \emptyset$ 
2: for каждого класса  $y$  do
3:   добавить в  $\Omega$  объект класса  $y$  с наибольшим отступом
4: end for
5: repeat
6:   по текущему  $\Omega$  найти неверно классифицируемый  $x_i$  с наименьшим отступом;
   добавить его в  $\Omega$ 
7: until все объекты классифицируются по  $\Omega$  верно (или достигнут лимит  $|\Omega|$ )
8: return  $\Omega$ 

```

4 Байесовское решающее правило

Метрические методы не используют явную модель данных. Переходим к противоположному подходу: пусть, как в Лекции 1, задано распределение $p(x, y)$ на $\mathcal{X} \times \mathcal{Y}$, $\mathcal{Y} = \{1, \dots, K\}$, и, в отличие от Лекции 1, дана общая матрица потерь $\lambda(y, y') \geq 0$ – плата за ответ y' при истинном классе y ($\lambda(y, y) = 0$).

Определение 4.1 (Условный риск). Для объекта x и ответа y' : $\rho(y', x) = \sum_{y=1}^K \lambda(y, y') p(y | x)$.

Теорема 4.2 (Байесовское решающее правило). Алгоритм $a^*(x) = \arg \min_{y' \in \mathcal{Y}} \rho(y', x)$ минимизирует истинный риск $R(a) = \mathbb{E}_{(x,y) \sim p} \lambda(y, a(x))$ среди всех измеримых $a : \mathcal{X} \rightarrow \mathcal{Y}$.

Доказательство. По формуле полного математического ожидания, $R(a) = \mathbb{E}_x[\mathbb{E}_{y|x} \lambda(y, a(x))] = \mathbb{E}_x[\rho(a(x), x)]$. Значение $a(x)$ можно выбирать независимо для каждого x , и $\rho(a(x), x) \geq \rho(a^*(x), x)$ по определению a^* ; значит $\mathbb{E}_x[\rho(a(x), x)] \geq \mathbb{E}_x[\rho(a^*(x), x)] = R(a^*)$ для любого a . $\square$

Следствие 4.3 (Правило максимума апостериорной вероятности). Для 0/1-потери $\lambda(y, y') = [y \neq y']$: $a^*(x) = \arg \max_{y \in \mathcal{Y}} p(y | x)$.

Доказательство. $\rho(y', x) = \sum_{y \neq y'} p(y | x) = 1 - p(y' | x)$, минимизация по y' равносильна максимизации $p(y' | x)$. $\square$

По формуле Байеса $p(y | x) = p(x | y)p(y)/p(x)$, а $p(x)$ от y не зависит, поэтому $a^*(x) = \arg \max_y p(x | y)p(y)$: оцениваем по выборке априорные вероятности $p(y)$ (доли классов) и функции правдоподобия классов $p(x | y)$. Способ моделирования $p(x | y)$ отличает конкретные методы далее.

5 Наивный байесовский классификатор

Оценивать $p(x | y)$ напрямую для $x = (f_1(x), \dots, f_n(x)) \in \mathbb{R}^n$ трудно – совместное распределение n признаков. Наивный Байес предполагает условную независимость: $p(x | y) = \prod_{j=1}^n p(f_j(x) | y)$, откуда

Определение 5.1 (Наивный байесовский классификатор).

$$a(x) = \arg \max_{y \in \mathcal{Y}} \left(\ln p(y) + \sum_{j=1}^n \ln p(f_j(x) | y) \right).$$

Одномерные $p(f_j(x) | y)$ оценить по выборке несравнимо проще совместной n -мерной: для номинального признака – доля объектов класса y с данным значением; для количественного – например, $f_j | y \sim \mathcal{N}(\mu_{jy}, \sigma_{jy}^2)$ по выборочным среднему и дисперсии среди объектов класса y .

Пример 5.2 (Наивный Байес вручную). Пусть $\mathcal{Y} = \{0, 1\}$, $p(y=0) = p(y=1) = 0.5$, и два бинарных признака с оценёнными по выборке вероятностями $p(f_1=1 | y=1) = 0.8$, $p(f_2=1 | y=1) = 0.6$, $p(f_1=1 | y=0) = 0.3$, $p(f_2=1 | y=0) = 0.4$. Для нового объекта с $f_1(x) = 1, f_2(x) = 1$:

$$p(y=1) p(f_1=1 | y=1) p(f_2=1 | y=1) = 0.5 \cdot 0.8 \cdot 0.6 = 0.24,$$

$$p(y=0) p(f_1=1 | y=0) p(f_2=1 | y=0) = 0.5 \cdot 0.3 \cdot 0.4 = 0.06.$$

Так как $0.24 > 0.06$, наивный Байес выдаёт $a(x) = 1$ (можно нормировать: $p(y=1 | x) \approx 0.24 / (0.24 + 0.06) = 0.8$).

Замечание 5.3 (Почему «наивный»). Независимость признаков внутри класса почти никогда не выполняется точно (например, для коррелированных признаков вроде «число банок корма» и «вес» из примера 1.4 Лекции 1). Тем не менее классификатор часто работает хорошо: для $\arg \max_y$ важен не точный масштаб $p(x | y)$, а то, у какого класса он больше, и ошибки масштаба от нарушения независимости часто одинаково искажают оценки всех классов, не меняя $\arg \max$.

Утверждение 5.4 (Наивный Байес с бинарными признаками – это логистическая регрессия). Пусть $\mathcal{Y} = \{0, 1\}$, признаки бинарны, $f_j(x) \in \{0, 1\}$, и $\theta_{jk} = p(f_j=1 | y=k) \in (0, 1)$. Тогда апостериорная вероятность наивного Байеса имеет вид $p(y=1 | x) = \sigma(w^T f(x) + b)$ для некоторых $w \in \mathbb{R}^n, b \in \mathbb{R}$, где $f(x) = (f_1(x), \dots, f_n(x))$ – в точности модель логистической регрессии (определение 1.2 Лекции 3).

Доказательство. По формуле Байеса, $p(y=1 | x) = 1 / (1 + e^{-z}) = \sigma(z)$, где $z = \ln \frac{p(x|y=1)p(y=1)}{p(x|y=0)p(y=0)}$. Для каждого признака $p(f_j | y=k) = \theta_{jk}^{f_j} (1 - \theta_{jk})^{1-f_j}$, и

$$\ln \frac{p(f_j | y=1)}{p(f_j | y=0)} = f_j \ln \frac{\theta_{j1}}{\theta_{j0}} + (1 - f_j) \ln \frac{1 - \theta_{j1}}{1 - \theta_{j0}} = f_j \underbrace{\ln \frac{\theta_{j1}(1 - \theta_{j0})}{\theta_{j0}(1 - \theta_{j1})}}_{w_j} + \ln \frac{1 - \theta_{j1}}{1 - \theta_{j0}}.$$

Суммируя по j (условная независимость) и добавляя $\ln \frac{p(y=1)}{p(y=0)}$, получаем $z = \sum_j w_j f_j(x) + b = w^T f(x) + b$ с $b = \ln \frac{p(y=1)}{p(y=0)} + \sum_j \ln \frac{1 - \theta_{j1}}{1 - \theta_{j0}}$ – линейная функция признаков, что и требовалось. $\square$

Замечание 5.5. Тот же вывод (с более громоздкой алгеброй) работает для количественных признаков с гауссовской $p(f_j | y)$ при условии одинаковой дисперсии σ_j^2 для обоих классов – условие, аналогичное общей Σ в LDA ниже. Общая картина: логистическая регрессия – дискриминативная модель с линейной границей; наивный Байес и LDA – две разные генеративные модели, каждая из которых при определённых предположениях о $p(x | y)$ приводит к той же самой линейной по признакам форме $p(y | x) = \sigma(w^T x + b)$, но оценивает w, b по-другому.

6 Нормальный дискриминантный анализ

Смоделируем n -мерное распределение внутри класса как многомерное нормальное: $p(x | y=k) = \mathcal{N}(x; \mu_k, \Sigma_k)$, где

$$\mathcal{N}(x; \mu, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$$

(Σ_k – симметричная положительно определённая ковариационная матрица; определитель $|\Sigma_k|$ вычисляется, как в Лекции 1, где мы дифференцировали определитель). Параметры $\mu_k, \Sigma_k, p(y=k)$ оцениваются выборочными аналогами по объектам класса k .

Определение 6.1 (Квадратичный дискриминант (QDA)). С $\delta_k(x) = \ln p(y=k) + \ln p(x | y=k)$ (следствие 4.3),

$$\delta_k(x) = \ln p(y=k) - \frac{1}{2} \ln |\Sigma_k| - \frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k), \quad a(x) = \arg \max_k \delta_k(x).$$

При различных Σ_k граница $\{\delta_k(x) = \delta_j(x)\}$ – квадратичная поверхность (эллипс, парабола или гипербола при $n = 2$).

Теорема 6.2 (LDA: общая ковариация даёт линейную границу). Если $\Sigma_k = \Sigma$ одна и та же для всех классов, то для любых j, k разность $\delta_k(x) - \delta_j(x)$ – линейная функция x .

Доказательство. $(x - \mu_k)^T \Sigma^{-1}(x - \mu_k) = x^T \Sigma^{-1}x - 2\mu_k^T \Sigma^{-1}x + \mu_k^T \Sigma^{-1}\mu_k$. Слагаемые $-\frac{1}{2} \ln |\Sigma|$ и $-\frac{1}{2}x^T \Sigma^{-1}x$ не зависят от k (общая Σ) и сокращаются при вычитании:

$$\delta_k(x) - \delta_j(x) = \ln \frac{p(y=k)}{p(y=j)} + (\mu_k - \mu_j)^T \Sigma^{-1}x - \frac{1}{2}\mu_k^T \Sigma^{-1}\mu_k + \frac{1}{2}\mu_j^T \Sigma^{-1}\mu_j,$$

линейная функция x с коэффициентом $w = \Sigma^{-1}(\mu_k - \mu_j)$. □




Рис. 2: Схематическая иллюстрация LDA: одинаковая форма (общая Σ) и ориентация эллипсов правдоподобия при разных центрах μ_0, μ_1 дают линейную границу (пунктир)

Замечание 6.3 (Сопоставление с Лекцией 3). Теорема 6.2 даёт классификатор вида $a(x) = \text{sign}(w^T x + b)$ из Лекции 3, но выведенный из другого принципа: там граница подбиралась дискриминативно (максимизацией отступа или минимизацией логистической потери), здесь – как следствие генеративной модели данных. Если предположение о нормальности $p(x | y)$ верно, LDA даёт более точную (при том же объеме выборки) оценку границы, чем логистическая регрессия; если неверно – может ей проигрывать, так как логистическая регрессия не предполагает ничего о $p(x | y)$.

Замечание 6.4 (Связь с метрическими методами). Метод окна Парзена (пример 1.2) можно переосмыслить байесовски: величина $\hat{p}(x | y) = \frac{1}{\ell_y h^n} \sum_{i: y_i = y} K(\rho(x, x_i)/h)$ (где ℓ_y – число обучающих объектов класса y) – это непараметрическая оценка плотности $p(x | y)$, не требующая предположений о её форме (в отличие от $\mathcal{N}(\mu_k, \Sigma_k)$ этого параграфа). Подставив $\hat{p}(x | y)$ в байесовское правило (следствие 4.3) вместо параметрической плотности, получаем классификатор, при подходящем ядре K в точности совпадающий с обобщённым метрическим классификатором (определение 1.1) – метрические и байесовские методы этой лекции не так уж независимы: первые можно рассматривать как байесовские методы с непараметрической, а вторые – с параметрической оценкой $p(x | y)$.

Заключение

Замечание 6.5. Вне рассмотрения остались: обучение метрики (metric learning) и проклятие размерности для метрических методов; восстановление плотности непараметрическими методами (аналог окна Парзена, применённый к оценке $p(x | y)$); регуляризованный дискриминантный анализ (промежуточный между LDA и QDA); связь наивного Байеса с текстовой классификацией. В следующей лекции – кластеризация и ЕМ-алгоритм, где класс объекта не наблюдается уже на обучающей выборке.

Машинное обучение

Лекция 7 — Кластеризация и ЕМ-алгоритм

Мотивация

Все методы Лекций 1–6 решали задачу обучения по прецедентам: в обучающей выборке $X^\ell = (x_i, y_i)_{i=1}^\ell$ каждому объекту сопоставлен ответ. В этой лекции – задачи обучения без учителя: дана лишь выборка объектов $X^\ell = (x_i)_{i=1}^\ell$, без ответов, и требуется найти в ней структуру. Начнём с простого и не вероятностного метода (K -средних), затем обобщим его до вероятностной модели (смесь распределений, ЕМ-алгоритм) и увидим, что первый – предельный случай второго. Завершим темой, устроенной совсем иначе (иерархическая кластеризация).

1 Метод K -средних

Определение 1.1 (Функционал качества кластеризации). Пусть $X^\ell \subset \mathbb{R}^n$, число кластеров K фиксировано. Для разбиения, заданного отображением $c : \{1, \dots, \ell\} \rightarrow \{1, \dots, K\}$ и центров $\mu_1, \dots, \mu_K \in \mathbb{R}^n$,

$$J(c, \mu) = \sum_{i=1}^{\ell} \|x_i - \mu_{c(i)}\|^2.$$

Метод K -средних ищет $(c^*, \mu^*) = \arg \min_{c, \mu} J(c, \mu)$.

Совместная минимизация по c (дискретной) и μ не сводится к градиентным методам Лекции 2 напрямую; используется покоординатный спуск.

Algorithm 1 K -средних (алгоритм Ллойда)

- 1: инициализировать $\mu_1, \dots, \mu_K$ (например, K случайных объектов выборки)
- 2: repeat
- 3: отнесение: $c(i) \leftarrow \arg \min_k \|x_i - \mu_k\|^2$ для каждого i
- 4: пересчёт: $\mu_k \leftarrow \frac{1}{|\{i: c(i)=k\}|} \sum_{i: c(i)=k} x_i$ для каждого k
- 5: until разбиение c не меняется

Утверждение 1.2 (Монотонность алгоритма Ллойда). Каждый из двух шагов алгоритма не увеличивает $J(c, \mu)$.

Доказательство. Отнесение. При фиксированных μ , $J = \sum_i \|x_i - \mu_{c(i)}\|^2$ – сумма независимых по i слагаемых, каждое минимизируется новым $c(i) = \arg \min_k \|x_i - \mu_k\|^2$.

Пересчёт. При фиксированном c , $J = \sum_k \sum_{i: c(i)=k} \|x_i - \mu_k\|^2$ распадается по кластерам; для каждого k приравниваем градиент по μ_k нулю. По формуле градиента квадратичной формы (предложение 6.2 Лекции 1, применённой к $w = x_i - \mu_k$ с единичной матрицей), каждое слагаемое даёт $\nabla_{\mu_k} \|x_i - \mu_k\|^2 = -2(x_i - \mu_k)$, так что $\sum_{i: c(i)=k} (-2)(x_i - \mu_k) = 0 \Rightarrow \mu_k = \frac{1}{|\{i: c(i)=k\}|} \sum_{i: c(i)=k} x_i$ – новое значение μ_k ; вторая производная $2|\{i : c(i) = k\}| > 0$, минимум. $\square$

Замечание 1.3. Разбиений с конечное число ($\leq K^\ell$), а J не возрастает и не может принимать одно и то же значение на разных разбиениях бесконечно долго без заикливания – при конечном числе разбиений это невозможно, значит алгоритм сходится за конечное число шагов, но лишь к локальному минимуму J , зависящему от инициализации. На практике запускают несколько раз с разных случайных $\mu^{(0)}$ и выбирают разбиение с наименьшим J . Число кластеров K – гиперпараметр: $J(c^*, \mu^*)$ монотонно убывает по K (при $K = \ell$ равно нулю), поэтому минимизировать J по K бессмысленно (в духе переобучения, Лекция 4); используют эвристики вроде «метода локтя».

Замечание 1.4 (Вычислительная сложность). Одна итерация K -средних требует $O(K\ell n)$ действий (расстояние от каждого из ℓ объектов до каждого из K центров в $\mathbb{R}^n$), и на практике сходимость наступает за небольшое число итераций – почти линейная зависимость от ℓ . Наивная реализация агломеративной кластеризации (§3) заново ищет пару ближайших кластеров на каждом из $\ell - 1$ шагов слияния среди $O(\ell^2)$ пар, то есть $O(\ell^3)$ суммарно (с очередью с приоритетами – $O(\ell^2 \log \ell)$); при больших ℓ это заметно дороже K -средних, что на практике часто перевешивает удобство не фиксировать K заранее.

Пример 1.5 (K -средних вручную). Четыре точки $p_1 = (1, 1)$, $p_2 = (2, 1)$, $p_3 = (4, 3)$, $p_4 = (5, 3)$, $K = 2$, начальные центры $\mu_1^{(0)} = (1, 1)$, $\mu_2^{(0)} = (5, 3)$.

Отнесение: $\rho(p_1, \mu_1) = 0 < \rho(p_1, \mu_2) = \sqrt{20} - p_1 \rightarrow 1$; аналогично $\rho(p_2, \mu_1) = 1 < \rho(p_2, \mu_2) = \sqrt{13} - p_2 \rightarrow 1$; $\rho(p_3, \mu_2) = 1 < \rho(p_3, \mu_1) = \sqrt{13} - p_3 \rightarrow 2$; $\rho(p_4, \mu_2) = 0 - p_4 \rightarrow 2$. Кластеры: $\{p_1, p_2\}$ и $\{p_3, p_4\}$.

Пересчёт: $\mu_1^{(1)} = \frac{1}{2}(p_1 + p_2) = (1.5, 1)$, $\mu_2^{(1)} = \frac{1}{2}(p_3 + p_4) = (4.5, 3)$.

Проверка следующего отнесения с новыми центрами не меняет разбиение (легко проверить: p_1, p_2 по-прежнему ближе к $\mu_1^{(1)}$, p_3, p_4 – к $\mu_2^{(1)}$) – алгоритм сошёлся за одну итерацию.




Рис. 1: Пример 1.5: два кластера и их центры после одной итерации

2 Смеси распределений и ЕМ-алгоритм

Метод K -средних жёстко относит каждый объект к одному кластеру. Обобщим его вероятностно: пусть данные порождены смесью K распределений, и объект может принадлежать компоненте с некоторой вероятностью, а не однозначно.

|

Определение 2.1 (Смесь распределений).

$$p(x; \Theta) = \sum_{k=1}^K \pi_k p(x; \theta_k), \quad \pi_k \geq 0, \quad \sum_{k=1}^K \pi_k = 1,$$

$\Theta = (\pi_1, \dots, \pi_K, \theta_1, \dots, \theta_K)$, π_k – веса компонент.

Вводя латентную переменную $z \in \{1, \dots, K\}$ ($p(z=k) = \pi_k$, $p(x | z=k) = p(x; \theta_k)$), по выборке $x_1, \dots, x_\ell$ (значения z_i не наблюдаются) требуется оценить Θ методом максимума правдоподобия (Лекция 1):

$$\ell(\Theta) = \sum_{i=1}^{\ell} \ln \left(\sum_{k=1}^K \pi_k p(x_i; \theta_k) \right).$$

Логарифм суммы не позволяет, как в Лекции 1, свести $\arg \max_{\Theta} \ell(\Theta)$ к раздельной оптимизации.

Практический приём: неравенство Йенсена. Для вогнутой φ (в частности, $\varphi = \ln$) и распределения $q(z)$, $z = 1, \dots, K$: $\varphi(\sum_z q(z)\xi(z)) \geq \sum_z q(z)\varphi(\xi(z))$, с равенством тогда и только тогда, когда $\xi(z)$ не зависит от z (на носителе q).

Для произвольного распределения $q_i(z)$ (своего для каждого x_i),

$$\ln p(x_i; \Theta) = \ln \sum_z q_i(z) \frac{\pi_z p(x_i; \theta_z)}{q_i(z)} \geq \sum_z q_i(z) \ln \frac{\pi_z p(x_i; \theta_z)}{q_i(z)} =: J_i(\Theta, q_i).$$

Обозначим $J(\Theta, q) = \sum_i J_i(\Theta, q_i)$ – нижняя оценка на $\ell(\Theta)$ для любого $q = (q_1, \dots, q_\ell)$.

Утверждение 2.2 (Точность оценки). Если $q_i(z) = p(z | x_i; \Theta)$, то $J(\Theta, q) = \ell(\Theta)$.

Доказательство. $p(z | x_i; \Theta) = \pi_z p(x_i; \theta_z) / p(x_i; \Theta)$, так что $\pi_z p(x_i; \theta_z) / q_i(z) = p(x_i; \Theta)$ не зависит от z . Тогда $J_i(\Theta, q_i) = \ln p(x_i; \Theta) \sum_z q_i(z) = \ln p(x_i; \Theta)$, и $J(\Theta, q) = \sum_i \ln p(x_i; \Theta) = \ell(\Theta)$. $\square$

Определение 2.3 (ЕМ-алгоритм). Начиная с произвольного $\Theta^{(0)}$, повторяются шаги: Е-шаг: $q_i^{(t)}(z) = p(z | x_i; \Theta^{(t)})$ для каждого i ; М-шаг: $\Theta^{(t+1)} = \arg \max_{\Theta} J(\Theta, q^{(t)})$.

Теорема 2.4 (Монотонность ЕМ). $\ell(\Theta^{(t+1)}) \geq \ell(\Theta^{(t)})$ для каждого t .

Доказательство. По предложению 2.2, $\ell(\Theta^{(t)}) = J(\Theta^{(t)}, q^{(t)})$. М-шаг максимизирует $J(\cdot, q^{(t)})$, а $\Theta^{(t)}$ – допустимый кандидат, поэтому $J(\Theta^{(t+1)}, q^{(t)}) \geq J(\Theta^{(t)}, q^{(t)})$. Неравенство Йенсена (для любого q) даёт $\ell(\Theta^{(t+1)}) \geq J(\Theta^{(t+1)}, q^{(t)})$. Собирая цепочку, $\ell(\Theta^{(t+1)}) \geq J(\Theta^{(t+1)}, q^{(t)}) \geq J(\Theta^{(t)}, q^{(t)}) = \ell(\Theta^{(t)})$. $\square$

Замечание 2.5 (Связь с K -средних). ЕМ для смеси K нормальных распределений с общей ковариацией $\Sigma_k = \sigma^2 I$ (одинаковой для всех компонент, $\sigma^2 \rightarrow 0$) и равными весами $\pi_k = 1/K$ вырождается в метод K -средних: апостериорная вероятность $\gamma_{ik} = p(z_i=k | x_i; \Theta)$ (см. ниже) стремится к 0 или 1 – «мягкое» отнесение (ЕМ) переходит в жёсткое (шаг отнесения K -средних), а обновление среднего компоненты переходит в шаг пересчёта центра. K -средних, изученный в §1 первым, исторически и методически – частный (упрощённый) случай ЕМ, разобранный здесь во всей общности.

Определение 2.6 (Ответственность). $\gamma_{ik} = p(z_i=k \mid x_i; \Theta) = \frac{\pi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i; \mu_j, \Sigma_j)}$ (плотность $\mathcal{N}$ – как в Лекции 6).

Пример 2.7 (Ответственность вручную). Пусть $n = 1$, $K = 2$, $\pi_1 = \pi_2 = 0.5$, $\mu_1 = 0, \sigma_1^2 = 1$; $\mu_2 = 3, \sigma_2^2 = 1$ (общий вид одномерной плотности – $\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}$). Для объекта $x = 1$:

$$\mathcal{N}(1; 0, 1) = \frac{1}{\sqrt{2\pi}} e^{-1/2} \approx 0.242, \quad \mathcal{N}(1; 3, 1) = \frac{1}{\sqrt{2\pi}} e^{-2} \approx 0.054.$$

$$\gamma_1 = \frac{0.5 \cdot 0.242}{0.5 \cdot 0.242 + 0.5 \cdot 0.054} \approx 0.82, \quad \gamma_2 \approx 0.18.$$

Объект $x = 1$ гораздо ближе к первой компоненте ($\mu_1 = 0$), чем ко второй ($\mu_2 = 3$), и ответственность $\gamma_1 \approx 0.82$ отражает это – в отличие от K -средних, где объект был бы отнесён к первому кластеру целиком ($\gamma_1 = 1$), здесь он «немного» (на 18%) учитывается и при обновлении параметров второй компоненты.

М-шаг максимизирует $J(\Theta, q^{(t)}) = \sum_i \sum_k \gamma_{ik} [\ln \pi_k + \ln \mathcal{N}(x_i; \mu_k, \Sigma_k)]$ (с точностью до слагаемого, не зависящего от Θ).

Утверждение 2.8 (Формулы М-шага).

$$\mu_k = \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}, \quad \pi_k = \frac{1}{\ell} \sum_i \gamma_{ik}, \quad \Sigma_k = \frac{\sum_i \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^\top}{\sum_i \gamma_{ik}}.$$

Доказательство. Для μ_k : слагаемые J , зависящие от μ_k , – это $-\frac{1}{2} \sum_i \gamma_{ik} (x_i - \mu_k)^\top \Sigma_k^{-1} (x_i - \mu_k)$. По формуле градиента квадратичной формы (предложение 6.2 Лекции 1, $w = x_i - \mu_k$), $\nabla_{\mu_k} (x_i - \mu_k)^\top \Sigma_k^{-1} (x_i - \mu_k) = -2 \Sigma_k^{-1} (x_i - \mu_k)$; приравнявая сумму нулю и решая относительно μ_k , получаем формулу.

Для π_k : максимизируем $\sum_i \sum_k \gamma_{ik} \ln \pi_k$ при $\sum_k \pi_k = 1$ (множители Лагранжа, Лекция 3): $\partial/\partial \pi_k (\sum_i \gamma_{ik} \ln \pi_k - \lambda (\sum_k \pi_k - 1)) = \sum_i \gamma_{ik} / \pi_k - \lambda = 0$, откуда $\pi_k = \sum_i \gamma_{ik} / \lambda$; суммируя по k и используя $\sum_k \gamma_{ik} = 1$, получаем $\lambda = \ell$.

Общая формула для Σ_k требует дифференцирования по матрице ($\nabla_{\Sigma} \ln |\Sigma|$, связанного с градиентом определителя из Лекции 1, и производной обратной матрицы) – выходит за рамки построенного аппарата, приводим её без вывода. Разберём вместо этого частный, но распространённый случай сферической компоненты, $\Sigma_k = v_k I$ ($v_k = \sigma_k^2 > 0$ – скаляр), где вычисление сводится к обычной производной по числу v_k . Тогда $\ln |\Sigma_k| = n \ln v_k$, $(x_i - \mu_k)^\top \Sigma_k^{-1} (x_i - \mu_k) = \|x_i - \mu_k\|^2 / v_k$, и слагаемые J , зависящие от v_k , равны $\sum_i \gamma_{ik} [-\frac{n}{2} \ln v_k - \frac{1}{2v_k} \|x_i - \mu_k\|^2]$. Дифференцируя по v_k и приравнявая нулю:

$$\sum_i \gamma_{ik} \left(-\frac{n}{2v_k} + \frac{\|x_i - \mu_k\|^2}{2v_k^2} \right) = 0 \implies v_k = \frac{\sum_i \gamma_{ik} \|x_i - \mu_k\|^2}{n \sum_i \gamma_{ik}}$$

(умножили на $2v_k^2 > 0$ и разрешили относительно v_k) – взвешенная средняя квадратичная невязка, полностью аналогичная общей формуле для Σ_k выше, но без матричного дифференцирования. $\square$

3 Иерархическая кластеризация

K -средних и ЕМ требуют заранее знать K и дают одно разбиение. Агломеративная иерархическая кластеризация строит вложенную последовательность разбиений от ℓ кластеров до одного, не фиксируя K .

Определение 3.1 (Расстояние между кластерами (linkage)).

$$d_{\min}(C, C') = \min_{x \in C, x' \in C'} \rho(x, x') \text{ (одиночная)}, \quad d_{\max}(C, C') = \max_{x \in C, x' \in C'} \rho(x, x') \text{ (полная)},$$

$$d_{\text{avg}}(C, C') = \frac{1}{|C||C'|} \sum_{x \in C} \sum_{x' \in C'} \rho(x, x') \text{ (средняя)}.$$

Algorithm 2 Агломеративная кластеризация

- 1: $\mathcal{C} \leftarrow \{\{x_1\}, \dots, \{x_\ell\}\}$
 - 2: while $|\mathcal{C}| > 1$ do
 - 3: найти $C, C' \in \mathcal{C}$ с наименьшим $d(C, C')$; заменить их на $C \cup C'$; запомнить высоту слияния $d(C, C')$
 - 4: end while
-

Результат – дендрограмма; разбиение на K кластеров – «срез» дендрограммы на подходящей высоте.

Пример 3.2 (Одиночная связь вручную). Четыре точки на прямой: $a = 0, b = 1, c = 3, d = 7$ (одномерный признак, метрика – модуль разности). Попарные расстояния: $\rho(a, b) = 1, \rho(a, c) = 3, \rho(a, d) = 7, \rho(b, c) = 2, \rho(b, d) = 6, \rho(c, d) = 4$.

Шаг 1. Наименьшее расстояние – $\rho(a, b) = 1$: объединяем в $\{a, b\}$.

Шаг 2. Расстояние одиночной связи от $\{a, b\}$ до c – это $\min(\rho(a, c), \rho(b, c)) = \min(3, 2) = 2$; до d – $\min(7, 6) = 6$; расстояние $\rho(c, d) = 4$ не изменилось. Наименьшее теперь – 2: объединяем c с $\{a, b\}$, получаем $\{a, b, c\}$.

Шаг 3. Расстояние от $\{a, b, c\}$ до d – $\min(7, 6, 4) = 4$. Единственный оставшийся кластер $\{a, b, c, d\}$ образуется на высоте 4.

Высоты слияний $1 < 2 < 4$ монотонно возрастают – это общее свойство дендрограмм одиночной связи (расстояние от объединения до любого другого кластера не меньше расстояния, на котором произошло само объединение).




Рис. 2: Схематическая дендрограмма для пяти объектов

Замечание 3.3. Одиночная связь склонна к «эффекту цепочки»; полная – чувствительна к выбросам; средняя – компромисс. В отличие от K -средних и ЕМ, агломеративная кластеризация детерминирована (нет случайной инициализации), но результат сильнее зависит от выбора метрики и linkage-функции.

Заключение

Замечание 3.4 (Информационные критерии). Число компонент K смеси можно выбирать не только скользящим контролем (Лекция 4), но и информационными критериями, штрафующими правдоподобие числом параметров без разбиения выборки: например, байесовский информационный критерий (BIC) выбирает $K = \arg \min_K (-2 \ln L(\hat{\Theta}_K, X^\ell) +$

$p_K \ln \ell$), где p_K – число свободных параметров модели с K компонентами. Это снова принцип структурной минимизации риска (определение 5.1 Лекции 4): штраф $p_K \ln \ell$ играет роль $\text{penalty}(\text{VCdim}, \ell)$ там, но получен из другой (асимптотической байесовской) теории, а не из VC-размерности.

Замечание 3.5. Вне рассмотрения остались: методы кластеризации по плотности (DBSCAN), находящие кластеры произвольной формы через связность областей высокой плотности, а не через расстояние до центра; скорость сходимости ЕМ; формальная связь с вариационным выводом (тот же приём с нижней оценкой $J(\Theta, q)$ работает не только для смесей, а для широкого класса байесовских моделей со скрытыми переменными). В следующей, последней лекции курса – метод главных компонент, снижающий размерность признакового пространства и, в отличие от всех методов Лекций 1–7, вовсе не использующий понятие обучающего сигнала (ни ответов y_i , ни скрытых переменных z_i).

Машинное обучение

Лекция 8 — Метод главных компонент и сингулярное разложение

Мотивация

Метрические методы (Лекция 6) страдают от «проклятия размерности» при большом числе признаков n ; визуализировать выборку с $n > 3$ напрямую невозможно; наконец, признаки часто избыточны или коллинеарны (Лекция 2) – несколько исходных признаков фактически измеряют одно и то же. Метод главных компонент (РСА) решает эти проблемы одним и тем же способом: строит новые признаки – линейные комбинации исходных, – в определённом смысле наилучшим образом сохраняющие структуру данных при уменьшении их числа. Как и кластеризация (Лекция 7), РСА не использует ответы y_i – это метод понижения размерности признакового пространства $\mathcal{X}$, последний в курсе.

1 Постановка: максимизация дисперсии проекции

Пусть выборка $x_1, \dots, x_\ell \in \mathbb{R}^n$ центрирована, $\frac{1}{\ell} \sum_i x_i = 0$ (иначе вычитаем выборочное среднее). Матрица $X \in \mathbb{R}^{\ell \times n}$ составлена из $x_i^\top$ по строкам (без столбца единиц – свободный член не нужен, данные уже центрированы).

Определение 1.1 (Выборочная ковариационная матрица).

$$C = \frac{1}{\ell} \sum_{i=1}^{\ell} x_i x_i^\top = \frac{1}{\ell} X^\top X \in \mathbb{R}^{n \times n}.$$

C симметрична и положительно полуопределена (матрица Грама $X^\top X$ из Лекции 2, с точностью до $1/\ell$). Для единичного w ($\|w\| = 1$) проекция x_i на направление w равна $x_i^\top w$; выборка центрирована, поэтому среднее проекций равно нулю, а их дисперсия

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (x_i^\top w)^2 = \frac{1}{\ell} w^\top X^\top X w = w^\top C w.$$

Первая главная компонента – направление w , вдоль которого эта дисперсия максимальна.

Практический приём: стандартизация признаков. Дисперсия $w^\top C w$ зависит от единиц измерения: признак, измеренный в миллиметрах, имеет в 10^6 раз большую дисперсию, чем тот же признак в километрах. Если признаки $x^{(1)}, \dots, x^{(n)}$ имеют разную природу (например, рост в метрах и доход в рублях), РСА без предобработки попросту найдёт направление, совпадающее с признаком наибольшего масштаба – это артефакт единиц измерения, а не структуры данных. Поэтому перед РСА каждый признак принято стандартизировать: $x^{(j)} \mapsto (x^{(j)} - \bar{x}^{(j)})/s_j$, где s_j – выборочное стандартное отклонение признака j . После этого C – матрица корреляций, а не ковариаций, и все признаки входят в задачу на равных.

2 Вывод через собственные векторы

Теорема 2.1 (Первая главная компонента). $\arg \max_{\|w\|=1} w^T C w$ – собственный вектор C , отвечающий наибольшему собственному числу $\lambda_{\max}$, а максимум дисперсии равен $\lambda_{\max}$.

Доказательство. Максимизируем $w^T C w$ при $w^T w = 1$ (множители Лагранжа, Лекция 3): $L(w, \lambda) = w^T C w - \lambda(w^T w - 1)$. По формуле градиента квадратичной формы (предложение 6.2 Лекции 1, C симметрична), $\nabla_w L = 2Cw - 2\lambda w = 0$, откуда $Cw = \lambda w$ – w обязано быть собственным вектором C . В стационарной точке $w^T C w = \lambda \|w\|^2 = \lambda$; максимум среди всех собственных чисел – $\lambda_{\max}$. $\square$

Замечание 2.2 (Следующие компоненты). C симметрична, поэтому обладает ортонормированным базисом собственных векторов $w_1, \dots, w_n$ с $\lambda_1 \geq \dots \geq \lambda_n \geq 0$. Аналогично теореме 2.1 (максимизация $w^T C w$ при ортогональности уже выбранным $w_1, \dots, w_{m-1}$) показывается, что m -я главная компонента – это w_m . Проекция на первые k компонент, $x \mapsto (x^T w_1, \dots, x^T w_k) \in \mathbb{R}^k$, – понижение размерности с n до k .

Утверждение 2.3 (Некоррелированность главных компонент). Пусть $z^{(i)} = x^T w_i$, $z^{(j)} = x^T w_j$ – i -я и j -я главные компоненты, $i \neq j$. Тогда их выборочная ковариация равна нулю.

Доказательство. Так как обе центрированы (среднее проекции центрированных данных равно нулю), ковариация равна $\frac{1}{\ell} \sum_m z_m^{(i)} z_m^{(j)} = \frac{1}{\ell} \sum_m (x_m^T w_i)(x_m^T w_j) = w_i^T C w_j = w_i^T (\lambda_j w_j) = \lambda_j (w_i^T w_j) = 0$, так как w_i, w_j ортогональны. $\square$

Практический приём: отбеливание (whitening). Преобразование $z = \Lambda^{-1/2} W^T x$ (используются все n компонент, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$) даёт данные с единичной ковариационной матрицей: $\text{Cov}(z) = \Lambda^{-1/2} W^T C W \Lambda^{-1/2} = \Lambda^{-1/2} \Lambda \Lambda^{-1/2} = I$ (используем $C = W \Lambda W^T$ и ортогональность W). По предложению 2.3 компоненты уже некоррелированы; деление на $\sqrt{\lambda_j}$ дополнительно уравнивает их дисперсии. Отбеливание – стандартная предобработка перед градиентными методами: в Лекции 2 обсуждалось, что скорость сходимости градиентного спуска зависит от числа обусловленности $\lambda_{\max}/\lambda_{\min}$ матрицы вторых производных (зигзагообразная траектория на вытянутых эллипсах); после отбеливания это число обусловленности равно 1, и зигзаг исчезает.

Утверждение 2.4 (Эквивалентность: минимизация ошибки восстановления). Направление w ($\|w\| = 1$), максимизирующее $\sum_i (x_i^T w)^2$, одновременно минимизирует $\sum_i \|x_i - (x_i^T w)w\|^2$.

Доказательство. $\hat{x}_i = (x_i^T w)w$ – проекция x_i на $\text{span}(w)$; $(x_i - \hat{x}_i)^T \hat{x}_i = (x_i^T w)(x_i^T w - (x_i^T w)\|w\|^2) = 0$. По теореме Пифагора и суммированию по i , $\sum_i \|x_i\|^2 = \sum_i (x_i^T w)^2 + \sum_i \|x_i - \hat{x}_i\|^2$; левая часть от w не зависит, значит максимизация первого слагаемого справа равносильна минимизации второго. $\square$

2.1 Доля объяснённой дисперсии и выбор числа компонент

Утверждение 2.5 (Полная дисперсия). $\sum_{j=1}^n \lambda_j = \text{tr } C = \frac{1}{\ell} \sum_{i=1}^{\ell} \|x_i\|^2$ – сумма дисперсий всех n исходных признаков.

Доказательство. След инвариантен относительно ортогонального сопряжения: $C = W \Lambda W^T$ с ортогональной W , значит $\text{tr } C = \text{tr}(W \Lambda W^T) = \text{tr}(\Lambda W^T W) = \text{tr } \Lambda = \sum_j \lambda_j$ (циклическое свойство следа). С другой стороны, по определению $\text{tr } C = \frac{1}{\ell} \text{tr}(X^T X) = \frac{1}{\ell} \sum_i \text{tr}(x_i x_i^T) = \frac{1}{\ell} \sum_i \|x_i\|^2$. $\square$

Практический приём: доля объяснённой дисперсии. Величина $\lambda_1 / \sum_j \lambda_j$ – доля дисперсии, сохранённая первой компонентой; аналогично для первых k компонент – $(\lambda_1 + \dots + \lambda_k) / \sum_j \lambda_j$. На практике число компонент k выбирают наименьшим, при котором эта доля превышает порог (например, 0.9 или 0.95) – тот же принцип, что и скользящий контроль (Лекция 4): находим наименьшую модель, объясняющую «почти всё». Для примера 3.1 $\text{tr } C = 2.5 + 2.5 = 5 = \lambda_1 + \lambda_2$ (сходится с предложением 2.5), первая компонента объясняет $4.5/5 = 90\%$ дисперсии – уже одной координаты $x^\top w_1$ достаточно для хорошего приближения.

Algorithm 1 Метод главных компонент (PCA)

```

1: procedure PCA( $x_1, \dots, x_\ell$ , число компонент  $k$ )
2:    $\bar{x} \leftarrow \frac{1}{\ell} \sum_i x_i$ ;  $x_i \leftarrow x_i - \bar{x}$  для всех  $i$  ▷ центрирование
3:    $C \leftarrow \frac{1}{\ell} \sum_i x_i x_i^\top$ 
4:   найти собственные пары  $(\lambda_j, w_j)$  матрицы  $C$ , отсортировать по убыванию  $\lambda_j$ 
5:   return  $\{w_1, \dots, w_k\}$  и проекции  $z_i = (x_i^\top w_1, \dots, x_i^\top w_k)$ 
6: end procedure
  
```

3 Численный пример

Пример 3.1. Четыре центрированных точки в $\mathbb{R}^2$: $x_1 = (2, 1)$, $x_2 = (-1, -2)$, $x_3 = (1, 2)$, $x_4 = (-2, -1)$ (сумма – нулевой вектор). Вычисляем

$$C = \frac{1}{4} \sum_i x_i x_i^\top = \frac{1}{4} \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix} = \begin{pmatrix} 2.5 & 2 \\ 2 & 2.5 \end{pmatrix}.$$

Характеристическое уравнение: $\lambda^2 - 5\lambda + 2.25 = 0$ (след 5, определитель $6.25 - 4 = 2.25$), корни $\lambda = (5 \pm 4)/2 \in \{4.5, 0.5\}$. Для $\lambda = 4.5$: $(C - 4.5I)w = 0 \Rightarrow -2w_1 + 2w_2 = 0 \Rightarrow w_1 = w_2$, единичный вектор $w_1 = (1/\sqrt{2}, 1/\sqrt{2})$. Для $\lambda = 0.5$: $2w_1 + 2w_2 = 0 \Rightarrow w_1 = -w_2$, вектор $w_2 = (1/\sqrt{2}, -1/\sqrt{2})$. Первая главная компонента – направление $(1, 1)/\sqrt{2}$ (вдоль диагонали, где четыре точки различаются сильнее всего), вторая – $(1, -1)/\sqrt{2}$.




Рис. 1: Пример 3.1: точки и главные направления w_1 (наибольшая дисперсия), w_2 (наименьшая, ортогональна w_1)

Пример 3.2 (Проекция на первую компоненту). Понижаем размерность с 2 до 1, проецируя на $w_1 = (1, 1)/\sqrt{2}$: $z_i = x_i^\top w_1$. Для $x_1 = (2, 1)$: $z_1 = (2 + 1)/\sqrt{2} = 3/\sqrt{2} \approx 2.12$;

аналогично $z_2 = -3/\sqrt{2}$, $z_3 = 3/\sqrt{2}$, $z_4 = -3/\sqrt{2}$ (x_1, x_3 и x_2, x_4 дают одинаковую проекцию – они различаются только вдоль «слабого» направления w_2). Восстановление $\hat{x}_1 = z_1 w_1 = (3/\sqrt{2})(1/\sqrt{2}, 1/\sqrt{2}) = (1.5, 1.5)$; ошибка $\|x_1 - \hat{x}_1\|^2 = (2 - 1.5)^2 + (1 - 1.5)^2 = 0.5$. По предложению 2.4 суммарная ошибка по всем четырём точкам равна $\lambda_2 \cdot \ell = 0.5 \cdot 4 = 2$ (несохранённая дисперсия вдоль w_2) – проверка: по симметрии все четыре слагаемых равны 0.5, сумма $4 \cdot 0.5 = 2$, совпадает.

4 Сингулярное разложение: вывод через РСА

Теорема 2.1 даёт способ явно построить сингулярное разложение матрицы X , используя только собственные векторы C – инструмент, который мы уже вывели.

Теорема 4.1 (Сингулярное разложение). Пусть $w_1, \dots, w_n$ – ортонормированный базис собственных векторов C с собственными числами $\lambda_1 \geq \dots \geq \lambda_n \geq 0$, все $\lambda_j > 0$ (столбцы X линейно независимы). Положим $\sigma_j = \sqrt{\ell \lambda_j}$ и $u_j = X w_j / \sigma_j \in \mathbb{R}^\ell$. Тогда $u_1, \dots, u_n$ ортонормированы, и

$$X = \sum_{j=1}^n \sigma_j u_j w_j^\top.$$

Доказательство. Так как $X^\top X = \ell C$ и $C w_j = \lambda_j w_j$, верно $X^\top X w_j = \ell \lambda_j w_j = \sigma_j^2 w_j$. Тогда для любых i, j

$$u_i^\top u_j = \frac{(X w_i)^\top (X w_j)}{\sigma_i \sigma_j} = \frac{w_i^\top X^\top X w_j}{\sigma_i \sigma_j} = \frac{w_i^\top (\sigma_j^2 w_j)}{\sigma_i \sigma_j} = \frac{\sigma_j}{\sigma_i} w_i^\top w_j.$$

При $i = j$ это даёт $u_j^\top u_j = 1$; при $i \neq j$ – $w_i^\top w_j = 0$ (ортонормированность w), значит $u_i^\top u_j = 0$ – $u_1, \dots, u_n$ ортонормированы. Далее, оба линейных отображения X и $\sum_j \sigma_j u_j w_j^\top$ (из $\mathbb{R}^n$ в $\mathbb{R}^\ell$) совпадают на базисе $w_1, \dots, w_n$: применяя второе к w_k , $\sum_j \sigma_j u_j (w_j^\top w_k) = \sigma_k u_k = \sigma_k \cdot X w_k / \sigma_k = X w_k$ – совпадает с $X w_k$. Совпадая на базисе, отображения совпадают всюду, то есть равны как матрицы. $\square$

Замечание 4.2. В матричной форме $X = U \Sigma W^\top$, где $U \in \mathbb{R}^{\ell \times n}$ – матрица со столбцами u_j , $W \in \mathbb{R}^{n \times n}$ – со столбцами w_j (ортогональна), $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$. Величины σ_j называются сингулярными числами X , а u_j, w_j – левыми и правыми сингулярными векторами. На практике главные компоненты вычисляют через SVD матрицы X напрямую, не составляя $C = X^\top X / \ell$ явно (это устойчивее численно: вычисление $X^\top X$ возводит числа обусловленности в квадрат).

Пример 4.3 (Продолжение примера 3.1). Для той же выборки $\sigma_1 = \sqrt{4 \cdot 4.5} = \sqrt{18} = 3\sqrt{2}$, $\sigma_2 = \sqrt{4 \cdot 0.5} = \sqrt{2}$. Вычисляем $u_1 = X w_1 / \sigma_1$: скалярные произведения строк X с $w_1 = (1, 1) / \sqrt{2}$ дают $(3/\sqrt{2}, -3/\sqrt{2}, 3/\sqrt{2}, -3/\sqrt{2})^\top$, делим на $\sigma_1 = 3\sqrt{2}$: $u_1 = (1/2, -1/2, 1/2, -1/2)^\top$. Аналогично $u_2 = X w_2 / \sigma_2 = (1/2, 1/2, -1/2, -1/2)^\top$. Проверка: $u_1^\top u_2 = \frac{1}{4} - \frac{1}{4} - \frac{1}{4} + \frac{1}{4} = 0$ – ортогональны, как и предсказывает теорема 4.1.

Замечание 4.4 (Малоранговое приближение). Отбрасывая слагаемые с $j > k$ в разложении теоремы 4.1, получаем $X_k = \sum_{j=1}^k \sigma_j u_j w_j^\top$ – матрицу ранга k . Известный факт (теорема Эккарта–Юнга, приводим без доказательства) состоит в том, что X_k – наилучшее приближение X матрицей ранга k по норме Фробениуса; это в точности РСА-проекция на первые k компонент, записанная в матричной форме. Для нашего примера ранг-1 приближение $X_1 = \sigma_1 u_1 w_1^\top$: первая строка $\sigma_1 u_1^{(1)} w_1 = (3\sqrt{2})(0.5)(1/\sqrt{2}, 1/\sqrt{2}) = (1.5, 1.5)$ – совпадает с восстановлением $\hat{x}_1$ из примера выше, как и должно быть.

Замечание 4.5 (Связь с нормальными уравнениями МНК). Теорема 4.1 даёт другой способ решать задачу наименьших квадратов из Лекции 1. Пусть $X = U\Sigma W^T$ – разложение из теоремы 4.1 (X полного столбцового ранга, U имеет ортонормированные столбцы, $U^T U = I$). Тогда $X^T X = W\Sigma U^T U \Sigma W^T = W\Sigma^2 W^T$, откуда $(X^T X)^{-1} = W\Sigma^{-2} W^T$, и решение теоремы 8.1 Лекции 1 переписывается как

$$\theta^* = (X^T X)^{-1} X^T y = W\Sigma^{-2} W^T W\Sigma U^T y = W\Sigma^{-1} U^T y = X^+ y,$$

где $X^+ := W\Sigma^{-1} U^T$ – псевдообратная матрица X . Как и отмечалось выше, вычисление θ^* через SVD (без явного построения $X^T X$ и обращения) численно устойчивее прямой формулы нормальных уравнений.

5 Многомерное шкалирование

Если вместо координат x_i известны только попарные расстояния $\rho(x_i, x_j)$ (например, экспертные оценки несходства без явных признаков), задача – найти $\tilde{x}_1, \dots, \tilde{x}_\ell \in \mathbb{R}^k$, приближённо воспроизводящие эти расстояния, $\|\tilde{x}_i - \tilde{x}_j\| \approx \rho(x_i, x_j)$.

Замечание 5.1 (Классическое многомерное шкалирование). Если исходные x_i существуют и центрированы, а ρ – евклидово расстояние, матрица Грама $B = XX^T \in \mathbb{R}^{\ell \times \ell}$ восстанавливается по матрице попарных квадратов расстояний через «двойное центрирование» (не выводим формулу), а искомые координаты $\tilde{x}_i$ получаются из k старших собственных векторов B – то же вычисление, что и PCA, но применённое к $B = XX^T$ ($\ell \times \ell$) вместо $C = X^T X / \ell$ ($n \times n$); по теореме 4.1, у $XX^T = U\Sigma^2 U^T$ и $X^T X = \ell C = W(\ell\Lambda)W^T$ одни и те же ненулевые собственные числа $\sigma_j^2 = \ell\lambda_j$. При $k = 2$ или 3 это – стандартный способ визуализации многомерных данных.




Рис. 2: Идея многомерного шкалирования: ℓ объектов, заданных только попарными несходствами, размещаются в $\mathbb{R}^k$ ($k = 2$) так, чтобы евклидовы расстояния между образами приближали исходные $\rho(x_i, x_j)$

Заключение

Замечание 5.2. Курс завершается на методе главных компонент, но список тем не исчерпан: вне рассмотрения остались ядерный PCA (нелинейное обобщение через ядра Лекции 3), факторный анализ, t -SNE и другие методы нелинейного понижения размерности, а также нейросетевые методы, изначально исключённые из программы курса.

Пройденный материал – от постановки задачи (Лекция 1) до обучения без учителя (Лекции 7–8) – образует общую картину классического обучения по прецедентам:

Общая нить: постановка задачи и модель $\rightarrow$ функция потерь и принцип ERM $\rightarrow$ конкретные модели $\rightarrow$ контроль переобучения (СМР как формальная рамка, применённая на практике в скользящем контроле, стрижке деревьев, бэггинге) $\rightarrow$ задачи без учителя, где ответов y_i нет вовсе, а структура данных ищется через плотность (ЕМ), сходство (кластеризация) или дисперсию (PCA).

Лекция	Содержание
1	Постановка задачи, ERM, МНК как частный случай ERM/MLE
2	Градиентные методы, скорость сходимости, регуляризация
3	Логистическая регрессия, MAP, SVM и двойственность, ядра
4	Переобучение, смещение–разброс, VC-размерность, СМР
5	Решающие деревья, бэггинг, случайный лес, бустинг
6	Метрические методы (k NN, Парзен, STOLP), байесовский классификатор, наивный Байес, LDA/QDA
7	Кластеризация: K -средних, EM, иерархическая
8	Понижение размерности: PCA, сингулярное разложение

Таблица 1: Структура курса