

Машинное обучение

Лекция 1 — Математическая постановка задачи обучения. Данные и модель

Мотивация

Пусть для конечного набора объектов известен набор их измеримых характеристик, а для части объектов дополнительно известна некоторая связанная с ними величина. Требуется, опираясь на известные характеристики, предсказывать эту величину и для остальных, ещё не размеченных объектов. Чтобы решать подобные задачи не для одной конкретной величины, а в общем виде, необходима математическая постановка задачи обучения по прецедентам — ей посвящена эта лекция.

1 Объекты, признаки, обучающая выборка

Определение 1.1 (Прецедент, обучающая выборка). Пусть $\mathcal{X}$ — множество объектов, $\mathcal{Y}$ — множество допустимых ответов, и существует целевая функция $y^* : \mathcal{X} \rightarrow \mathcal{Y}$, значения которой $y_i = y^*(x_i)$ известны только на конечном подмножестве объектов $\{x_1, \dots, x_\ell\} \subset \mathcal{X}$. Пара «объект–ответ» (x_i, y_i) называется прецедентом, а совокупность пар $X^\ell = (x_i, y_i)_{i=1}^\ell$ — обучающей выборкой.

Задача обучения по прецедентам заключается в том, чтобы по выборке X^ℓ построить алгоритм $a : \mathcal{X} \rightarrow \mathcal{Y}$, приближающий y^* не только на объектах выборки, но и на всём $\mathcal{X}$.

Определение 1.2 (Признак). Признаком объекта называется отображение $f : \mathcal{X} \rightarrow D_f$, где D_f — множество допустимых значений признака. В зависимости от природы D_f признаки делятся на четыре типа:

Тип	D_f
бинарный	$\{0, 1\}$
номинальный	конечное неупорядоченное множество
порядковый	конечное упорядоченное множество
количественный	$\mathbb{R}$

Набор признаков $f_1, \dots, f_n$ задаёт признаковое описание объекта $x \mapsto (f_1(x), \dots, f_n(x))$; далее мы отождествляем объект с его признаковым описанием, полагая $\mathcal{X} = D_{f_1} \times \dots \times D_{f_n}$. Таблицу признаковых описаний всех объектов выборки называют матрицей объектов–признаков:

$$F = \|f_j(x_i)\|_{\ell \times n} = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \vdots & \ddots & \vdots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix}.$$

Пример 1.3 (Типы признаков). Индикатор некоторого свойства объекта — бинарный признак ($D_f = \{0, 1\}$); принадлежность к одной из нескольких категорий без отношения порядка между ними — номинальный (D_f конечно, порядок не определён); степень выраженности некоторого свойства — порядковый (D_f конечно и линейно упорядочено);

физическая величина – количественный ($D_f = \mathbb{R}$).

Пример 1.4 (Обучающая выборка). Пусть $\mathcal{X}$ – множество кошек, и для каждой известны два количественных признака: $f_1(x)$ – число банок корма, съедаемых в день, и $f_2(x)$ – возраст в годах; $\mathcal{Y} = \mathbb{R}$, $y(x)$ – вес в кг. Обучающая выборка из $\ell = 8$ наблюдений:

i	$f_1(x_i)$	$f_2(x_i)$	y_i
1	1	1	3.0
2	2	2	4.2
3	2	3	4.5
4	3	5	5.5
5	2	7	4.8
6	3	10	6.0
7	1	2	3.4
8	4	8	6.6

Матрица объектов–признаков F – это столбцы f_1, f_2 данной таблицы. Эта выборка используется также в примерах 3.2 и 7.2.

2 Типы задач по природе ответов

В зависимости от множества $\mathcal{Y}$ задачи обучения по прецедентам делятся на типы. Если $\mathcal{Y} = \mathbb{R}$ – это задача восстановления регрессии. Если $\mathcal{Y} = \{1, \dots, M\}$ – это задача классификации на M классов.

Пример 2.1 (Классификация). Пусть $\mathcal{X} = \mathbb{R}^2$, и по координатам точки $x = (x_1, x_2)$ требуется определить, по какую сторону от прямой $x_2 = x_1$ она расположена: $\mathcal{Y} = \{0, 1\}$, $y = 1$, если $x_2 > x_1$, и $y = 0$ иначе. Это задача классификации на два класса; в примере 3.2 такие задачи решаются линейной моделью.

Замечание 2.2. Задачи ранжирования и прогнозирования по структуре $\mathcal{Y}$ сводятся к классификации или регрессии и здесь отдельно не рассматриваются.

3 Модель алгоритмов и метод обучения

Определение 3.1 (Модель алгоритмов). Моделью алгоритмов называется параметрическое семейство отображений $A = \{g(x, \theta) \mid \theta \in \Theta\}$, где $g : \mathcal{X} \times \Theta \rightarrow \mathcal{Y}$ – заданная функция, Θ – пространство параметров.

Пример 3.2 (Линейная модель). Для признаков $f_1, \dots, f_n : \mathcal{X} \rightarrow \mathbb{R}$ и параметров $\theta = (\theta_0, \theta_1, \dots, \theta_n) \in \mathbb{R}^{n+1}$:

$$g(x, \theta) = \theta_0 + \sum_{j=1}^n \theta_j f_j(x) \quad - \text{ для регрессии,}$$

$$g(x, \theta) = \text{sign} \left(\theta_0 + \sum_{j=1}^n \theta_j f_j(x) \right) \quad - \text{ для классификации.}$$

Для выборки из примера 1.4 ($n = 2$) это $g(x, \theta) = \theta_0 + \theta_1 f_1(x) + \theta_2 f_2(x)$. Признаками для линейной модели могут служить и функции от исходных данных: если положить $f_j(x) = x^{j-1}$, та же формула задаёт полином степени $n - 1$.

Определение 3.3 (Метод обучения). Методом обучения называется отображение $\mu : (\mathcal{X} \times \mathcal{Y})^\ell \rightarrow A$, которое по обучающей выборке X^ℓ строит алгоритм $a = \mu(X^\ell) \in A$.

Различаются два этапа: на этапе обучения метод μ по выборке X^ℓ строит алгоритм a ; на этапе применения алгоритм a для нового объекта x выдаёт ответ $a(x)$.




Рис. 1: Этап обучения (сверху) и этап применения (снизу)

4 Напоминание из теории вероятностей

Для корректного введения понятия риска в следующем параграфе потребуется минимальный набор фактов теории вероятностей.

Будем считать, что на множестве $\mathcal{X} \times \mathcal{Y}$ задано (неизвестное нам) совместное распределение $p(x, y)$, и обучающая выборка – это набор наблюдений, случайно и независимо извлечённых из этого распределения.

Определение 4.1 (Простая выборка). Выборка $X^\ell = (x_i, y_i)_{i=1}^\ell$ называется простой (независимой одинаково распределённой), если пары (x_i, y_i) – независимые случайные величины с одним и тем же распределением $p(x, y)$.

Для случайных величин ξ, η и констант $\alpha, \beta \in \mathbb{R}$ математическое ожидание линейно: $\mathbb{E}[\alpha\xi + \beta\eta] = \alpha\mathbb{E}[\xi] + \beta\mathbb{E}[\eta]$; этот факт используется ниже.

Замечание 4.2. Вероятностная постановка – это способ формализовать неточность и неполноту реальных данных: одному и тому же x на практике могут соответствовать разные y (например, из-за погрешностей измерений), и вместо функциональной зависимости $y^*(x)$ удобнее говорить о распределении $p(x, y)$.

Предположим, что распределение $p(x, y)$ (точнее, его плотность) моделируется параметрическим семейством $\varphi(x, y, \theta)$, $\theta \in \Theta$, – так же, как модель алгоритмов $g(x, \theta)$ аппроксимирует целевую функцию y^* . Требуется по выборке X^ℓ подобрать параметр θ , при котором плотность $\varphi(\cdot, \cdot, \theta)$ наилучшим образом согласуется с данными.

Определение 4.3 (Функция правдоподобия). Пусть $X^\ell = (x_i, y_i)_{i=1}^\ell$ – простая выборка из распределения с плотностью $\varphi(x, y, \theta)$. Функцией правдоподобия называется

$$L(\theta, X^\ell) = \prod_{i=1}^{\ell} \varphi(x_i, y_i, \theta).$$

(Совместная плотность независимых наблюдений равна произведению плотностей.)

Определение 4.4 (Принцип максимума правдоподобия). Оценкой максимального правдоподобия (ММП) называется

$$\theta_{\text{ML}} = \arg \max_{\theta \in \Theta} L(\theta, X^\ell).$$

Поскольку логарифм монотонно возрастает, максимизация $L(\theta, X^\ell)$ равносильна минимизации $-\ln L(\theta, X^\ell)$; а поскольку логарифм произведения равен сумме логарифмов,

$$\theta_{\text{ML}} = \arg \min_{\theta \in \Theta} (-\ln L(\theta, X^\ell)) = \arg \min_{\theta \in \Theta} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta)).$$

5 Функция потерь, эмпирический и истинный риск

Определение 5.1 (Функция потерь). Функцией потерь называется неотрицательная функция $\mathcal{L}(a, x, y)$, характеризующая величину ошибки алгоритма a на объекте x с истинным ответом y . Стандартные примеры при $\mathcal{Y} \subseteq \mathbb{R}$:

$$\begin{aligned} \mathcal{L}(a, x, y) &= [a(x) \neq y] && \text{(классификация),} \\ \mathcal{L}(a, x, y) &= |a(x) - y|, \\ \mathcal{L}(a, x, y) &= (a(x) - y)^2 && \text{(регрессия).} \end{aligned}$$

Определение 5.2 (Эмпирический риск). Эмпирическим риском алгоритма a на выборке X^ℓ называется

$$Q(a, X^\ell) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(a, x_i, y_i).$$

Определение 5.3 (Истинный риск). Истинным (или ожидаемым) риском алгоритма a называется

$$R(a) = \mathbb{E}_{(x,y) \sim p} \mathcal{L}(a, x, y).$$

Величина $R(a)$ характеризует качество работы a на новых, ещё не виденных объектах. Но $R(a)$ вычислить нельзя, так как $p(x, y)$ неизвестно; вместо этого мы умеем считать $Q(a, X^\ell)$ по имеющимся данным.

Утверждение 5.4. Если X^ℓ – простая выборка, то $\mathbb{E}[Q(a, X^\ell)] = R(a)$.

Доказательство. По определению эмпирического риска и линейности математического ожидания,

$$\mathbb{E}[Q(a, X^\ell)] = \mathbb{E}\left[\frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(a, x_i, y_i)\right] = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbb{E}[\mathcal{L}(a, x_i, y_i)].$$

Поскольку выборка простая, все пары (x_i, y_i) распределены одинаково – как $(x, y) \sim p$, поэтому каждое слагаемое равно $\mathbb{E}[\mathcal{L}(a, x_i, y_i)] = \mathbb{E}_{(x,y) \sim p} \mathcal{L}(a, x, y) = R(a)$, и

$$\mathbb{E}[Q(a, X^\ell)] = \frac{1}{\ell} \sum_{i=1}^{\ell} R(a) = \frac{1}{\ell} \cdot \ell \cdot R(a) = R(a). \quad \square$$

Утверждение 5.4 объясняет, почему разумно заменить минимизацию недоступного $R(a)$ минимизацией вычислимого $Q(a, X^\ell)$: в среднем по всем случайным выборкам Q равен R .

Определение 5.5 (Принцип минимизации эмпирического риска (ERM)).

$$\mu(X^\ell) = \arg \min_{a \in A} Q(a, X^\ell).$$

Утверждение 5.6 (Связь ERM и ММП). Пусть модель алгоритмов $A = \{a_\theta \mid \theta \in \Theta\}$ и вероятностная модель $\varphi(x, y, \theta)$ используют один и тот же параметр θ . Если положить функцию потерь $\mathcal{L}(a_\theta, x, y) = -\ln \varphi(x, y, \theta)$, то принцип ERM для этой потери совпадает с принципом максимума правдоподобия:

$$\arg \min_{\theta \in \Theta} Q(a_\theta, X^\ell) = \theta_{\text{ML}}.$$

Доказательство. По определению эмпирического риска для указанной потери,

$$Q(a_\theta, X^\ell) = \frac{1}{\ell} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta)).$$

Умножение на положительную константу $1/\ell$ не меняет точку минимума по θ , поэтому

$$\arg \min_{\theta} Q(a_\theta, X^\ell) = \arg \min_{\theta} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta)) = \theta_{\text{ML}},$$

где последнее равенство – это в точности определение 4.4 в форме, полученной в конце §4. $\square$

6 Практический приём: матричное дифференцирование

Практический приём: матричное дифференцирование. Для скалярной функции $f(w)$ векторного аргумента $w \in \mathbb{R}^n$ градиентом называется вектор $\nabla_w f(w) = (\partial f / \partial w_1, \dots, \partial f / \partial w_n)^\top$. Потребуется два тождества:

$$\nabla_w (a^\top w) = a, \quad \nabla_w (w^\top A w) = (A + A^\top)w.$$

Утверждение 6.1 (Градиент линейной формы). Для $a \in \mathbb{R}^n$ и $f(w) = a^\top w = \sum_{i=1}^n a_i w_i$ верно $\nabla_w f(w) = a$.

Доказательство. Зафиксируем $k \in \{1, \dots, n\}$. Слагаемое $a_k w_k$ – единственное в сумме $\sum_i a_i w_i$, зависящее от w_k , поэтому $\partial f / \partial w_k = a_k$. Это верно для каждого k , значит $\nabla_w f(w) = (a_1, \dots, a_n)^\top = a$. $\square$

Утверждение 6.2 (Градиент квадратичной формы). Для $A \in \mathbb{R}^{n \times n}$ и $f(w) = w^\top A w = \sum_{i=1}^n \sum_{j=1}^n A_{ij} w_i w_j$ верно $\nabla_w f(w) = (A + A^\top)w$.

Доказательство. Зафиксируем k . В двойной сумме от w_k зависят только слагаемые с $i = k$ или $j = k$:

$$f(w) = A_{kk} w_k^2 + w_k \sum_{j \neq k} A_{kj} w_j + w_k \sum_{i \neq k} A_{ik} w_i + (\text{члены, не содержащие } w_k).$$

Дифференцируя по w_k (первое слагаемое даёт $2A_{kk}w_k$ по правилу дифференцирования степенной функции),

$$\frac{\partial f}{\partial w_k} = 2A_{kk}w_k + \sum_{j \neq k} A_{kj}w_j + \sum_{i \neq k} A_{ik}w_i = \sum_{j=1}^n A_{kj}w_j + \sum_{i=1}^n A_{ik}w_i = (Aw)_k + (A^T w)_k.$$

Так как равенство верно для каждого k , $\nabla_w f(w) = Aw + A^T w = (A + A^T)w$. $\square$

Пример 6.3. Проверим обе формулы при $n = 2$ для $f(w) = a^T w + w^T A w$, $a = (2, -1)^T$, $A = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix}$. Раскрывая f напрямую и дифференцируя,

$$f(w) = (2w_1 - w_2) + (w_1^2 + w_1w_2 + 2w_2^2), \quad \frac{\partial f}{\partial w_1} = 2 + 2w_1 + w_2, \quad \frac{\partial f}{\partial w_2} = -1 + w_1 + 4w_2.$$

По предложениям 6.1 и 6.2, $A + A^T = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}$ и

$$\nabla_w f(w) = a + (A + A^T)w = \begin{pmatrix} 2 \\ -1 \end{pmatrix} + \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \end{pmatrix} = \begin{pmatrix} 2 + 2w_1 + w_2 \\ -1 + w_1 + 4w_2 \end{pmatrix},$$

что совпадает с прямым вычислением.

Выведем формулу для градиента нормы невязки, которая понадобится в следующем параграфе. Раскрывая скобки,

$$\|Xw - y\|^2 = (Xw - y)^T (Xw - y) = w^T X^T X w - 2y^T X w + y^T y.$$

Первое слагаемое – квадратичная форма с матрицей $X^T X$ (симметричной), второе – линейная форма с вектором $-2X^T y$ (поскольку $y^T X w = (X^T y)^T w$), третье от w не зависит. Применяя предложения 6.1 и 6.2 почленно,

$$\nabla_w \|Xw - y\|^2 = (X^T X + (X^T X)^T)w - 2X^T y = 2X^T X w - 2X^T y = 2X^T (Xw - y).$$

Эта формула используется в следующем параграфе, а также в дальнейшем изложении.

Рассмотренные тождества касаются дифференцирования по вектору. Аналогично определяется дифференцирование скалярной функции по матрице: для $f : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$ градиентом $\nabla_A f(A)$ называется матрица тех же размеров, что и A , с элементами $(\nabla_A f(A))_{ij} = \partial f / \partial A_{ij}$. Типичный пример такой функции – определитель.

Утверждение 6.4 (Градиент определителя). Пусть $A \in \mathbb{R}^{n \times n}$ невырождена. Тогда

$$\nabla_A \det A = \det(A) (A^{-1})^T.$$

Доказательство. Разложим определитель по i -й строке: $\det A = \sum_{k=1}^n A_{ik} C_{ik}$, где $C_{ik} = (-1)^{i+k} M_{ik}$ – алгебраическое дополнение элемента A_{ik} , а минор M_{ik} – определитель матрицы, полученной вычёркиванием строки i и столбца k из A . Минор M_{ik} не содержит ни одного элемента строки i , в частности не зависит от A_{ij} ни при каком j . Поэтому в сумме $\sum_k A_{ik} C_{ik}$ от A_{ij} зависит только слагаемое с $k = j$, и

$$\frac{\partial \det A}{\partial A_{ij}} = C_{ij}.$$

Это верно для любых i, j , поэтому $\nabla_A \det A = (C_{ij})$ – транспонированная матрица алгебраических дополнений, называемая присоединённой матрицей: $(C_{ij}) = \text{adj}(A)^T$. Из формулы обратной матрицы $A^{-1} = \det(A)^{-1} \text{adj}(A)$ получаем $\text{adj}(A) = \det(A) A^{-1}$, откуда $\nabla_A \det A = \text{adj}(A)^T = \det(A) (A^{-1})^T$. $\square$

Пример 6.5. При $n = 2$, $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$, $\det A = ad - bc$, откуда непосредственным дифференцированием

$$\nabla_A \det A = \begin{pmatrix} \partial(\det A)/\partial a & \partial(\det A)/\partial b \\ \partial(\det A)/\partial c & \partial(\det A)/\partial d \end{pmatrix} = \begin{pmatrix} d & -c \\ -b & a \end{pmatrix}.$$

С другой стороны, $A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$, так что $\det(A)(A^{-1})^\top = \begin{pmatrix} d & -c \\ -b & a \end{pmatrix}$ – формулы совпадают.

Замечание 6.6. Градиент определителя используется, например, при работе с плотностью многомерного нормального распределения, куда определитель ковариационной матрицы входит через нормировочный множитель.

7 Пример: метод наименьших квадратов как ERM

Рассмотрим линейную модель $g(x, \theta) = \theta_0 + \sum_{j=1}^n \theta_j f_j(x)$ с квадратичной функцией потерь, как в определении 5.1. Обозначим через $X \in \mathbb{R}^{\ell \times (n+1)}$ матрицу объектов–признаков с добавленным первым столбцом из единиц (под свободный член θ_0), через $y \in \mathbb{R}^\ell$ – вектор ответов. Тогда

$$Q(\theta) = \frac{1}{\ell} \sum_{i=1}^{\ell} (g(x_i, \theta) - y_i)^2 = \frac{1}{\ell} \|X\theta - y\|^2,$$

и минимизация $Q(\theta)$ равносильна минимизации $\|X\theta - y\|^2$, так как множитель $1/\ell$ не влияет на точку минимума.

Теорема 7.1 (Нормальные уравнения МНК). Если $X^\top X$ невырождена, то $\theta^* = \arg \min_{\theta} \|X\theta - y\|^2$ единствен и равен

$$\theta^* = (X^\top X)^{-1} X^\top y.$$

Доказательство. По формуле для градиента нормы невязки из §6, $\nabla_{\theta} \|X\theta - y\|^2 = 2X^\top(X\theta - y)$. В точке минимума градиент обращается в ноль:

$$2X^\top(X\theta - y) = 0 \iff X^\top X\theta = X^\top y,$$

откуда при невырожденности $X^\top X$ следует $\theta = (X^\top X)^{-1} X^\top y$, и эта точка единственна. Матрица Гессе равна $\nabla_{\theta}^2 \|X\theta - y\|^2 = 2X^\top X$; она всегда положительно полуопределена, так как $w^\top (X^\top X) w = \|Xw\|^2 \geq 0$ для любого w , а при невырожденности $X^\top X$ – положительно определена (иначе нашёлся бы $w \neq 0$ с $Xw = 0$ и $X^\top Xw = 0$, противоречие). Значит, $\|X\theta - y\|^2$ выпукла, и найденная стационарная точка – глобальный минимум. $\square$

Пример 7.2. Применим теорему 7.1 к выборке из примера 1.4: $X \in \mathbb{R}^{8 \times 3}$ (со столбцом единиц под θ_0) и $y \in \mathbb{R}^8$ составлены по данным таблицы этого примера. Решение системы нормальных уравнений $X^\top X\theta = X^\top y$ (вычисления, как в теореме 7.1, опускаем) даёт

$$\theta^* \approx (2.201, 0.893, 0.114),$$

то есть $g(x, \theta^*) \approx 2.201 + 0.893f_1(x) + 0.114f_2(x)$.

Пример 7.3 (Вероятностная интерпретация МНК). Предположим дополнительно, что $y = g(x, \theta) + \varepsilon$, где шум $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ независим для разных наблюдений и не зависит от x . Тогда при фиксированном x ответ y распределён как $\mathcal{N}(g(x, \theta), \sigma^2)$, и

$$\varphi(x, y, \theta) = p(x) \cdot \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - g(x, \theta))^2}{2\sigma^2}\right).$$

Логарифмируя,

$$-\ln \varphi(x, y, \theta) = \underbrace{-\ln p(x) + \frac{1}{2} \ln(2\pi\sigma^2)}_{C, \text{ не зависит от } \theta} + \frac{1}{2\sigma^2} (g(x, \theta) - y)^2.$$

По предложению 5.6, $\theta_{\text{ML}} = \arg \min_{\theta} \sum_{i=1}^{\ell} (-\ln \varphi(x_i, y_i, \theta))$. Слагаемое ℓC от θ не зависит, а положительный множитель $1/(2\sigma^2)$ на точку минимума не влияет, поэтому

$$\theta_{\text{ML}} = \arg \min_{\theta} \sum_{i=1}^{\ell} (g(x_i, \theta) - y_i)^2 = \arg \min_{\theta} \|X\theta - y\|^2 = \theta^*.$$

Иными словами, найденное в примере 7.2 решение нормальных уравнений – это в точности оценка максимального правдоподобия для линейной модели с независимым гауссовским шумом постоянной дисперсии.

Заключение

Замечание 7.4. Вне рассмотрения остались две темы. Во-первых, минимизация эмпирического риска до нуля не гарантирует малости истинного риска – это явление переобучения. Во-вторых, нормальные уравнения – не единственный способ решать $\arg \min_{\theta} Q(\theta)$; в следующей лекции тот же результат получен итеративно, методом градиентного спуска, и линейная регрессия разобрана подробнее.