

Машинное обучение

Лекция 2 — Линейные модели: градиентный спуск и регуляризация

Мотивация

В Лекции 1 для линейной модели $g(x, \theta) = \theta_0 + \sum_{j=1}^n \theta_j f_j(x)$ и квадратичной функции потерь была получена явная формула $\theta^* = (X^T X)^{-1} X^T y$ и на конкретной выборке (восемь объектов, признаки f_1, f_2) вычислен ответ. У этой формулы есть два недостатка. Во-первых, обращение матрицы $X^T X$ размера $(n+1) \times (n+1)$ требует $O(n^3)$ операций, что дорого при большом числе признаков. Во-вторых, формула вовсе не работает, если $X^T X$ вырождена, и работает плохо, если $X^T X$ близка к вырожденной, — это происходит при почти линейной зависимости между признаками. В этой лекции разбираются два независимых способа справиться с этими проблемами: итерационный метод (градиентный спуск, не требующий обращения матрицы) и регуляризация (модификация функционала, гарантирующая невырожденность).

1 Метод градиентного спуска

Функционал $Q(\theta) = \|X\theta - y\|^2$ выпуклый (Лекция 1, Теорема о нормальных уравнениях), поэтому его стационарная точка — глобальный минимум. Вместо решения уравнения $\nabla Q(\theta) = 0$ в явном виде можно искать минимум итерационно.

Определение 1.1 (Градиентный спуск). Методом градиентного спуска для минимизации дифференцируемого функционала $Q(\theta)$ называется итерационная процедура

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla Q(\theta^{(t)}), \quad t = 0, 1, 2, \dots,$$

где $\theta^{(0)}$ — начальное приближение, $\eta_t > 0$ — шаг (learning rate).

Направление $-\nabla Q(\theta^{(t)})$ — это направление наискорейшего локального убывания Q , поэтому при достаточно малом η_t выполняется $Q(\theta^{(t+1)}) \leq Q(\theta^{(t)})$. Следующее утверждение уточняет, при каких $\eta_t \equiv \eta$ (постоянный шаг) последовательность $\theta^{(t)}$ сходится к минимуму для нашего квадратичного функционала.

Утверждение 1.2 (Сходимость градиентного спуска). Пусть $X^T X$ невырождена, $\theta^* = (X^T X)^{-1} X^T y$, и пусть $\lambda_{\max}$ — наибольшее собственное число матрицы $X^T X$. Если шаг постоянен, $\eta_t \equiv \eta$, и $0 < \eta < 1/\lambda_{\max}$, то $\theta^{(t)} \rightarrow \theta^*$ при $t \rightarrow \infty$ для любого начального приближения $\theta^{(0)}$.

Доказательство. Так как $X^T X \theta^* = X^T y$ (нормальные уравнения),

$$\nabla Q(\theta) = 2X^T(X\theta - y) = 2X^T X\theta - 2X^T y = 2X^T X(\theta - \theta^*) = H(\theta - \theta^*),$$

где $H = 2X^T X$ — симметричная положительно определённая матрица (при невырожденности $X^T X$). Обозначим $e_t = \theta^{(t)} - \theta^*$. Тогда

$$e_{t+1} = \theta^{(t+1)} - \theta^* = e_t - \eta H e_t = (I - \eta H) e_t, \quad \text{откуда} \quad e_t = (I - \eta H)^t e_0.$$

Пусть $v_1, \dots, v_n$ – ортонормированный базис из собственных векторов H с собственными числами $\mu_1, \dots, \mu_n > 0$ ($\mu_{\max} = 2\lambda_{\max}$), и $e_0 = \sum_i c_i v_i$. Матрица $I - \eta H$ имеет тот же базис собственных векторов с числами $1 - \eta\mu_i$, поэтому

$$e_t = \sum_i c_i (1 - \eta\mu_i)^t v_i, \quad \|e_t\|^2 = \sum_i c_i^2 (1 - \eta\mu_i)^{2t}.$$

Каждое слагаемое стремится к нулю при $t \rightarrow \infty$ тогда и только тогда, когда $|1 - \eta\mu_i| < 1$, то есть $0 < \eta < 2/\mu_i$. Это верно для всех i одновременно при $0 < \eta < 2/\mu_{\max} = 1/\lambda_{\max}$, значит $\|e_t\| \rightarrow 0$. $\square$

Пример 1.3. При $n = 1$, $Q(\theta) = \theta^2$ ($H = 2$, $\lambda_{\max}$ для этой модели играет число 1), шаг $\theta^{(t+1)} = \theta^{(t)} - \eta \cdot 2\theta^{(t)} = (1 - 2\eta)\theta^{(t)}$, так что $\theta^{(t)} = (1 - 2\eta)^t \theta^{(0)}$. Ряд сходится к $0 = \theta^*$ при $0 < \eta < 1$, расходится при $\eta > 1$ и колеблется не убывая при $\eta = 1$ ($\theta^{(t)} = \pm \theta^{(0)}$) – ровно то, что предсказывает предложение 1.2.




Рис. 1: Схематический путь градиентного спуска на квадратичном Q с вытянутыми (не круговыми) линиями уровня – отношение полуосей эллипсов равно $\sqrt{\lambda_{\max}/\lambda_{\min}}$. Чем сильнее вытянуты эллипсы (хуже обусловленность), тем заметнее «зигзаг»: шаг, хороший вдоль направления $\lambda_{\min}$, слишком велик вдоль направления $\lambda_{\max}$.

Замечание 1.4 (Скорость сходимости). Доказательство показывает больше, чем сходимость: медленнее всего убывают компоненты с собственными числами, ближайшими к границам спектра, а точная скорость (при оптимальном выборе η) определяется числом обусловленности $\text{cond}(X^T X) = \lambda_{\max}/\lambda_{\min}$ – отношением наибольшего и наименьшего собственных чисел. Чем ближе $\lambda_{\min}$ к нулю (то есть чем ближе $X^T X$ к вырожденной), тем медленнее сходится градиентный спуск. Это тот же параметр $\lambda_{\min}$, что вызывает неустойчивость нормальных уравнений – см. §2.

Определение 1.5 (Стохастический градиентный спуск). Пусть $Q(\theta) = \frac{1}{\ell} \sum_{i=1}^{\ell} Q_i(\theta)$, где $Q_i(\theta) = \mathcal{L}(a_\theta, x_i, y_i)$ – потеря на одном объекте. Стохастическим градиентным спуском (SGD) называется процедура

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla Q_{i_t}(\theta^{(t)}),$$

где на каждом шаге индекс i_t выбирается случайно (равномерно на $\{1, \dots, \ell\}$ или последовательным проходом по перемешанной выборке).

В отличие от обычного (batch) градиентного спуска, здесь каждый шаг требует $O(n)$, а не $O(n\ell)$ операций – это существенно при больших ℓ . Платой за это является шум:

$\nabla Q_{i_t}(\theta)$ – лишь несмещённая оценка $\nabla Q(\theta)$ (в смысле, аналогичном утверждению 5.4 из Лекции 1 – матожидание по случайному индексу i_t равно $\nabla Q(\theta)$), и последовательность $\theta^{(t)}$ не сходится к θ^* при постоянном шаге, а колеблется в его окрестности. Чтобы добиться сходимости, шаг обычно берут убывающим, $\eta_t \rightarrow 0$; общепринятое (Роббинс–Монро, 1951) достаточное условие –

$$\sum_{t=0}^{\infty} \eta_t = \infty, \quad \sum_{t=0}^{\infty} \eta_t^2 < \infty$$

(например, $\eta_t \sim 1/t$) – шаги должны убывать, но не слишком быстро, чтобы суммарно можно было пройти любое расстояние. На практике используют мини-пакеты (mini-batch): усредняют ∇Q_i по небольшой случайной группе объектов, получая компромисс между точностью batch-градиента и дешевизной SGD.

2 Мультиколлинеарность и обусловленность

Определение 2.1 (Мультиколлинеарность). Признаки $f_1, \dots, f_n$ называются мультиколлинеарными, если столбцы матрицы X (почти) линейно зависимы. В этом случае матрица $X^T X$ (почти) вырождена: у неё есть собственное число $\lambda_{\min}$, близкое к нулю.

Пример 2.2. Пусть $\ell = 3$ и признак f_2 пропорционален f_1 : $f_2 = 2f_1$, со значениями $f_1 = (1, 2, 3)^T$. Без учёта свободного члена,

$$X = \begin{pmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{pmatrix}, \quad X^T X = \begin{pmatrix} 14 & 28 \\ 28 & 56 \end{pmatrix}, \quad \det(X^T X) = 14 \cdot 56 - 28^2 = 0.$$

Матрица вырождена: второй столбец $X^T X$ равен удвоенному первому, так как $f_2 = 2f_1$. Нормальные уравнения либо не имеют решения, либо имеют их бесконечно много (вдоль направления $(2, -1)$, на котором $X^T X$ обращается в нуль).

Утверждение 2.3 (Неустойчивость решения). Пусть $A = X^T X$ невырождена, с наименьшим и наибольшим собственными числами $\lambda_{\min}, \lambda_{\max} > 0$, $b = X^T y$, $\theta = A^{-1}b$. Если b возмущён на δb , то решение $\theta + \delta\theta = A^{-1}(b + \delta b)$ удовлетворяет

$$\frac{\|\delta\theta\|}{\|\theta\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|}, \quad \text{cond}(A) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Доказательство. Так как A симметрична, для любого v верно $\|Av\| \leq \lambda_{\max} \|v\|$ и $\|Av\| \geq \lambda_{\min} \|v\|$ (раскладывая v по ортонормированному базису собственных векторов). Из $\delta\theta = A^{-1}\delta b$ и первого неравенства, применённого к A^{-1} (с собственными числами $1/\lambda_i$), получаем $\|\delta\theta\| \leq \|\delta b\| / \lambda_{\min}$. Из $b = A\theta$ и второго неравенства – $\|b\| \geq \lambda_{\min} \|\theta\|$... точнее, применяя оценку сверху к $b = A\theta$: $\|\theta\| \geq \|b\| / \lambda_{\max}$. Комбинируя,

$$\frac{\|\delta\theta\|}{\|\theta\|} \leq \frac{\|\delta b\| / \lambda_{\min}}{\|b\| / \lambda_{\max}} = \frac{\lambda_{\max}}{\lambda_{\min}} \cdot \frac{\|\delta b\|}{\|b\|}. \quad \square$$

Итак, чем больше $\text{cond}(X^T X)$ – тем сильнее шум в данных (например, погрешности измерений, входящие в y , а значит и в $b = X^T y$) раскачивает решение θ^* , и тем медленнее (замечание к предложению 1.2) сходится градиентный спуск. Оба явления – следствие малости $\lambda_{\min}$. Способ гарантированно отодвинуть $\lambda_{\min}$ от нуля – регуляризация.

3 Гребневая регрессия (Ridge, L_2 -регуляризация)

Свободный член θ_0 регуляризовать нежелательно: прибавление константы ко всем y_i должно просто сдвигать θ_0 на ту же константу, а штраф за величину θ_0 этому препятствовал бы. Введём матрицу $D = \text{diag}(0, 1, \dots, 1) \in \mathbb{R}^{(n+1) \times (n+1)}$, обнуляющую вклад θ_0 .

Определение 3.1 (Гребневая регрессия). При параметре регуляризации $\lambda > 0$ регуляризованным эмпирическим риском называется

$$Q_\lambda(\theta) = \|X\theta - y\|^2 + \lambda \theta^\top D \theta = \|X\theta - y\|^2 + \lambda \sum_{j=1}^n \theta_j^2,$$

а гребневой регрессией – метод $\theta_\lambda^* = \arg \min_\theta Q_\lambda(\theta)$.

Практический приём: матричное дифференцирование (Лекция 1). Напомним два факта из Лекции 1: для симметричной A верно $\nabla_\theta(\theta^\top A \theta) = 2A\theta$, и $\nabla_\theta \|X\theta - y\|^2 = 2X^\top(X\theta - y)$.

Теорема 3.2 (Нормальные уравнения гребневой регрессии). Для любого $\lambda > 0$ матрица $X^\top X + \lambda D$ положительно определена (в частности, невырождена, даже если $X^\top X$ вырождена), и

$$\theta_\lambda^* = (X^\top X + \lambda D)^{-1} X^\top y.$$

Доказательство. По формулам из практического приёма, $\nabla_\theta Q_\lambda(\theta) = 2X^\top(X\theta - y) + 2\lambda D\theta$. Приравнявая нулю, $(X^\top X + \lambda D)\theta = X^\top y$.

Проверим положительную определённость. Пусть $v \neq 0$ и $v^\top(X^\top X + \lambda D)v = 0$. Так как оба слагаемых $\|Xv\|^2 = v^\top X^\top X v$ и $\lambda v^\top D v$ неотрицательны, оба должны быть равны нулю. Из $v^\top D v = \sum_{j \geq 1} v_j^2 = 0$ следует $v_1 = \dots = v_n = 0$, то есть $v = (v_0, 0, \dots, 0)$ с $v_0 \neq 0$. Но первый столбец X – это столбец из единиц, поэтому $Xv = v_0 \mathbf{1} \neq 0$ (так как $\ell \geq 1$), и $\|Xv\|^2 = \ell v_0^2 > 0$ – противоречие. Значит, $X^\top X + \lambda D$ положительно определена, и найденная стационарная точка – единственный глобальный минимум Q_λ (выпуклой функции). $\square$

Замечание 3.3. При $\lambda \rightarrow 0$ формула переходит в обычные нормальные уравнения (Лекция 1); при $\lambda \rightarrow \infty$ решение $\theta_\lambda^* \rightarrow (\theta_0, 0, \dots, 0)$ – все веса, кроме свободного члена, стягиваются к нулю (можно проверить, переписав $\theta_\lambda^* = (X^\top X / \lambda + D)^{-1} X^\top y / \lambda$ и устремив $\lambda \rightarrow \infty$). Промежуточные значения λ дают компромисс: увеличение λ увеличивает смещение (bias) решения, но уменьшает его разброс (variance) и, как показано выше, устраняет неустойчивость при мультиколлинеарности.

4 Байесовская интерпретация: апостериорный максимум

В Лекции 1 было показано, что θ^* (обычные нормальные уравнения) – это оценка максимума правдоподобия (ММП) для линейной модели с независимым гауссовским шумом $\varepsilon \sim \mathcal{N}(0, \sigma^2)$: $\theta_{\text{ML}} = \arg \min_\theta \|X\theta - y\|^2$. Байесовский подход добавляет априорное распределение на параметр – θ также считается случайным, с известной плотностью $p(\theta)$ до наблюдения данных.

Определение 4.1 (Апостериорный максимум (МАР)). Пусть $p(\theta)$ – априорная плотность параметра, $L(\theta, X^\ell)$ – функция правдоподобия (Лекция 1). По формуле Байеса апостериорная плотность $p(\theta | X^\ell) \propto L(\theta, X^\ell) p(\theta)$. Оценкой апостериорного максимума называется

$$\theta_{\text{МАР}} = \arg \max_{\theta} L(\theta, X^\ell) p(\theta) = \arg \min_{\theta} (-\ln L(\theta, X^\ell) - \ln p(\theta)).$$

Утверждение 4.2 (Связь МАР и гребневой регрессии). Пусть шум гауссовский, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, как в Лекции 1, а априорное распределение – независимое гауссовское на нерегуляризуемых координатах: $\theta_j \sim \mathcal{N}(0, \tau^2)$ независимо для $j = 1, \dots, n$, θ_0 имеет несобственное (равномерное) априорное распределение. Тогда

$$\theta_{\text{МАР}} = \theta_{\lambda}^*, \quad \lambda = \sigma^2 / \tau^2.$$

Доказательство. Из Лекции 1, $-\ln L(\theta, X^\ell) = \ell C + \frac{1}{2\sigma^2} \|X\theta - y\|^2$, где C от θ не зависит. Далее,

$$-\ln p(\theta) = \sum_{j=1}^n \left(\frac{1}{2} \ln(2\pi\tau^2) + \frac{\theta_j^2}{2\tau^2} \right) = \frac{n}{2} \ln(2\pi\tau^2) + \frac{1}{2\tau^2} \theta^\top D \theta$$

(слагаемое для θ_0 отсутствует ввиду несобственного априорного распределения). Сумма даёт

$$-\ln L(\theta, X^\ell) - \ln p(\theta) = \text{const} + \frac{1}{2\sigma^2} \|X\theta - y\|^2 + \frac{1}{2\tau^2} \theta^\top D \theta.$$

Умножая на положительную константу $2\sigma^2$ (аргумент минимума не меняется),

$$\theta_{\text{МАР}} = \arg \min_{\theta} \left(\|X\theta - y\|^2 + \frac{\sigma^2}{\tau^2} \theta^\top D \theta \right) = \theta_{\lambda}^*, \quad \lambda = \sigma^2 / \tau^2. \quad \square$$

Замечание 4.3. Чем увереннее априорное предположение о малости весов (меньше τ^2), тем сильнее эффективная регуляризация $\lambda = \sigma^2 / \tau^2$. Аналогичная связь есть и для L_1 -регуляризации из следующего параграфа: если положить θ_j независимыми с плотностью Лапласа $p(\theta_j) \propto \exp(-|\theta_j|/b)$, то $-\ln p(\theta)$ содержит слагаемое $\sum |\theta_j|/b$, и МАР-оценка совпадает с LASSO.

5 LASSO (L_1 -регуляризация)

Определение 5.1 (LASSO). При $\lambda > 0$ LASSO (least absolute shrinkage and selection operator) – это метод

$$\theta_{\lambda}^* = \arg \min_{\theta} \left(\|X\theta - y\|^2 + \lambda \sum_{j=1}^n |\theta_j| \right).$$

В отличие от гребневой регрессии, здесь штраф $\sum |\theta_j|$ не дифференцируем при $\theta_j = 0$, и явной формулы для θ_{λ}^* не существует; решение находят численно (покоординатный спуск, субградиентные методы). Качественно же LASSO ведёт себя иначе, чем ridge: при достаточно большом λ решение θ_{λ}^* – разреженное, то есть часть координат обращается в точности в ноль, а не просто становится малой. Это делает LASSO инструментом отбора признаков.




Рис. 2: Схематическая иллюстрация: минимум квадратичного Q на L_1 -шаре типично достигается в вершине (разреженное решение); на L_2 -шаре (круге) выделенных направлений нет, и решение обычно не разрежено.

Замечание 5.2. Геометрическая причина: множество уровня $\{\theta : \sum |\theta_j| \leq c\}$ — многогранник с вершинами на координатных осях (там, где часть координат равна нулю), тогда как $\{\theta : \sum \theta_j^2 \leq c\}$ — шар, гладкий и без выделенных направлений. У выпуклой задачи минимизации гладкого Q на выпуклом множестве решение часто попадает на границу; для многогранника это преимущественно вершины и рёбра (разреженные точки), для шара — произвольная точка сферы (плотное решение).

Заключение

Замечание 5.3. Вне рассмотрения остались: линейные модели классификации (логистическая регрессия, метод опорных векторов) — предмет следующей лекции; строгая теория сходимости SGD (условия Роббинса–Монро приведены без доказательства); способы выбора параметра λ по данным (скользящий контроль, рассмотренный в общих чертах в Лекции о переобучении).