

Машинное обучение

Лекция 3 — Линейная классификация: логистическая регрессия и метод опорных векторов

Мотивация

В Лекции 1 линейный классификатор был введён формулой $a(x) = \text{sign}(\theta_0 + \sum_{j=1}^n \theta_j f_j(x))$ (Пример 3.2), а в качестве функции потерь для классификации — индикатор ошибки $\mathcal{L}(a, x, y) = [a(x) \neq y]$. У этой потери есть техническая проблема: как функция параметра θ она кусочно-постоянна, её градиент почти всюду равен нулю, и градиентный спуск (Лекция 2) к ней неприменим. В этой лекции разбираются два независимых способа обойти эту проблему: заменить индикатор гладкой функцией потерь, допускающей вероятностную интерпретацию (логистическая регрессия), или отказаться от градиентного подхода в пользу геометрической идеи максимального отступа, приводящей к задаче выпуклой оптимизации с ограничениями (метод опорных векторов, SVM).

1 Логистическая регрессия

Рассмотрим задачу классификации на два класса, $\mathcal{Y} = \{0, 1\}$ (Пример 2.1: $y = 1$, если $x_2 > x_1$, и $y = 0$ иначе). Вместо того чтобы сразу предсказывать y , логистическая регрессия моделирует вероятность $p(y = 1 | x)$.

Определение 1.1 (Логистическая (сигмоидная) функция).

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z \in \mathbb{R}.$$

Функция σ монотонно возрастает от 0 до 1, $\sigma(0) = 1/2$, и удовлетворяет удобному тождеству $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ (проверяется прямым дифференцированием $\sigma(z) = (1 + e^{-z})^{-1}$).




Рис. 1: График логистической функции

Определение 1.2 (Модель логистической регрессии). $g(x, \theta) = \sigma(\theta_0 + \sum_{j=1}^n \theta_j f_j(x))$ моделирует $p(y = 1 | x, \theta)$; предсказание $a(x) = [g(x, \theta) \geq 1/2]$.

Обозначим $h_i = g(x_i, \theta)$ (как и раньше, θ включает свободный член, а x_i — соответствующий столбец единиц). Поскольку $y_i \in \{0, 1\}$, удобно записать вероятность одной формулой: $p(y_i | x_i, \theta) = h_i^{y_i} (1 - h_i)^{1-y_i}$. Функция правдоподобия (Лекция 1) — $L(\theta, X^\ell) = \prod_{i=1}^\ell h_i^{y_i} (1 - h_i)^{1-y_i}$, и

Определение 1.3 (Логистическая функция потерь).

$$\mathcal{L}(a_\theta, x, y) = -y \ln g(x, \theta) - (1 - y) \ln(1 - g(x, \theta)).$$

По построению $-\ln L(\theta, X^\ell) = \sum_i \mathcal{L}(a_\theta, x_i, y_i)$, так что принцип ERM для логистической потери – это в точности ММП (предложение о связи ERM и ММП, Лекция 1).

Утверждение 1.4 (Градиент логистической потери). Пусть $Q(\theta) = \sum_{i=1}^\ell \mathcal{L}(a_\theta, x_i, y_i)$. Тогда

$$\nabla_\theta Q(\theta) = \sum_{i=1}^\ell (h_i - y_i) x_i = X^\top (h - y),$$

где $h = (h_1, \dots, h_\ell)^\top$.

Доказательство. Обозначим $z_i = \theta^\top x_i$, так что $h_i = \sigma(z_i)$. По правилу дифференцирования сложной функции и тождеству $\sigma' = \sigma(1 - \sigma)$,

$$\frac{\partial \mathcal{L}_i}{\partial z_i} = -y_i \frac{\sigma'(z_i)}{\sigma(z_i)} + (1 - y_i) \frac{\sigma'(z_i)}{1 - \sigma(z_i)} = -y_i(1 - h_i) + (1 - y_i)h_i = h_i - y_i.$$

Так как $\partial z_i / \partial \theta = x_i$, по цепному правилу $\nabla_\theta \mathcal{L}_i = (h_i - y_i) x_i$. Суммируя по i , получаем утверждение. $\square$

Замечание 1.5. Формула $\nabla Q(\theta) = X^\top (h - y)$ имеет в точности ту же форму, что и градиент квадратичной потери из Лекции 1, $\nabla \|X\theta - y\|^2 = 2X^\top (X\theta - y)$ – в обоих случаях это «матрица объектов–признаков», умноженная на вектор разностей (предсказание минус ответ). Разница лишь в том, что предсказание $h = \sigma(X\theta)$ здесь нелинейно по θ .

Утверждение 1.6 (Выпуклость). $Q(\theta)$ выпукла.

Доказательство. Дифференцируя формулу предложения 1.4 ещё раз по θ (с учётом $\partial h_i / \partial \theta = h_i(1 - h_i)x_i$), получаем матрицу Гессе

$$\nabla_\theta^2 Q(\theta) = \sum_{i=1}^\ell h_i(1 - h_i) x_i x_i^\top = X^\top S X, \quad S = \text{diag}(h_1(1 - h_1), \dots, h_\ell(1 - h_\ell)).$$

Так как $h_i \in (0, 1)$, диагональные элементы S неотрицательны, и для любого v , $v^\top X^\top S X v = \sum_i s_i (x_i^\top v)^2 \geq 0$ – матрица Гессе положительно полуопределена, Q выпукла (тот же приём, что и для $X^\top X$ в Лекции 1). $\square$

В отличие от линейной регрессии, уравнение $\nabla Q(\theta) = 0$ здесь трансцендентно и не решается в явном виде; но выпуклость (предложение 1.6) гарантирует, что градиентный спуск (Лекция 2) сходится к глобальному минимуму.

Пример 1.7 (Один шаг градиентного спуска вручную). Пусть $n = 1$ (единственный признак $f_1(x) = x$), три объекта: $x_1 = 1, y_1 = 0$; $x_2 = 2, y_2 = 1$; $x_3 = 3, y_3 = 1$. Начнём с $\theta^{(0)} = (\theta_0, \theta_1) = (0, 0)$. Тогда для всех трёх объектов $z_i = \theta_0 + \theta_1 x_i = 0$, и, так как $\sigma(0) = 1/2$, $h_i = 1/2$ одинаково для всех i . По предложению 1.4,

$$\begin{aligned} \nabla Q(\theta^{(0)}) &= X^\top (h - y), \quad X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \quad h - y = \begin{pmatrix} 0.5 \\ -0.5 \\ -0.5 \end{pmatrix}, \\ \nabla Q(\theta^{(0)}) &= \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 0.5 \\ -0.5 \\ -0.5 \end{pmatrix} = \begin{pmatrix} 0.5 - 0.5 - 0.5 \\ 0.5 - 1 - 1.5 \end{pmatrix} = \begin{pmatrix} -0.5 \\ -2 \end{pmatrix}. \end{aligned}$$

При шаге $\eta = 0.5$: $\theta^{(1)} = \theta^{(0)} - \eta \nabla Q(\theta^{(0)}) = (0, 0) - 0.5(-0.5, -2) = (0.25, 1)$ – уже после одного шага $\theta_1 > 0$, то есть модель начинает верно улавливать, что большим x соответствует класс 1.




Рис. 2: Выборка примера 1.7: требуется отделить x_1 (класс 0) от x_2, x_3 (класс 1)

2 Метод опорных векторов: жёсткий зазор

В этом параграфе удобнее использовать обозначения $\mathcal{Y} = \{-1, +1\}$ вместо $\{0, 1\}$ (Пример 2.1 переразмечается: $y = +1$, если $x_2 > x_1$, и $y = -1$ иначе) и явно выписывать свободный член: классификатор ищется в виде $a(x) = \text{sign}(w^\top x + b)$, $w \in \mathbb{R}^n$, $b \in \mathbb{R}$ (x здесь без добавленной единицы).

Определение 2.1 (Отступ). Отступом (margin) объекта (x_i, y_i) относительно гиперплоскости $w^\top x + b = 0$ называется $\gamma_i = y_i(w^\top x_i + b) / \|w\|$. Если $\gamma_i > 0$, объект классифицирован верно. Отступом выборки называется $\gamma = \min_i \gamma_i$.

Величина γ_i – это (со знаком) евклидово расстояние от x_i до гиперплоскости. Идея метода опорных векторов – выбрать (w, b) , максимизирующие отступ γ , то есть разделяющую полосу максимальной ширины между классами. Пара (w, b) определена с точностью до положительного масштабирования (умножение обоих на $c > 0$ не меняет $\text{sign}(w^\top x + b)$ и не меняет γ_i), поэтому можно наложить нормировку $\min_i y_i(w^\top x_i + b) = 1$; тогда $\gamma = 1 / \|w\|$, и максимизация γ равносильна минимизации $\|w\|$.

Определение 2.2 (Прямая задача SVM).

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{при условиях} \quad y_i(w^\top x_i + b) \geq 1, \quad i = 1, \dots, \ell.$$

Это задача выпуклого квадратичного программирования (выпуклая квадратичная цель, линейные ограничения); при линейно разделимой выборке решение существует и единственно.

Практический приём: множители Лагранжа. Для задачи $\min_w f(w)$ при ограничениях $c_i(w) \geq 0$ вводится функция Лагранжа $L(w, \alpha) = f(w) - \sum_i \alpha_i c_i(w)$, $\alpha_i \geq 0$. В точке минимума выполнены условия стационарности $\nabla_w L = 0$ и условия дополняющей нежёсткости $\alpha_i c_i(w) = 0$ (либо ограничение не активно, $c_i(w) > 0$, и тогда $\alpha_i = 0$; либо оно активно, $c_i(w) = 0$). При выпуклой f и линейных c_i (наш случай) эти условия достаточны для оптимальности, а подстановка стационарной точки обратно в L даёт эквивалентную двойственную задачу $\max_{\alpha \geq 0} \min_w L(w, \alpha)$.

Функция Лагранжа для задачи 2.2 (перепишем ограничения как $c_i(w, b) = y_i(w^\top x_i + b) - 1 \geq 0$):

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^{\ell} \alpha_i [y_i(w^\top x_i + b) - 1], \quad \alpha_i \geq 0.$$

Утверждение 2.3 (Стационарность). В точке минимума по (w, b) выполнено

$$w = \sum_{i=1}^{\ell} \alpha_i y_i x_i, \quad \sum_{i=1}^{\ell} \alpha_i y_i = 0.$$

Доказательство. $\nabla_w L = w - \sum_i \alpha_i y_i x_i = 0$ и $\partial L / \partial b = -\sum_i \alpha_i y_i = 0$. $\square$

Теорема 2.4 (Двойственная задача SVM). Подстановка предложения 2.3 в $L(w, b, \alpha)$ даёт

$$\max_{\alpha} \sum_{i=1}^{\ell} \alpha_i - \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \alpha_i \alpha_j y_i y_j (x_i^{\top} x_j) \quad \text{при} \quad \alpha_i \geq 0, \sum_{i=1}^{\ell} \alpha_i y_i = 0.$$

Доказательство. Подставляя $w = \sum_i \alpha_i y_i x_i$ в L ,

$$\frac{1}{2} \|w\|^2 = \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j,$$

$$\sum_i \alpha_i y_i w^{\top} x_i = \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j, \quad \sum_i \alpha_i y_i b = b \sum_i \alpha_i y_i = 0.$$

Собирая,

$$L = \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j - \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j + \sum_i \alpha_i = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^{\top} x_j. \quad \square$$

Двойственная задача – тоже выпуклое квадратичное программирование, но теперь с ℓ переменными α_i и простыми ограничениями (в отличие от прямой задачи с $n + 1$ переменными). Решив её (численно, здесь не обсуждается), восстанавливаем $w^* = \sum_i \alpha_i^* y_i x_i$, а b^* – из любого i с $\alpha_i^* > 0$, для которого ограничение активно: $y_i(w^{*\top} x_i + b^*) = 1 \Rightarrow b^* = y_i - w^{*\top} x_i$ (используем $y_i^2 = 1$).

Определение 2.5 (Опорные векторы). Объекты x_i с $\alpha_i^* > 0$ называются опорными векторами. По условию дополняющей нежёсткости для них $y_i(w^{*\top} x_i + b^*) = 1$ – они лежат ровно на границе полосы. Для объектов с $\alpha_i^* = 0$ ограничение неактивно; они не влияют на решение – ни на w^* (сумма по опорным векторам), ни, следовательно, на классификатор $a(x) = \text{sign}(\sum_i \alpha_i^* y_i x_i^{\top} x + b^*)$.




Рис. 3: Разделяющая прямая (сплошная), границы полосы отступа (пунктир) и опорные векторы (выделены кружком) для примера 2.1 – схематически.

3 Мягкий зазор

Если выборка линейно неразделима (или разделима, но с очень узким отступом из-за выбросов), задача 2.2 не имеет допустимых решений. Вводятся переменные зазора (slack) $\xi_i \geq 0$, допускающие нарушение отступа за плату:

Определение 3.1 (Прямая задача SVM с мягким зазором).

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^{\ell} \xi_i \quad \text{при} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0,$$

где $C > 0$ – параметр, задающий компромисс между шириной полосы и суммарным нарушением отступа.

Утверждение 3.2 (Двойственная задача с мягким зазором). Двойственная задача имеет тот же вид, что и в теореме 2.4, с дополнительным ограничением $\alpha_i \leq C$:

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{при} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0.$$

Доказательство. Лагранжиан теперь $L = \frac{1}{2} \|w\|^2 + C \sum \xi_i - \sum_i \alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i$, $\alpha_i, \mu_i \geq 0$. Условия стационарности по w, b те же, что в предложении 2.3; по ξ_i : $\partial L / \partial \xi_i = C - \alpha_i - \mu_i = 0$, откуда $\mu_i = C - \alpha_i$. Так как $\mu_i \geq 0$, получаем $\alpha_i \leq C$. Слагаемые с ξ_i в L сокращаются: $C\xi_i - \alpha_i\xi_i - \mu_i\xi_i = (C - \alpha_i - \mu_i)\xi_i = 0$, и оставшаяся часть подстановки в точности повторяет вычисление из теоремы 2.4. $\square$

Замечание 3.3. При $C \rightarrow \infty$ нарушения отступа становятся сколь угодно дорогими, и задача сходится к жёсткому зазору. Малые C допускают больше нарушений ради более широкой полосы – ещё один параметр регуляризации, в духе Лекции 2: увеличение C уменьшает смещение и увеличивает разброс решения.

4 Ядра

И двойственная задача (теорема 2.4), и итоговый классификатор зависят от объектов только через скалярные произведения $x_i^\top x_j$ (соответственно $x_i^\top x$). Это позволяет обучать нелинейные разделяющие поверхности, не меняя алгоритм: достаточно заменить скалярное произведение на функцию, вычисляющую скалярное произведение в некотором другом (обычно более многомерном) пространстве признаков.

Определение 4.1 (Ядро). Функция $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ называется ядром, если существует отображение $\varphi : \mathcal{X} \rightarrow H$ в некоторое пространство со скалярным произведением, такое что $K(x, x') = \langle \varphi(x), \varphi(x') \rangle$ для всех $x, x' \in \mathcal{X}$.

Замечание 4.2 (Критерий Мерсера). K является ядром тогда и только тогда, когда для любого конечного набора точек $x_1, \dots, x_\ell$ матрица $\|K(x_i, x_j)\|_{\ell \times \ell}$ симметрична и положительно полуопределена. Мы не доказываем этот факт; достаточно уметь проверять его для конкретных K .

Пример 4.3 (Квадратичное ядро). При $x = (x_1, x_2) \in \mathbb{R}^2$ положим $\varphi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$. Тогда

$$\langle \varphi(x), \varphi(x') \rangle = x_1^2 x_1'^2 + 2x_1 x_2 x_1' x_2' + x_2^2 x_2'^2 = (x_1 x_1' + x_2 x_2')^2 = (x^\top x')^2,$$

то есть $K(x, x') = (x^\top x')^2$ – ядро, соответствующее явному отображению в пространство квадратичных мономов. Более общий факт: для любого $d \in \mathbb{N}$ и $c \geq 0$, $K(x, x') = (x^\top x' + c)^d$ – полиномиальное ядро степени d (соответствующий φ выписывается явно, но громоздок при больших d).

Пример 4.4 (Гауссово (RBF) ядро).

$$K(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right).$$

Соответствующее пространство H бесконечномерно (явного конечномерного φ не существует); тем не менее K вычисляется за $O(n)$ и удовлетворяет критерию Мерсера.

С ядром двойственная задача (теорема 2.4) принимает вид

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad \text{при} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0,$$

а классификатор – $a(x) = \text{sign}(\sum_i \alpha_i^* y_i K(x_i, x) + b^*)$: во всех формулах $x_i^\top x_j$ заменено на $K(x_i, x_j)$ («kernel trick»), явно вычислять φ не требуется.

Заключение

Замечание 4.5. Вне рассмотрения остались: многоклассовое обобщение SVM (один-против-всех или один-против-одного); численные методы решения двойственной задачи (SMO – Sequential Minimal Optimization); выбор C и параметров ядра по данным (скользящий контроль); связь SVM с ERM для потери hinge $\mathcal{L}(a, x, y) = \max(0, 1 - y a(x))$, которая приводит к прямой задаче 3.1 напрямую, без геометрии отступа. Логистическая регрессия и SVM с линейным ядром решают структурно похожую задачу разными методами (гладкая оптимизация против квадратичного программирования) и на практике часто дают близкие разделяющие поверхности.