

Машинное обучение

Лекция 4 — Переобучение и обобщающая способность

Мотивация

В Лекции 1 было показано, что $\mathbb{E}[Q(a, X^\ell)] = R(a)$ для простой выборки: эмпирический риск в среднем равен истинному. Это утверждение – о среднем по случайным выборкам, а не о конкретной выборке X^ℓ , на которой алгоритм $a = \mu(X^\ell)$ ещё и сам зависит от X^ℓ . Крайний пример: алгоритм, запоминая обучающую выборку и выдающий на новом объекте произвольный ответ, имеет $Q(a, X^\ell) = 0$, но $R(a)$ может быть сколь угодно велико. Значит, малость $Q(a, X^\ell)$ сама по себе ничего не говорит о качестве a на новых данных. В этой лекции разбираются: количественное описание разрыва между Q и R (разложение смещение–разброс), практический способ его оценить, не имея доступа к R (скользящий контроль), и теоретическая граница, связывающая разрыв со сложностью модели (VC-размерность).

1 Переобучение

Определение 1.1 (Переобучение). Метод μ переобучается на выборке X^ℓ , если построенный им алгоритм $a = \mu(X^\ell)$ имеет малый эмпирический риск $Q(a, X^\ell)$, но существенно больший истинный риск $R(a)$: $R(a) - Q(a, X^\ell) \gg 0$.

Замечание 1.2. Переобучение – следствие того, что a подбирается по той же выборке, на которой затем измеряется Q : минимизация $Q(a, X^\ell)$ по $a \in A$ находит алгоритм, наилучшим образом согласующийся не только с закономерностью, но и со случайным шумом конкретной выборки. Чем богаче (сложнее) модель A , тем точнее она способна подстроиться под шум – и тем больше типичный разрыв $R(a) - Q(a, X^\ell)$.




Рис. 1: Типичная зависимость эмпирического и истинного риска от сложности модели: Q монотонно убывает, R имеет минимум – разрыв $R(a) - Q(a, X^\ell)$ (переобучение) нарастает правее оптимума.

2 Разложение смещение–разброс

Зафиксируем объект x и рассмотрим регрессию с квадратичной потерей. Пусть истинная зависимость $y = f(x) + \varepsilon$, где шум ε не зависит от x и от обучающей выборки, $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$ (ср. вероятностную модель Лекции 1). Обучающая выборка X^ℓ сама случайна, поэтому построенный по ней алгоритм $a(x) = a_{X^\ell}(x)$ – тоже случайная величина (при фиксированном x , случайность – по X^ℓ).

Теорема 2.1 (Разложение смещение–разброс).

$$\mathbb{E}_{X^\ell, \varepsilon}[(y - a(x))^2] = \underbrace{(f(x) - \mathbb{E}_{X^\ell}[a(x)])^2}_{\text{смещение}^2} + \underbrace{\text{Var}_{X^\ell}(a(x))}_{\text{разброс}} + \underbrace{\sigma^2}_{\text{шум}}.$$

Доказательство. Так как ε не зависит от X^ℓ (а значит, и от $a(x)$) и $\mathbb{E}[\varepsilon] = 0$,

$$\begin{aligned} \mathbb{E}[(y - a(x))^2] &= \mathbb{E}[(f(x) - a(x) + \varepsilon)^2] \\ &= \mathbb{E}[(f(x) - a(x))^2] + 2\mathbb{E}[f(x) - a(x)]\mathbb{E}[\varepsilon] + \mathbb{E}[\varepsilon^2] \\ &= \mathbb{E}[(f(x) - a(x))^2] + \sigma^2. \end{aligned}$$

Обозначим $\bar{a} = \mathbb{E}_{X^\ell}[a(x)]$. Добавляя и вычитая $\bar{a}$,

$$\mathbb{E}[(f(x) - a(x))^2] = \mathbb{E}[(f(x) - \bar{a})^2] + 2(f(x) - \bar{a})\mathbb{E}[\bar{a} - a(x)] + \mathbb{E}[(\bar{a} - a(x))^2].$$

Первое слагаемое – константа $(f(x) - \bar{a})^2$ (смещение в квадрате); среднее слагаемое равно нулю, так как $\mathbb{E}[\bar{a} - a(x)] = \bar{a} - \bar{a} = 0$; последнее – по определению $\text{Var}_{X^\ell}(a(x))$. Складывая с σ^2 , получаем утверждение. $\square$

Замечание 2.2. Смещение (bias) измеряет систематическую ошибку модели: даже усреднив предсказание по всем возможным обучающим выборкам, $\bar{a}$ может не совпадать с $f(x)$ (например, если истинная зависимость нелинейна, а модель линейна). Разброс (variance) измеряет чувствительность $a(x)$ к конкретной обучающей выборке. Простые модели (мало параметров) обычно имеют большое смещение и малый разброс; сложные модели – малое смещение и большой разброс. Переобучение (определение 1.1) – это режим большого разброса: алгоритм точно подстраивается под каждую конкретную выборку, поэтому сильно от неё зависит.

Пример 2.3. Вернёмся к регрессии веса кота по признакам из примера 1.4 Лекции 1. Модель-константа $g(x, \theta) = \theta_0$ имеет малый разброс (её значение слабо зависит от конкретной выборки), но большое смещение, если вес всё же зависит от рациона и возраста. На другом краю – модель высокой степени (например, полином высокой степени от обоих признаков): она способна точно пройти через все восемь точек обучающей выборки ($Q = 0$), но её значение в новой точке сильно зависит от того, какие именно восемь котиков попали в выборку, – большой разброс. Линейная модель из примера 7.2 – промежуточный случай.

Пример 2.4 (Численный пример: две крайности). Пусть истинная зависимость – константа, $f(x) \equiv 4$, шум $\varepsilon \in \{-1, +1\}$ равновероятно (в частности, $\mathbb{E}[\varepsilon] = 0$, $\sigma^2 = \mathbb{E}[\varepsilon^2] = 1$), обучающая выборка состоит из одного наблюдения $y_1 = 4 + \varepsilon_1 \in \{3, 5\}$. Сравним два «игрушечных» метода.

Метод А («запомнить»): $a(x) = y_1$ при любом x . Тогда $\mathbb{E}[a(x)] = \mathbb{E}[y_1] = 4 = f(x)$ – смещение равно 0; а $\text{Var}(a(x)) = \text{Var}(y_1) = \text{Var}(\varepsilon_1) = 1$ – весь разброс перешёл от данных к алгоритму. По теореме 2.1, $\mathbb{E}[(y - a(x))^2] = 0^2 + 1 + 1 = 2$.

Метод В («игнорировать данные»): $a(x) = 0$ при любом x , каким бы ни было y_1 . Тогда $\mathbb{E}[a(x)] = 0$, смещение $f(x) - \mathbb{E}[a(x)] = 4$, а $\text{Var}(a(x)) = 0$ (алгоритм детерминирован, от выборки не зависит). По той же теореме, $\mathbb{E}[(y - a(x))^2] = 4^2 + 0 + 1 = 17$.

Метод А выигрывает у метода В ($2 < 17$): здесь маленький разброс метода В не окупает его огромного смещения. Ни один из этих двух крайних методов не оптимален в общем случае – разумный компромисс (например, усреднение по нескольким наблюдениям вместо одного) уменьшает разброс, почти не увеличивая смещение; управление этим компромиссом явно – в точности роль параметра регуляризации λ из Лекции 2.

3 Скользящий контроль

Разложение смещение–разброс объясняет природу переобучения, но не даёт способа обнаружить его на практике: $f(x)$ и распределение X^ℓ неизвестны, вычислить смещение и разброс нельзя. Работающий на практике приём – не использовать всю выборку для обучения.

Определение 3.1 (Отложенная выборка). Выборка X^L случайно делится на обучающую X^ℓ ($\ell < L$) и контрольную $X^k = X^L \setminus X^\ell$ ($k = L - \ell$). Алгоритм $a = \mu(X^\ell)$ строится только по X^ℓ , а его качество оценивается величиной $Q(a, X^k)$ – эмпирическим риском на объектах, не участвовавших в обучении.

Поскольку X^k не использовалась при построении a , оценка $Q(a, X^k)$ несмещена относительно $R(a)$ в том же смысле, что и утверждение 5.4 Лекции 1 (примененное к паре независимых выборок). Недостаток отложенной выборки – часть данных (X^k) не участвует в обучении, а оценка зависит от случайного разбиения.

Определение 3.2 (k -кратный скользящий контроль). Выборка X^L случайно разбивается на q примерно равных непересекающихся блоков $X_1, \dots, X_q$. Для каждого $n = 1, \dots, q$ строится алгоритм $a_n = \mu(X^L \setminus X_n)$ (обучение на всех блоках, кроме n -го) и вычисляется $Q(a_n, X_n)$. Оценкой скользящего контроля называется

$$\text{CV}(\mu, X^L) = \frac{1}{q} \sum_{n=1}^q Q(a_n, X_n).$$

Пример 3.3 (LOO вручную). Пусть $\mathcal{Y} = \mathbb{R}$, признаков нет ($n = 0$, модель – константа $g(\theta) = \theta_0$, метод – выборочное среднее), выборка из четырёх ответов $y = (2, 4, 6, 8)$, потеря квадратичная. При исключении объекта i метод А предсказывает среднее оставшихся трёх:

исключён	среднее остальных	ошибка ²
$y_1 = 2$	$(4+6+8)/3 = 6$	$(2 - 6)^2 = 16$
$y_2 = 4$	$(2+6+8)/3 \approx 5.33$	$(4 - 5.33)^2 \approx 1.78$
$y_3 = 6$	$(2+4+8)/3 \approx 4.67$	$(6 - 4.67)^2 \approx 1.78$
$y_4 = 8$	$(2+4+6)/3 = 4$	$(8 - 4)^2 = 16$

LOO(метод А) = $(16 + 1.78 + 1.78 + 16)/4 \approx 8.89$. Для сравнения, метод Б, всегда предсказывающий 0 независимо от данных (как в примере 2.4), даёт ошибки $2^2, 4^2, 6^2, 8^2$ на исключённых объектах, LOO(метод Б) = $(4 + 16 + 36 + 64)/4 = 30$. Скользящий контроль, не зная истинного $R(a)$, тем не менее верно улавливает, что метод А (учитывающий данные) лучше метода Б – ровно та же качественная картина, что и точный расчёт через теорему 2.1 в примере 2.4.

Замечание 3.4. При $q = L$ каждый блок состоит из одного объекта – это контроль по отдельным объектам (leave-one-out, LOO); он даёт наименее смещённую, но самую дорогую по вычислениям (нужно построить L алгоритмов) и высокодисперсную оценку. На практике обычно берут $q \in [5, 10]$: каждый алгоритм a_n обучается на достаточно большой части выборки, а оценка усредняется по нескольким разбиениям, что снижает разброс по сравнению с одной отложенной выборкой.

Практический приём: скользящий контроль как инструмент выбора модели. Если модель зависит от гиперпараметра (степень полинома, λ в гребневой регрессии из Лекции 2, C и ядро в SVM из Лекции 3), его выбирают, перебирая сетку значений и находя минимум $CV(\mu_\lambda, X^L)$ по λ – это и есть общая процедура, на которую ссылались Лекции 2 и 3.

4 VC-размерность

Скользящий контроль оценивает обобщающую способность экспериментально. Теоретический вопрос – существуют ли верхние границы на разрыв $R(a) - Q(a, X^\ell)$, зависящие только от сложности модели A и объёма выборки ℓ , но не от неизвестного распределения $p(x, y)$. Первые такие оценки получены В. Н. Вапником и А. Я. Червоненкисом.

Определение 4.1 (Разбиение множеством классификаторов). Пусть A – множество бинарных классификаторов $a : \mathcal{X} \rightarrow \{0, 1\}$. Говорят, что A разбивает (shatters) конечное множество точек $x_1, \dots, x_d \in \mathcal{X}$, если для любой разметки $(y_1, \dots, y_d) \in \{0, 1\}^d$ найдётся $a \in A$ с $a(x_i) = y_i$ при всех i – то есть все 2^d разметок реализуемы.

Определение 4.2 (VC-размерность). VC-размерностью $VCdim(A)$ называется наибольшее d , для которого найдётся набор из d точек, разбиваемый A (или ∞ , если такое d не ограничено).

Пример 4.3. Пусть $\mathcal{X} = \mathbb{R}^2$, A – множество линейных классификаторов $a(x) = [w^\top x + b \geq 0]$ (ср. Лекцию 3). Тогда $VCdim(A) = 3$.

Три точки общего положения (не лежащие на одной прямой) разбиваются: для каждой из $2^3 = 8$ разметок нетрудно провести прямую, отделяющую точки одного класса от другого (включая вырожденные случаи «все одного класса» – прямая, не пересекающая треугольник). Четыре точки разбить нельзя: если одна из них лежит внутри треугольника, образованного тремя другими, то разметка «внутренняя точка – одного класса, все три внешние – другого» нереализуема прямой (внутренняя точка – выпуклая комбинация внешних, и для любой прямой $w^\top x + b$ линейна, значит принимает на внутренней точке значение между значениями на внешних – не может быть строго противоположного знака сразу всем трём). Если же четыре точки в общем положении образуют выпуклый четырёхугольник, не реализуется «разметка крест-накрест» (противоположные вершины одного цвета) – классический пример XOR.

Замечание 4.4 (Теорема Вапника–Червоненкиса, без доказательства). Если $VCdim(A) = d < \infty$, то с вероятностью не менее $1 - \eta$ по случайной простой выборке X^ℓ одновременно для всех $a \in A$

$$R(a) \leq Q(a, X^\ell) + O\left(\sqrt{\frac{d \ln(\ell/d) + \ln(1/\eta)}{\ell}}\right).$$

Мы не доказываем эту оценку (доказательство существенно опирается на комбинаторную лемму Шелаха–Заура и требует отдельного развития), но подчеркнём качественный




Рис. 2: Слева: одна из восьми разметок трёх точек и разделяющая прямая (пунктир) – реализуемы все восемь. Справа: разметка «крест-накрест» четырёх точек – ни одна прямая не отделяет закрашенные вершины от незакрашенных.

смысл: разрыв между R и Q равномерно по всей модели A убывает с ростом ℓ и растёт с ростом $\text{VCdim}(A)$. Модель с бесконечной VC-размерностью (например, алгоритм, запоминающий выборку) не даёт гарантий обобщения ни при каком ℓ – в точности пример из мотивации.

Утверждение 4.5 (VC-размерность конечной модели). Если модель A конечна, то $\text{VCdim}(A) \leq \log_2 |A|$.

Доказательство. Пусть A разбивает набор из d точек. Тогда каждой из 2^d разметок соответствует хотя бы один алгоритм $a \in A$, реализующий её на этих точках, причём разным разметкам – разные алгоритмы (иначе один и тот же a не мог бы одновременно давать два разных набора ответов на одних и тех же точках). Значит, $|A| \geq 2^d$, откуда $d \leq \log_2 |A|$. Так как это верно для наибольшего разбиваемого d , $\text{VCdim}(A) \leq \log_2 |A|$. $\square$

Замечание 4.6. Это объясняет, почему конечные (или зависящие от небольшого числа дискретных решений) модели обобщаются лучше: решающее дерево глубины не более D с n бинарными признаками – конечная модель, и оценка предложения 4.5 даёт нетривиальную (хотя обычно грубую) границу VC-размерности через D и n – пригодится в Лекции 5, где ограничение глубины дерева – один из способов борьбы с переобучением.

5 Принцип структурной минимизации риска

Замечание о теореме Вапника–Червоненкиса подсказывает практическую стратегию выбора не только параметров внутри одной модели (как в скользящем контроле), но и самой модели – если есть несколько моделей разной сложности на выбор.

Определение 5.1 (Структурная минимизация риска). Пусть $A_1 \subset A_2 \subset \dots \subset A_M$ – вложенные модели возрастающей сложности, $\text{VCdim}(A_1) \leq \dots \leq \text{VCdim}(A_M)$. Принцип структурной минимизации риска (structural risk minimization, SRM) состоит в том, чтобы для каждого m найти $a_m = \arg \min_{a \in A_m} Q(a, X^\ell)$, а затем выбрать

$$m^* = \arg \min_{m=1, \dots, M} \left(Q(a_m, X^\ell) + \text{penalty}(\text{VCdim}(A_m), \ell) \right),$$

где penalty – граница из замечания о теореме Вапника–Червоненкиса (или её аналог), растущая по VC-размерности и убывающая по ℓ .

Замечание 5.2. SRM формализует рисунок 1: вместо того чтобы минимизировать только эмпирический риск Q (что всегда приводит к самой сложной модели A_M , так как $Q(a_m, X^\ell)$ не возрастает по m – более широкая модель может только уменьшить минимум), минимизируется верхняя оценка на R , явно штрафующая сложность. Гребневая

регрессия и LASSO (Лекция 2) реализуют похожую идею иначе: вместо дискретного набора вложенных моделей $A_1, \dots, A_M$ они штрафуют норму θ непрерывно, одним параметром λ , так что рост λ играет роль убывания эффективной сложности модели. Оба подхода – частные случаи одной идеи: компенсировать неизвестное $R(a)$ вычислимой величиной, штрафующей сложность.

Заключение

Замечание 5.3. Вне рассмотрения остались: точное доказательство VC-оценки; более точные современные границы (Rademacher complexity, PAC-Bayes); связь регуляризации (Лекция 2) со смещением и разбросом – параметр λ явно управляет компромиссом между ними, что теперь можно связать с теоремой 2.1 количественно. В следующих лекциях скользящий контроль будет систематически использоваться для выбора гиперпараметров моделей: глубины дерева (Лекция 5), ширины окна и числа соседей (Лекция 6).