

Машинное обучение

Лекция 5 — Решающие деревья и композиции алгоритмов

Мотивация

Все модели, рассмотренные до сих пор (Лекции 1–3), были параметрическими и линейными: $g(x, \theta)$ – линейная (или сигмоидная от линейной) функция признаков. Это ограничивает форму разделяющей поверхности или регрессионной зависимости. Решающее дерево – модель другой природы: не формула от θ , а последовательность вопросов об объекте, кусочно-постоянная на итоге. Она умеет представлять сколь угодно сложные зависимости, но именно поэтому особенно склонна к переобучению (Лекция 4) – вопрос борьбы с этим проходит через всю лекцию: сначала для одного дерева (стрижка), затем для композиций многих деревьев (бэггинг, бустинг).

1 Решающее дерево

Определение 1.1 (Решающее дерево). Решающим деревом называется бинарное дерево, в каждой внутренней вершине v которого стоит предикат $[f_{j(v)}(x) < t_v]$ по одному признаку $f_{j(v)}$ с порогом $t_v \in \mathbb{R}$ (для количественного признака) или предикат вида $[f_{j(v)}(x) \in S_v]$ (для номинального), а в каждом листе – прогноз: класс (для классификации) или число (для регрессии). Алгоритм $a(x)$ спускается от корня к листу, на каждой вершине проверяя предикат и переходя в левое или правое поддерево, и возвращает прогноз найденного листа.

Модель дерева фиксированной структуры (заданное дерево с порогом) – кусочно-постоянная функция $x \mapsto \mathcal{Y}$, а множество всех деревьев не параметризуется конечномерным $\theta \in \Theta$ в смысле определения 3.1 Лекции 1 – это модель переменной структуры; методы обучения для неё жадные, не сводятся к ERM в чистом виде.

1.1 Критерии информативности

Пусть R – множество объектов обучающей выборки, попавших в вершину (или лист), $|R|$ – их число.

Определение 1.2 (Энтропийный критерий). Для классификации на K классов пусть $p_k = |\{i \in R : y_i = k\}|/|R|$. Энтропией множества R называется

$$H(R) = - \sum_{k=1}^K p_k \ln p_k$$

(с соглашением $0 \ln 0 = 0$).

Определение 1.3 (Критерий Джини).

$$\text{Gini}(R) = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2.$$

Обе величины неотрицательны и равны нулю тогда и только тогда, когда все объекты R одного класса («чистое» множество); обе максимальны при равномерном распределении классов. Для регрессии аналогом служит дисперсия:

Определение 1.4 (Критерий дисперсии).

$$D(R) = \frac{1}{|R|} \sum_{i \in R} (y_i - \bar{y}_R)^2, \quad \bar{y}_R = \frac{1}{|R|} \sum_{i \in R} y_i.$$

Определение 1.5 (Прирост информации). Пусть предикат в вершине с множеством объектов R разбивает его на $R = R_L \sqcup R_R$. Приростом информации для критерия $\Phi \in \{H, \text{Gini}, D\}$ называется

$$\text{Gain}(R, R_L, R_R) = \Phi(R) - \frac{|R_L|}{|R|} \Phi(R_L) - \frac{|R_R|}{|R|} \Phi(R_R).$$

Утверждение 1.6 (Неотрицательность прироста). Для энтропии и критерия Джини $\text{Gain}(R, R_L, R_R) \geq 0$ для любого разбиения.

Набросок доказательства. Обе функции $\Phi(p) = -\sum p_k \ln p_k$ и $\Phi(p) = 1 - \sum p_k^2$ строго вогнуты по вектору частот $p = (p_1, \dots, p_K)$. Частоты в R – это выпуклая комбинация частот в R_L, R_R с весами $|R_L|/|R|, |R_R|/|R|$ (простая проверка: числа объектов класса k в R равны сумме чисел в R_L и R_R). По определению вогнутости, $\Phi(\frac{|R_L|}{|R|} p^{(L)} + \frac{|R_R|}{|R|} p^{(R)}) \geq \frac{|R_L|}{|R|} \Phi(p^{(L)}) + \frac{|R_R|}{|R|} \Phi(p^{(R)})$, что в точности означает $\text{Gain} \geq 0$. $\square$

1.2 Построение дерева

Дерево строится жадно и рекурсивно: в каждой вершине перебираются все пары (признак, порог), выбирается разбиение, максимизирующее прирост информации, и рекурсия продолжается в обеих ветвях, пока не выполнен критерий останова.

Algorithm 1 Построение дерева (BuildTree)

```

1: procedure BuildTree( $R$ )
2:   if критерий останова выполнен для  $R$  then ▷ напр.,  $|R| < n_{\min}$ , глубина  $\geq d_{\max}$ ,
     или  $\Phi(R) = 0$ 
3:     return лист с прогнозом (класс большинства или  $\bar{y}_R$ )
4:   end if
5:   найти  $(j, t) = \arg \max_{j,t} \text{Gain}(R, R_L(j, t), R_R(j, t))$ , где  $R_L(j, t) = \{x \in R : f_j(x) < t\}$ 
6:   return вершину с предикатом  $[f_j(x) < t]$ , левое поддерево  $\text{BuildTree}(R_L)$ , правое
      $\text{BuildTree}(R_R)$ 
7: end procedure

```

Пример 1.7 (Прирост информации вручную). Пусть в вершине R восемь объектов двух классов: пять «+» и три «-», $p_+ = 5/8$, $p_- = 3/8$. Бинарный признак делит их на R_L

(четыре объекта: три «+», один «-») и R_R (четыре объекта: два «+», два «-»). По критерию Джини:

$$\text{Gini}(R) = 1 - \left(\frac{5}{8}\right)^2 - \left(\frac{3}{8}\right)^2 = 1 - 0.3906 - 0.1406 = 0.4688,$$

$$\text{Gini}(R_L) = 1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2 = 1 - 0.5625 - 0.0625 = 0.375, \quad \text{Gini}(R_R) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5.$$

$$\text{Gain} = 0.4688 - \frac{4}{8} \cdot 0.375 - \frac{4}{8} \cdot 0.5 = 0.4688 - 0.1875 - 0.25 = 0.0313 > 0,$$

как и предсказывает предложение 1.6. Аналогично (с натуральными логарифмами) считается энтропийный критерий: $H(R) \approx 0.661$, $H(R_L) \approx 0.562$, $H(R_R) = \ln 2 \approx 0.693$, прирост $\approx 0.661 - 0.5 \cdot 0.562 - 0.5 \cdot 0.693 \approx 0.034 > 0$ – тот же знак, хотя и другое число.




Рис. 1: Разбиение из примера 1.7: корень и два листа

2 Переобучение и стрижка

По предложению 1.6 прирост информации неотрицателен, и без критерия остановки дерево растёт, пока в каждом листе не останется один объект (или объекты с одинаковыми признаками) – эмпирический риск $Q(a, X^\ell)$ становится равен нулю. Это ровно определение 1.1 Лекции 4: неограниченное дерево – модель с (потенциально) неограниченной сложностью, предельный случай «запоминания выборки».

Замечание 2.1 (Предварительная и последующая стрижка). Предварительная стрижка (pre-pruning) останавливает рост дерева по эвристике: ограничение глубины $d_{\max}$, минимальное число объектов в листе $n_{\min}$, минимальный прирост информации. Недостаток – жадность: разбиение с малым локальным приростом может открывать путь к разбиениям с большим приростом глубже. Последующая стрижка (post-pruning) сначала строит полное дерево, затем отсекает поддеревья, если это не ухудшает (или допустимо ухудшает) качество на контрольной выборке – скользящий контроль из Лекции 4 применяется напрямую: перебираются поддеревья-кандидаты, и выбирается то, что минимизирует CV.

Определение 2.2 (Стрижка по цене сложности). Для полностью выращенного дерева T и параметра $\alpha \geq 0$ ценой сложности называется

$$Q_\alpha(T) = Q(T, X^\ell) + \alpha |\text{leaves}(T)|,$$

где $|\text{leaves}(T)|$ – число листьев. Стрижка по цене сложности выбирает поддерево $T' \subseteq T$, минимизирующее $Q_\alpha(T')$ среди всех поддеревьев с корнем в корне T .

Замечание 2.3. Это в точности принцип структурной минимизации риска (определение 5.1 Лекции 4), применённый к вложенному семейству поддеревьев T , упорядоченных по числу листьев: штраф $\alpha |\text{leaves}(T)|$ играет роль $\text{penalty}(\text{VCdim}, \ell)$ там. Параметр α ,

как и λ в гребневой регрессии (Лекция 2), выбирается скользящим контролем; $\alpha = 0$ не штрафует сложность вовсе (возвращает исходное дерево T), большие α агрессивно стригут дерево вплоть до одного листа (константный прогноз).

3 Бэггинг и случайный лес

Одно дерево, подобранное под конкретную выборку, имеет большой разброс (Лекция 4). Идея бэггинга – усреднить много таких моделей, обученных на слегка разных выборках, чтобы уменьшить разброс, не увеличивая смещение.

Определение 3.1 (Бутстреп). Бутстреп-выборкой размера ℓ называется выборка, полученная из X^ℓ независимым равновероятным выбором ℓ объектов с возвращением (объекты могут повторяться).

Определение 3.2 (Бэггинг). Бэггинг (bagging, bootstrap aggregating) строит B бутстреп-выборок $X_1^\ell, \dots, X_B^\ell$, на каждой обучает алгоритм $a_b = \mu(X_b^\ell)$ (в типичном случае – дерево, дерево не подрезается специально, чтобы иметь малое смещение), и возвращает

$$a(x) = \frac{1}{B} \sum_{b=1}^B a_b(x) \quad (\text{регрессия}), \quad a(x) = \arg \max_k |\{b : a_b(x) = k\}| \quad (\text{классификация, голосование}).$$

Утверждение 3.3 (Разброс усреднённого предсказания). Пусть $a_1(x), \dots, a_B(x)$ – одинаково распределённые случайные величины (по случайности бутстрепа) с $\text{Var}(a_b(x)) = \sigma^2$ и попарной корреляцией $\rho = \text{corr}(a_b(x), a_c(x))$, $b \neq c$, одной и той же для всех пар. Тогда для $\bar{a}(x) = \frac{1}{B} \sum_b a_b(x)$

$$\text{Var}(\bar{a}(x)) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

Доказательство.

$$\text{Var}(\bar{a}(x)) = \frac{1}{B^2} \left(\sum_b \text{Var}(a_b(x)) + \sum_{b \neq c} \text{Cov}(a_b(x), a_c(x)) \right) = \frac{1}{B^2} (B\sigma^2 + B(B-1)\rho\sigma^2) = \frac{\sigma^2}{B} + \frac{B-1}{B}\rho\sigma^2,$$

что и требовалось (перегруппировка слагаемых). $\square$

Пример 3.4. Пусть отдельное дерево имеет разброс $\sigma^2 = 4$ (в единицах y^2), а корреляция между деревьями бэггинга $\rho = 0.5$. При $B = 4$ деревьях

$$\text{Var}(\bar{a}(x)) = 0.5 \cdot 4 + \frac{1-0.5}{4} \cdot 4 = 2 + 0.5 = 2.5,$$

то есть усреднение четырёх деревьев снижает разброс с 4 до 2.5 – заметно, но не в 4 раза (как было бы при $\rho = 0$). Если случайный лес снижает корреляцию до $\rho = 0.2$, тот же расчёт даёт $\text{Var} = 0.2 \cdot 4 + \frac{0.8}{4} \cdot 4 = 0.8 + 0.8 = 1.6$ – дополнительный выигрыш от декоррелированности деревьев.

Замечание 3.5. При $B \rightarrow \infty$ разброс убывает не до нуля, а до $\rho\sigma^2$: полностью устранить его усреднением нельзя, так как деревья a_b , обученные на пересекающихся бутстреп-выборках из одних и тех же данных, коррелированы. Это мотивирует случайный лес (random forest): помимо бутстрепа объектов, в каждой вершине дерева признак для разбиения (шаг 3 алгоритма BuildTree) выбирается не из всех n признаков, а из случайного

подмножества размера $m < n$ (типично $m \approx \sqrt{n}$). Это уменьшает корреляцию ρ между деревьями (заставляя их иногда использовать разные признаки), а значит по предположению 3.3 уменьшает и итоговый разброс, ценой небольшого увеличения смещения отдельных деревьев.

4 Бустинг

Бэггинг строит независимые (по обучающим подвыборкам) модели и усредняет их – уменьшает разброс. Бустинг строит модели последовательно, каждая следующая исправляет ошибки предыдущих, – уменьшает смещение.

Рассмотрим классификацию, $\mathcal{Y} = \{-1, +1\}$ (как в Лекции 3). Пусть $b_1, \dots, b_T$ – слабые классификаторы (каждый лишь немного лучше случайного угадывания), и итоговый алгоритм ищется в виде $a(x) = \text{sign}(\sum_{t=1}^T \alpha_t b_t(x))$.

Определение 4.1 (Экспоненциальная потеря).

$$\mathcal{L}(a, x, y) = e^{-y F(x)}, \quad F(x) = \sum_{t=1}^T \alpha_t b_t(x).$$

AdaBoost минимизирует эмпирический риск для этой потери жадно, пошагово (forward stagewise): на шаге t уже построенная сумма $F_{t-1}(x) = \sum_{s < t} \alpha_s b_s(x)$ не меняется, и ищутся только новые α_t, b_t .

Теорема 4.2 (Вес слабого классификатора в AdaBoost). Пусть на шаге t веса объектов $w_i = \exp(-y_i F_{t-1}(x_i))$, слабый классификатор b_t фиксирован, и $\text{err}_t = \sum_{i: b_t(x_i) \neq y_i} w_i / \sum_{i=1}^{\ell} w_i$ – его взвешенная частота ошибок. Тогда $\alpha_t = \arg \min_{\alpha} \sum_i w_i e^{-\alpha y_i b_t(x_i)}$ равен

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \text{err}_t}{\text{err}_t}.$$

Доказательство. Обозначим $W = \sum_i w_i$. Так как $y_i b_t(x_i) \in \{-1, +1\}$, сумма разбивается на верно и неверно классифицированные объекты:

$$\sum_i w_i e^{-\alpha y_i b_t(x_i)} = e^{-\alpha} \sum_{i: b_t(x_i)=y_i} w_i + e^{\alpha} \sum_{i: b_t(x_i) \neq y_i} w_i = W[(1 - \text{err}_t)e^{-\alpha} + \text{err}_t e^{\alpha}].$$

Дифференцируя по α и приравнивая нулю: $-(1 - \text{err}_t)e^{-\alpha} + \text{err}_t e^{\alpha} = 0 \Rightarrow e^{2\alpha} = (1 - \text{err}_t)/\text{err}_t$, откуда следует утверждение (вторая производная $W[(1 - \text{err}_t)e^{-\alpha} + \text{err}_t e^{\alpha}] > 0$ – это минимум). $\square$

Замечание 4.3. Формула осмысленна при $\text{err}_t < 1/2$ (это и есть требование «слабости» – чуть лучше случайного угадывания): тогда $\alpha_t > 0$, и чем точнее b_t , тем больше его вес в сумме. После вычисления α_t веса объектов обновляются, $w_i \leftarrow w_i \exp(-\alpha_t y_i b_t(x_i))$ (с последующей нормировкой $\sum w_i = 1$) – ошибочно классифицированные b_t объекты получают больший вес, и следующий слабый классификатор b_{t+1} обучается уделять им больше внимания.

Пример 4.4 (Один шаг AdaBoost вручную). Три точки на прямой: $x_1 = 1, y_1 = +1$; $x_2 = 2, y_2 = -1$; $x_3 = 3, y_3 = +1$, начальные веса равномерны: $w_1 = w_2 = w_3 = 1/3$. Пусть слабый классификатор $b_1(x) = \text{sign}(x - 2.5)$ (то есть -1 при $x < 2.5$ и $+1$ при

$x \geq 2.5$). Тогда $b_1(1) = -1$ (неверно, истинный класс $+1$), $b_1(2) = -1$ (верно), $b_1(3) = +1$ (верно) – ошибается только на x_1 , значит $\text{err}_1 = w_1/(w_1+w_2+w_3) = 1/3$. По теореме 4.2,

$$\alpha_1 = \frac{1}{2} \ln \frac{1 - 1/3}{1/3} = \frac{1}{2} \ln 2 \approx 0.347.$$

Обновление весов, $w_i \leftarrow w_i \exp(-\alpha_1 y_i b_1(x_i))$: для x_1 (ошибка) множитель $e^{\alpha_1} = \sqrt{2}$, для x_2, x_3 (верно) множитель $e^{-\alpha_1} = 1/\sqrt{2}$. До нормировки: $w_1 = \frac{1}{3}\sqrt{2}$, $w_2 = w_3 = \frac{1}{3} \cdot \frac{1}{\sqrt{2}}$, сумма $= \frac{1}{3}(\sqrt{2} + \sqrt{2}) = \frac{2\sqrt{2}}{3}$. После нормировки – на удивление круглые числа:

$$w_1 = \frac{\sqrt{2}/3}{2\sqrt{2}/3} = \frac{1}{2}, \quad w_2 = w_3 = \frac{1/(3\sqrt{2})}{2\sqrt{2}/3} = \frac{1}{4}.$$

Вес единственного ошибочно классифицированного объекта x_1 вырос с $1/3$ до $1/2$: следующий слабый классификатор b_2 будет вынужден уделить ему больше внимания.

Замечание 4.5 (Градиентный бустинг). AdaBoost – частный случай общей схемы: на шаге t ищется b_t , приближающий антиградиент функции потерь по текущим предсказаниям $F_{t-1}(x_i)$ (для экспоненциальной потери это в точности эквивалентно теореме 4.2; в общем случае деревья b_t обучаются приближать $-\partial \mathcal{L}(F_{t-1}(x_i), y_i)/\partial F_{t-1}(x_i)$ методом наименьших квадратов). Это градиентный спуск (Лекция 2) не в пространстве параметров θ , а в пространстве функций F : каждый шаг $F_t = F_{t-1} + \alpha_t b_t$ сдвигает F в направлении убывания эмпирического риска.

Заключение

Замечание 4.6. Вне рассмотрения остались: точный вывод градиентного бустинга для произвольной гладкой потери; практические ускорения (гистограммные методы, регуляризация числа листьев – XGBoost, LightGBM); важность признаков (feature importance) как побочный продукт обучения леса. В следующей лекции – метрические методы классификации, где, в отличие от деревьев, вовсе нет явно обучаемых параметров.