

# Машинное обучение

## Лекция 6 — Метрические и байесовские методы классификации

### Мотивация

Линейные модели (Лекции 1–3) и деревья (Лекция 5) явно обучают параметры (веса  $\theta$  или структуру дерева) по выборке, а затем применяют полученный алгоритм к новым объектам, уже не обращаясь к обучающей выборке напрямую. В этой лекции – два принципиально иных подхода. Метрические методы (§§1–3) вовсе не обучают параметры: решение для нового объекта  $x$  принимается непосредственно по обучающим объектам, ближайшим к  $x$ , в предположении, что близкие объекты имеют близкие ответы. Байесовские методы (§§4–6), напротив, обучают не разделяющую границу, а полную вероятностную модель данных  $p(x, y)$ , из которой граница – лишь следствие.

### 1 Обобщённый метрический классификатор

Пусть на  $\mathcal{X}$  задана метрика  $\rho(x, x')$ . Для объекта  $x$  упорядочим обучающую выборку по возрастанию расстояния до  $x$ :  $\rho(x, x_{(1)}) \leq \dots \leq \rho(x, x_{(\ell)})$ , где  $x_{(i)}$  – объект на  $i$ -м месте (с ответом  $y_{(i)}$ ).

Определение 1.1 (Обобщённый метрический классификатор).

$$\Gamma_y(x) = \sum_{i=1}^{\ell} [y_{(i)} = y] w(i, x), \quad a(x) = \arg \max_{y \in \mathcal{Y}} \Gamma_y(x),$$

где  $w(i, x) \geq 0$  – вес, убывающий по  $i$ .

Пример 1.2 (Частные случаи).  $k$  ближайших соседей ( $k$ NN):  $w(i, x) = [i \leq k]$ . Метод окна Парзена:  $w(i, x) = K(\rho(x, x_{(i)})/h)$ , где  $h > 0$  – ширина окна,  $K$  – невозрастающая на  $[0, \infty)$  функция ядра (например,  $K(r) = [r \leq 1]$  – прямоугольное окно, или  $K(r) = e^{-r^2/2}$  – гауссовское). Вариант переменной ширины:  $w(i, x) = K(\rho(x, x_{(i)})/\rho(x, x_{(k+1)}))$  – ширина подстраивается под локальную плотность объектов. Метод потенциальных функций суммирует по всем объектам с обучаемыми весами («зарядами»)  $\gamma_i \geq 0$ :  $w(x, x_i) = \gamma_i K(\rho(x, x_i)/h)$ ; заряды подбираются итеративно (штраф  $\gamma_i \leftarrow \gamma_i + 1$  при ошибке на  $x_i$ ).

### 2 Выбор параметров скользящим контролем

Качество  $k$ NN и окна Парзена существенно зависит от  $k$  (или  $h$ ): малые  $k$  – сложная модель с малым смещением и большим разбросом (переобучение, Лекция 4); большие  $k$  – простая модель, сглаживающая границу вплоть до предсказания самого частого класса при  $k = \ell$ . Оптимальное значение выбирается по скользящему контролю (определение 3.2 Лекции 4), как правило – контролем с исключением объектов по одному (LOO).

**Практический приём: эффективное вычисление LOO для  $k$ NN.** Наивно LOO требует  $\ell$  раз заново находить  $k$  ближайших соседей –  $O(\ell^2)$  на одно значение  $k$ . Но если заранее для каждого  $x_i$  отсортировать остальные объекты по расстоянию, ответ  $k$ NN при исключении  $x_i$

для всех  $k$  одновременно вычисляется по этому списку за  $O(\ell)$  – LOO( $k$ ) для всех  $k = 1, \dots, \ell$  считается за  $O(\ell^2)$  суммарно.

Пример 2.1. Пять обучающих точек на плоскости (Пример 2.1 Лекции 1:  $y = 1$ , если  $x_2 > x_1$ ):  $x_1 = (1, 3), y_1=1$ ;  $x_2 = (0, 1), y_2=0$ ;  $x_3 = (2, 2.5), y_3=1$ ;  $x_4 = (3, 1), y_4=0$ ;  $x_5 = (1, 0.5), y_5=0$ . Классифицируем  $x = (1.5, 2)$  методом 3NN с евклидовой метрикой:  $\rho(x, x_1) \approx 1.12$ ,  $\rho(x, x_2) \approx 1.80$ ,  $\rho(x, x_3) \approx 0.71$ ,  $\rho(x, x_4) \approx 1.80$ ,  $\rho(x, x_5) \approx 1.58$ . Три ближайших –  $x_3, x_1, x_5$  с ответами 1, 1, 0; большинство – класс 1, значит  $a(x) = 1$  (верно:  $2 > 1.5$ ).




Рис. 1: Пример 2.1: окружность радиуса  $\rho(x, x_5) \approx 1.58$  отделяет трёх ближайших соседей ( $x_3, x_1$  – класс 1;  $x_5$  – класс 0) от остальных

### 3 Отступ и отбор эталонов (STOLP)

Определение 3.1 (Отступ). Отступом объекта  $x_i$  называется  $M(x_i) = \Gamma_{y_i}(x_i) - \max_{y \neq y_i} \Gamma_y(x_i)$ , где  $\Gamma_y(x_i)$  вычисляется по всем объектам выборки, кроме самого  $x_i$  (leave-one-out).

Объекты с  $M(x_i) < 0$  – шумовые (среди объектов чужого класса, вероятно выбросы); с  $M(x_i)$ , близким к нулю сверху, – пограничные (информативны для границы); с большим  $M(x_i) > 0$  – избыточные (глубоко внутри класса).

Пример 3.2. Посчитаем отступ объекта  $x_2 = (0, 1), y_2 = 0$  из примера 2.1 при  $k = 3$ . Расстояния от  $x_2$  до остальных:  $\rho(x_2, x_5) \approx 1.12$ ,  $\rho(x_2, x_1) \approx 2.24$ ,  $\rho(x_2, x_3) \approx 2.50$ ,  $\rho(x_2, x_4) = 3$ . Три ближайших (без  $x_2$ ) –  $x_5$  (класс 0),  $x_1, x_3$  (класс 1), так что  $\Gamma_0(x_2) = 1$ ,  $\Gamma_1(x_2) = 2$ , и

$$M(x_2) = \Gamma_0(x_2) - \Gamma_1(x_2) = 1 - 2 = -1 < 0.$$

Отрицательный отступ означает, что при  $k = 3$  ближайшие соседи  $x_2$  чаще относятся к чужому классу – на первом шаге STOLP такой объект был бы удалён как шумовой (или как лежащий глубоко на территории соседнего класса).

Замечание 3.3. STOLP одновременно чистит выборку от шума и сжимает её: эталонное множество  $\Omega$  обычно много меньше исходной выборки, но даёт то же качество – это существенно ускоряет применение метрических методов, где классификация нового объекта требует хранить и перебирать всю обучающую выборку (в отличие от линейных моделей, где достаточно вектора  $\theta$ ).

---

Algorithm 1 STOLP (отбор эталонных объектов)

---

```

1: удалить объекты с  $M(x_i) < 0$  (шум);  $\Omega \leftarrow \emptyset$ 
2: for каждого класса  $y$  do
3:   добавить в  $\Omega$  объект класса  $y$  с наибольшим отступом
4: end for
5: repeat
6:   по текущему  $\Omega$  найти неверно классифицируемый  $x_i$  с наименьшим отступом;
   добавить его в  $\Omega$ 
7: until все объекты классифицируются по  $\Omega$  верно (или достигнут лимит  $|\Omega|$ )
8: return  $\Omega$ 

```

---



---

4 Байесовское решающее правило

---

Метрические методы не используют явную модель данных. Переходим к противоположному подходу: пусть, как в Лекции 1, задано распределение  $p(x, y)$  на  $\mathcal{X} \times \mathcal{Y}$ ,  $\mathcal{Y} = \{1, \dots, K\}$ , и, в отличие от Лекции 1, дана общая матрица потерь  $\lambda(y, y') \geq 0$  – плата за ответ  $y'$  при истинном классе  $y$  ( $\lambda(y, y) = 0$ ).

Определение 4.1 (Условный риск). Для объекта  $x$  и ответа  $y'$ :  $\rho(y', x) = \sum_{y=1}^K \lambda(y, y') p(y | x)$ .

Теорема 4.2 (Байесовское решающее правило). Алгоритм  $a^*(x) = \arg \min_{y' \in \mathcal{Y}} \rho(y', x)$  минимизирует истинный риск  $R(a) = \mathbb{E}_{(x,y) \sim p} \lambda(y, a(x))$  среди всех измеримых  $a : \mathcal{X} \rightarrow \mathcal{Y}$ .

Доказательство. По формуле полного математического ожидания,  $R(a) = \mathbb{E}_x[\mathbb{E}_{y|x} \lambda(y, a(x))] = \mathbb{E}_x[\rho(a(x), x)]$ . Значение  $a(x)$  можно выбирать независимо для каждого  $x$ , и  $\rho(a(x), x) \geq \rho(a^*(x), x)$  по определению  $a^*$ ; значит  $\mathbb{E}_x[\rho(a(x), x)] \geq \mathbb{E}_x[\rho(a^*(x), x)] = R(a^*)$  для любого  $a$ .  $\square$

Следствие 4.3 (Правило максимума апостериорной вероятности). Для 0/1-потери  $\lambda(y, y') = [y \neq y']$ :  $a^*(x) = \arg \max_{y \in \mathcal{Y}} p(y | x)$ .

Доказательство.  $\rho(y', x) = \sum_{y \neq y'} p(y | x) = 1 - p(y' | x)$ , минимизация по  $y'$  равносильна максимизации  $p(y' | x)$ .  $\square$

По формуле Байеса  $p(y | x) = p(x | y)p(y)/p(x)$ , а  $p(x)$  от  $y$  не зависит, поэтому  $a^*(x) = \arg \max_y p(x | y)p(y)$ : оцениваем по выборке априорные вероятности  $p(y)$  (доли классов) и функции правдоподобия классов  $p(x | y)$ . Способ моделирования  $p(x | y)$  отличает конкретные методы далее.

---

5 Наивный байесовский классификатор

---

Оценивать  $p(x | y)$  напрямую для  $x = (f_1(x), \dots, f_n(x)) \in \mathbb{R}^n$  трудно – совместное распределение  $n$  признаков. Наивный Байес предполагает условную независимость:  $p(x | y) = \prod_{j=1}^n p(f_j(x) | y)$ , откуда

Определение 5.1 (Наивный байесовский классификатор).

$$a(x) = \arg \max_{y \in \mathcal{Y}} \left( \ln p(y) + \sum_{j=1}^n \ln p(f_j(x) | y) \right).$$

Одномерные  $p(f_j(x) | y)$  оценить по выборке несравнимо проще совместной  $n$ -мерной: для номинального признака – доля объектов класса  $y$  с данным значением; для количественного – например,  $f_j | y \sim \mathcal{N}(\mu_{jy}, \sigma_{jy}^2)$  по выборочным среднему и дисперсии среди объектов класса  $y$ .

Пример 5.2 (Наивный Байес вручную). Пусть  $\mathcal{Y} = \{0, 1\}$ ,  $p(y=0) = p(y=1) = 0.5$ , и два бинарных признака с оценёнными по выборке вероятностями  $p(f_1=1 | y=1) = 0.8$ ,  $p(f_2=1 | y=1) = 0.6$ ,  $p(f_1=1 | y=0) = 0.3$ ,  $p(f_2=1 | y=0) = 0.4$ . Для нового объекта с  $f_1(x) = 1, f_2(x) = 1$ :

$$p(y=1) p(f_1=1 | y=1) p(f_2=1 | y=1) = 0.5 \cdot 0.8 \cdot 0.6 = 0.24,$$

$$p(y=0) p(f_1=1 | y=0) p(f_2=1 | y=0) = 0.5 \cdot 0.3 \cdot 0.4 = 0.06.$$

Так как  $0.24 > 0.06$ , наивный Байес выдаёт  $a(x) = 1$  (можно нормировать:  $p(y=1 | x) \approx 0.24 / (0.24 + 0.06) = 0.8$ ).

Замечание 5.3 (Почему «наивный»). Независимость признаков внутри класса почти никогда не выполняется точно (например, для коррелированных признаков вроде «число банок корма» и «вес» из примера 1.4 Лекции 1). Тем не менее классификатор часто работает хорошо: для  $\arg \max_y$  важен не точный масштаб  $p(x | y)$ , а то, у какого класса он больше, и ошибки масштаба от нарушения независимости часто одинаково искажают оценки всех классов, не меняя  $\arg \max$ .

Утверждение 5.4 (Наивный Байес с бинарными признаками – это логистическая регрессия). Пусть  $\mathcal{Y} = \{0, 1\}$ , признаки бинарны,  $f_j(x) \in \{0, 1\}$ , и  $\theta_{jk} = p(f_j=1 | y=k) \in (0, 1)$ . Тогда апостериорная вероятность наивного Байеса имеет вид  $p(y=1 | x) = \sigma(w^T f(x) + b)$  для некоторых  $w \in \mathbb{R}^n, b \in \mathbb{R}$ , где  $f(x) = (f_1(x), \dots, f_n(x))$  – в точности модель логистической регрессии (определение 1.2 Лекции 3).

Доказательство. По формуле Байеса,  $p(y=1 | x) = 1 / (1 + e^{-z}) = \sigma(z)$ , где  $z = \ln \frac{p(x|y=1)p(y=1)}{p(x|y=0)p(y=0)}$ . Для каждого признака  $p(f_j | y=k) = \theta_{jk}^{f_j} (1 - \theta_{jk})^{1-f_j}$ , и

$$\ln \frac{p(f_j | y=1)}{p(f_j | y=0)} = f_j \ln \frac{\theta_{j1}}{\theta_{j0}} + (1 - f_j) \ln \frac{1 - \theta_{j1}}{1 - \theta_{j0}} = f_j \underbrace{\ln \frac{\theta_{j1}(1 - \theta_{j0})}{\theta_{j0}(1 - \theta_{j1})}}_{w_j} + \ln \frac{1 - \theta_{j1}}{1 - \theta_{j0}}.$$

Суммируя по  $j$  (условная независимость) и добавляя  $\ln \frac{p(y=1)}{p(y=0)}$ , получаем  $z = \sum_j w_j f_j(x) + b = w^T f(x) + b$  с  $b = \ln \frac{p(y=1)}{p(y=0)} + \sum_j \ln \frac{1 - \theta_{j1}}{1 - \theta_{j0}}$  – линейная функция признаков, что и требовалось.  $\square$

Замечание 5.5. Тот же вывод (с более громоздкой алгеброй) работает для количественных признаков с гауссовской  $p(f_j | y)$  при условии одинаковой дисперсии  $\sigma_j^2$  для обоих классов – условие, аналогичное общей  $\Sigma$  в LDA ниже. Общая картина: логистическая регрессия – дискриминативная модель с линейной границей; наивный Байес и LDA – две разные генеративные модели, каждая из которых при определённых предположениях о  $p(x | y)$  приводит к той же самой линейной по признакам форме  $p(y | x) = \sigma(w^T x + b)$ , но оценивает  $w, b$  по-другому.

## 6 Нормальный дискриминантный анализ

Смоделируем  $n$ -мерное распределение внутри класса как многомерное нормальное:  $p(x | y=k) = \mathcal{N}(x; \mu_k, \Sigma_k)$ , где

$$\mathcal{N}(x; \mu, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$$

( $\Sigma_k$  – симметричная положительно определённая ковариационная матрица; определитель  $|\Sigma_k|$  вычисляется, как в Лекции 1, где мы дифференцировали определитель). Параметры  $\mu_k, \Sigma_k, p(y=k)$  оцениваются выборочными аналогами по объектам класса  $k$ .

Определение 6.1 (Квадратичный дискриминант (QDA)). С  $\delta_k(x) = \ln p(y=k) + \ln p(x | y=k)$  (следствие 4.3),

$$\delta_k(x) = \ln p(y=k) - \frac{1}{2} \ln |\Sigma_k| - \frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k), \quad a(x) = \arg \max_k \delta_k(x).$$

При различных  $\Sigma_k$  граница  $\{\delta_k(x) = \delta_j(x)\}$  – квадратичная поверхность (эллипс, парабола или гипербола при  $n = 2$ ).

Теорема 6.2 (LDA: общая ковариация даёт линейную границу). Если  $\Sigma_k = \Sigma$  одна и та же для всех классов, то для любых  $j, k$  разность  $\delta_k(x) - \delta_j(x)$  – линейная функция  $x$ .

Доказательство.  $(x - \mu_k)^T \Sigma^{-1}(x - \mu_k) = x^T \Sigma^{-1}x - 2\mu_k^T \Sigma^{-1}x + \mu_k^T \Sigma^{-1}\mu_k$ . Слагаемые  $-\frac{1}{2} \ln |\Sigma|$  и  $-\frac{1}{2}x^T \Sigma^{-1}x$  не зависят от  $k$  (общая  $\Sigma$ ) и сокращаются при вычитании:

$$\delta_k(x) - \delta_j(x) = \ln \frac{p(y=k)}{p(y=j)} + (\mu_k - \mu_j)^T \Sigma^{-1}x - \frac{1}{2}\mu_k^T \Sigma^{-1}\mu_k + \frac{1}{2}\mu_j^T \Sigma^{-1}\mu_j,$$

линейная функция  $x$  с коэффициентом  $w = \Sigma^{-1}(\mu_k - \mu_j)$ . □




Рис. 2: Схематическая иллюстрация LDA: одинаковая форма (общая  $\Sigma$ ) и ориентация эллипсов правдоподобия при разных центрах  $\mu_0, \mu_1$  дают линейную границу (пунктир)

Замечание 6.3 (Сопоставление с Лекцией 3). Теорема 6.2 даёт классификатор вида  $a(x) = \text{sign}(w^T x + b)$  из Лекции 3, но выведенный из другого принципа: там граница подбиралась дискриминативно (максимизацией отступа или минимизацией логистической потери), здесь – как следствие генеративной модели данных. Если предположение о нормальности  $p(x | y)$  верно, LDA даёт более точную (при том же объёме выборки) оценку границы, чем логистическая регрессия; если неверно – может ей проигрывать, так как логистическая регрессия не предполагает ничего о  $p(x | y)$ .

Замечание 6.4 (Связь с метрическими методами). Метод окна Парзена (пример 1.2) можно переосмыслить байесовски: величина  $\hat{p}(x | y) = \frac{1}{\ell_y h^n} \sum_{i: y_i = y} K(\rho(x, x_i)/h)$  (где  $\ell_y$  – число обучающих объектов класса  $y$ ) – это непараметрическая оценка плотности  $p(x | y)$ , не требующая предположений о её форме (в отличие от  $\mathcal{N}(\mu_k, \Sigma_k)$  этого параграфа). Подставив  $\hat{p}(x | y)$  в байесовское правило (следствие 4.3) вместо параметрической плотности, получаем классификатор, при подходящем ядре  $K$  в точности совпадающий с обобщённым метрическим классификатором (определение 1.1) – метрические и байесовские методы этой лекции не так уж независимы: первые можно рассматривать как байесовские методы с непараметрической, а вторые – с параметрической оценкой  $p(x | y)$ .

## Заключение

Замечание 6.5. Вне рассмотрения остались: обучение метрики (metric learning) и проклятие размерности для метрических методов; восстановление плотности непараметрическими методами (аналог окна Парзена, применённый к оценке  $p(x | y)$ ); регуляризованный дискриминантный анализ (промежуточный между LDA и QDA); связь наивного Байеса с текстовой классификацией. В следующей лекции – кластеризация и ЕМ-алгоритм, где класс объекта не наблюдается уже на обучающей выборке.