

Машинное обучение

Лекция 7 — Кластеризация и ЕМ-алгоритм

Мотивация

Все методы Лекций 1–6 решали задачу обучения по прецедентам: в обучающей выборке $X^\ell = (x_i, y_i)_{i=1}^\ell$ каждому объекту сопоставлен ответ. В этой лекции – задачи обучения без учителя: дана лишь выборка объектов $X^\ell = (x_i)_{i=1}^\ell$, без ответов, и требуется найти в ней структуру. Начнём с простого и не вероятностного метода (K -средних), затем обобщим его до вероятностной модели (смесь распределений, ЕМ-алгоритм) и увидим, что первый – предельный случай второго. Завершим темой, устроенной совсем иначе (иерархическая кластеризация).

1 Метод K -средних

Определение 1.1 (Функционал качества кластеризации). Пусть $X^\ell \subset \mathbb{R}^n$, число кластеров K фиксировано. Для разбиения, заданного отображением $c : \{1, \dots, \ell\} \rightarrow \{1, \dots, K\}$ и центров $\mu_1, \dots, \mu_K \in \mathbb{R}^n$,

$$J(c, \mu) = \sum_{i=1}^{\ell} \|x_i - \mu_{c(i)}\|^2.$$

Метод K -средних ищет $(c^*, \mu^*) = \arg \min_{c, \mu} J(c, \mu)$.

Совместная минимизация по c (дискретной) и μ не сводится к градиентным методам Лекции 2 напрямую; используется покоординатный спуск.

Algorithm 1 K -средних (алгоритм Ллойда)

- 1: инициализировать $\mu_1, \dots, \mu_K$ (например, K случайных объектов выборки)
- 2: repeat
- 3: отнесение: $c(i) \leftarrow \arg \min_k \|x_i - \mu_k\|^2$ для каждого i
- 4: пересчёт: $\mu_k \leftarrow \frac{1}{|\{i: c(i)=k\}|} \sum_{i: c(i)=k} x_i$ для каждого k
- 5: until разбиение c не меняется

Утверждение 1.2 (Монотонность алгоритма Ллойда). Каждый из двух шагов алгоритма не увеличивает $J(c, \mu)$.

Доказательство. Отнесение. При фиксированных μ , $J = \sum_i \|x_i - \mu_{c(i)}\|^2$ – сумма независимых по i слагаемых, каждое минимизируется новым $c(i) = \arg \min_k \|x_i - \mu_k\|^2$.

Пересчёт. При фиксированном c , $J = \sum_k \sum_{i: c(i)=k} \|x_i - \mu_k\|^2$ распадается по кластерам; для каждого k приравниваем градиент по μ_k нулю. По формуле градиента квадратичной формы (предложение 6.2 Лекции 1, применённой к $w = x_i - \mu_k$ с единичной матрицей), каждое слагаемое даёт $\nabla_{\mu_k} \|x_i - \mu_k\|^2 = -2(x_i - \mu_k)$, так что $\sum_{i: c(i)=k} (-2)(x_i - \mu_k) = 0 \Rightarrow \mu_k = \frac{1}{|\{i: c(i)=k\}|} \sum_{i: c(i)=k} x_i$ – новое значение μ_k ; вторая производная $2|\{i : c(i) = k\}| > 0$, минимум. $\square$

Замечание 1.3. Разбиений с конечное число ($\leq K^\ell$), а J не возрастает и не может принимать одно и то же значение на разных разбиениях бесконечно долго без заикливания – при конечном числе разбиений это невозможно, значит алгоритм сходится за конечное число шагов, но лишь к локальному минимуму J , зависящему от инициализации. На практике запускают несколько раз с разных случайных $\mu^{(0)}$ и выбирают разбиение с наименьшим J . Число кластеров K – гиперпараметр: $J(c^*, \mu^*)$ монотонно убывает по K (при $K = \ell$ равно нулю), поэтому минимизировать J по K бессмысленно (в духе переобучения, Лекция 4); используют эвристики вроде «метода локтя».

Замечание 1.4 (Вычислительная сложность). Одна итерация K -средних требует $O(K\ell n)$ действий (расстояние от каждого из ℓ объектов до каждого из K центров в $\mathbb{R}^n$), и на практике сходимость наступает за небольшое число итераций – почти линейная зависимость от ℓ . Наивная реализация агломеративной кластеризации (§3) заново ищет пару ближайших кластеров на каждом из $\ell - 1$ шагов слияния среди $O(\ell^2)$ пар, то есть $O(\ell^3)$ суммарно (с очередью с приоритетами – $O(\ell^2 \log \ell)$); при больших ℓ это заметно дороже K -средних, что на практике часто перевешивает удобство не фиксировать K заранее.

Пример 1.5 (K -средних вручную). Четыре точки $p_1 = (1, 1)$, $p_2 = (2, 1)$, $p_3 = (4, 3)$, $p_4 = (5, 3)$, $K = 2$, начальные центры $\mu_1^{(0)} = (1, 1)$, $\mu_2^{(0)} = (5, 3)$.

Отнесение: $\rho(p_1, \mu_1) = 0 < \rho(p_1, \mu_2) = \sqrt{20} - p_1 \rightarrow 1$; аналогично $\rho(p_2, \mu_1) = 1 < \rho(p_2, \mu_2) = \sqrt{13} - p_2 \rightarrow 1$; $\rho(p_3, \mu_2) = 1 < \rho(p_3, \mu_1) = \sqrt{13} - p_3 \rightarrow 2$; $\rho(p_4, \mu_2) = 0 - p_4 \rightarrow 2$. Кластеры: $\{p_1, p_2\}$ и $\{p_3, p_4\}$.

Пересчёт: $\mu_1^{(1)} = \frac{1}{2}(p_1 + p_2) = (1.5, 1)$, $\mu_2^{(1)} = \frac{1}{2}(p_3 + p_4) = (4.5, 3)$.

Проверка следующего отнесения с новыми центрами не меняет разбиение (легко проверить: p_1, p_2 по-прежнему ближе к $\mu_1^{(1)}$, p_3, p_4 – к $\mu_2^{(1)}$) – алгоритм сошёлся за одну итерацию.




Рис. 1: Пример 1.5: два кластера и их центры после одной итерации

2 Смеси распределений и ЕМ-алгоритм

Метод K -средних жёстко относит каждый объект к одному кластеру. Обобщим его вероятностно: пусть данные порождены смесью K распределений, и объект может принадлежать компоненте с некоторой вероятностью, а не однозначно.

|

Определение 2.1 (Смесь распределений).

$$p(x; \Theta) = \sum_{k=1}^K \pi_k p(x; \theta_k), \quad \pi_k \geq 0, \quad \sum_{k=1}^K \pi_k = 1,$$

$\Theta = (\pi_1, \dots, \pi_K, \theta_1, \dots, \theta_K)$, π_k – веса компонент.

Вводя латентную переменную $z \in \{1, \dots, K\}$ ($p(z=k) = \pi_k$, $p(x | z=k) = p(x; \theta_k)$), по выборке $x_1, \dots, x_\ell$ (значения z_i не наблюдаются) требуется оценить Θ методом максимума правдоподобия (Лекция 1):

$$\ell(\Theta) = \sum_{i=1}^{\ell} \ln \left(\sum_{k=1}^K \pi_k p(x_i; \theta_k) \right).$$

Логарифм суммы не позволяет, как в Лекции 1, свести $\arg \max_{\Theta} \ell(\Theta)$ к раздельной оптимизации.

Практический приём: неравенство Йенсена. Для вогнутой φ (в частности, $\varphi = \ln$) и распределения $q(z)$, $z = 1, \dots, K$: $\varphi(\sum_z q(z)\xi(z)) \geq \sum_z q(z)\varphi(\xi(z))$, с равенством тогда и только тогда, когда $\xi(z)$ не зависит от z (на носителе q).

Для произвольного распределения $q_i(z)$ (своего для каждого x_i),

$$\ln p(x_i; \Theta) = \ln \sum_z q_i(z) \frac{\pi_z p(x_i; \theta_z)}{q_i(z)} \geq \sum_z q_i(z) \ln \frac{\pi_z p(x_i; \theta_z)}{q_i(z)} =: J_i(\Theta, q_i).$$

Обозначим $J(\Theta, q) = \sum_i J_i(\Theta, q_i)$ – нижняя оценка на $\ell(\Theta)$ для любого $q = (q_1, \dots, q_\ell)$.

Утверждение 2.2 (Точность оценки). Если $q_i(z) = p(z | x_i; \Theta)$, то $J(\Theta, q) = \ell(\Theta)$.

Доказательство. $p(z | x_i; \Theta) = \pi_z p(x_i; \theta_z) / p(x_i; \Theta)$, так что $\pi_z p(x_i; \theta_z) / q_i(z) = p(x_i; \Theta)$ не зависит от z . Тогда $J_i(\Theta, q_i) = \ln p(x_i; \Theta) \sum_z q_i(z) = \ln p(x_i; \Theta)$, и $J(\Theta, q) = \sum_i \ln p(x_i; \Theta) = \ell(\Theta)$. $\square$

Определение 2.3 (ЕМ-алгоритм). Начиная с произвольного $\Theta^{(0)}$, повторяются шаги: Е-шаг: $q_i^{(t)}(z) = p(z | x_i; \Theta^{(t)})$ для каждого i ; М-шаг: $\Theta^{(t+1)} = \arg \max_{\Theta} J(\Theta, q^{(t)})$.

Теорема 2.4 (Монотонность ЕМ). $\ell(\Theta^{(t+1)}) \geq \ell(\Theta^{(t)})$ для каждого t .

Доказательство. По предложению 2.2, $\ell(\Theta^{(t)}) = J(\Theta^{(t)}, q^{(t)})$. М-шаг максимизирует $J(\cdot, q^{(t)})$, а $\Theta^{(t)}$ – допустимый кандидат, поэтому $J(\Theta^{(t+1)}, q^{(t)}) \geq J(\Theta^{(t)}, q^{(t)})$. Неравенство Йенсена (для любого q) даёт $\ell(\Theta^{(t+1)}) \geq J(\Theta^{(t+1)}, q^{(t)})$. Собирая цепочку, $\ell(\Theta^{(t+1)}) \geq J(\Theta^{(t+1)}, q^{(t)}) \geq J(\Theta^{(t)}, q^{(t)}) = \ell(\Theta^{(t)})$. $\square$

Замечание 2.5 (Связь с K -средних). ЕМ для смеси K нормальных распределений с общей ковариацией $\Sigma_k = \sigma^2 I$ (одинаковой для всех компонент, $\sigma^2 \rightarrow 0$) и равными весами $\pi_k = 1/K$ вырождается в метод K -средних: апостериорная вероятность $\gamma_{ik} = p(z_i=k | x_i; \Theta)$ (см. ниже) стремится к 0 или 1 – «мягкое» отнесение (ЕМ) переходит в жёсткое (шаг отнесения K -средних), а обновление среднего компоненты переходит в шаг пересчёта центра. K -средних, изученный в §1 первым, исторически и методически – частный (упрощённый) случай ЕМ, разобранный здесь во всей общности.

Определение 2.6 (Ответственность). $\gamma_{ik} = p(z_i=k \mid x_i; \Theta) = \frac{\pi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i; \mu_j, \Sigma_j)}$ (плотность $\mathcal{N}$ – как в Лекции 6).

Пример 2.7 (Ответственность вручную). Пусть $n = 1$, $K = 2$, $\pi_1 = \pi_2 = 0.5$, $\mu_1 = 0, \sigma_1^2 = 1$; $\mu_2 = 3, \sigma_2^2 = 1$ (общий вид одномерной плотности – $\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}$). Для объекта $x = 1$:

$$\mathcal{N}(1; 0, 1) = \frac{1}{\sqrt{2\pi}} e^{-1/2} \approx 0.242, \quad \mathcal{N}(1; 3, 1) = \frac{1}{\sqrt{2\pi}} e^{-2} \approx 0.054.$$

$$\gamma_1 = \frac{0.5 \cdot 0.242}{0.5 \cdot 0.242 + 0.5 \cdot 0.054} \approx 0.82, \quad \gamma_2 \approx 0.18.$$

Объект $x = 1$ гораздо ближе к первой компоненте ($\mu_1 = 0$), чем ко второй ($\mu_2 = 3$), и ответственность $\gamma_1 \approx 0.82$ отражает это – в отличие от K -средних, где объект был бы отнесён к первому кластеру целиком ($\gamma_1 = 1$), здесь он «немного» (на 18%) учитывается и при обновлении параметров второй компоненты.

М-шаг максимизирует $J(\Theta, q^{(t)}) = \sum_i \sum_k \gamma_{ik} [\ln \pi_k + \ln \mathcal{N}(x_i; \mu_k, \Sigma_k)]$ (с точностью до слагаемого, не зависящего от Θ).

Утверждение 2.8 (Формулы М-шага).

$$\mu_k = \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}, \quad \pi_k = \frac{1}{\ell} \sum_i \gamma_{ik}, \quad \Sigma_k = \frac{\sum_i \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^\top}{\sum_i \gamma_{ik}}.$$

Доказательство. Для μ_k : слагаемые J , зависящие от μ_k , – это $-\frac{1}{2} \sum_i \gamma_{ik} (x_i - \mu_k)^\top \Sigma_k^{-1} (x_i - \mu_k)$. По формуле градиента квадратичной формы (предложение 6.2 Лекции 1, $w = x_i - \mu_k$), $\nabla_{\mu_k} (x_i - \mu_k)^\top \Sigma_k^{-1} (x_i - \mu_k) = -2 \Sigma_k^{-1} (x_i - \mu_k)$; приравнявая сумму нулю и решая относительно μ_k , получаем формулу.

Для π_k : максимизируем $\sum_i \sum_k \gamma_{ik} \ln \pi_k$ при $\sum_k \pi_k = 1$ (множители Лагранжа, Лекция 3): $\partial/\partial \pi_k (\sum_i \gamma_{ik} \ln \pi_k - \lambda (\sum_k \pi_k - 1)) = \sum_i \gamma_{ik} / \pi_k - \lambda = 0$, откуда $\pi_k = \sum_i \gamma_{ik} / \lambda$; суммируя по k и используя $\sum_k \gamma_{ik} = 1$, получаем $\lambda = \ell$.

Общая формула для Σ_k требует дифференцирования по матрице ($\nabla_{\Sigma} \ln |\Sigma|$, связанного с градиентом определителя из Лекции 1, и производной обратной матрицы) – выходит за рамки построенного аппарата, приводим её без вывода. Разберём вместо этого частный, но распространённый случай сферической компоненты, $\Sigma_k = v_k I$ ($v_k = \sigma_k^2 > 0$ – скаляр), где вычисление сводится к обычной производной по числу v_k . Тогда $\ln |\Sigma_k| = n \ln v_k$, $(x_i - \mu_k)^\top \Sigma_k^{-1} (x_i - \mu_k) = \|x_i - \mu_k\|^2 / v_k$, и слагаемые J , зависящие от v_k , равны $\sum_i \gamma_{ik} [-\frac{n}{2} \ln v_k - \frac{1}{2v_k} \|x_i - \mu_k\|^2]$. Дифференцируя по v_k и приравнявая нулю:

$$\sum_i \gamma_{ik} \left(-\frac{n}{2v_k} + \frac{\|x_i - \mu_k\|^2}{2v_k^2} \right) = 0 \implies v_k = \frac{\sum_i \gamma_{ik} \|x_i - \mu_k\|^2}{n \sum_i \gamma_{ik}}$$

(умножили на $2v_k^2 > 0$ и разрешили относительно v_k) – взвешенная средняя квадратичная невязка, полностью аналогичная общей формуле для Σ_k выше, но без матричного дифференцирования. $\square$

3 Иерархическая кластеризация

K -средних и ЕМ требуют заранее знать K и дают одно разбиение. Агломеративная иерархическая кластеризация строит вложенную последовательность разбиений от ℓ кластеров до одного, не фиксируя K .

Определение 3.1 (Расстояние между кластерами (linkage)).

$$d_{\min}(C, C') = \min_{x \in C, x' \in C'} \rho(x, x') \text{ (одиночная)}, \quad d_{\max}(C, C') = \max_{x \in C, x' \in C'} \rho(x, x') \text{ (полная)},$$

$$d_{\text{avg}}(C, C') = \frac{1}{|C||C'|} \sum_{x \in C} \sum_{x' \in C'} \rho(x, x') \text{ (средняя)}.$$

Algorithm 2 Агломеративная кластеризация

- 1: $\mathcal{C} \leftarrow \{\{x_1\}, \dots, \{x_\ell\}\}$
 - 2: while $|\mathcal{C}| > 1$ do
 - 3: найти $C, C' \in \mathcal{C}$ с наименьшим $d(C, C')$; заменить их на $C \cup C'$; запомнить высоту слияния $d(C, C')$
 - 4: end while
-

Результат – дендрограмма; разбиение на K кластеров – «срез» дендрограммы на подходящей высоте.

Пример 3.2 (Одиночная связь вручную). Четыре точки на прямой: $a = 0, b = 1, c = 3, d = 7$ (одномерный признак, метрика – модуль разности). Попарные расстояния: $\rho(a, b) = 1, \rho(a, c) = 3, \rho(a, d) = 7, \rho(b, c) = 2, \rho(b, d) = 6, \rho(c, d) = 4$.

Шаг 1. Наименьшее расстояние – $\rho(a, b) = 1$: объединяем в $\{a, b\}$.

Шаг 2. Расстояние одиночной связи от $\{a, b\}$ до c – это $\min(\rho(a, c), \rho(b, c)) = \min(3, 2) = 2$; до d – $\min(7, 6) = 6$; расстояние $\rho(c, d) = 4$ не изменилось. Наименьшее теперь – 2: объединяем c с $\{a, b\}$, получаем $\{a, b, c\}$.

Шаг 3. Расстояние от $\{a, b, c\}$ до d – $\min(7, 6, 4) = 4$. Единственный оставшийся кластер $\{a, b, c, d\}$ образуется на высоте 4.

Высоты слияний $1 < 2 < 4$ монотонно возрастают – это общее свойство дендрограмм одиночной связи (расстояние от объединения до любого другого кластера не меньше расстояния, на котором произошло само объединение).




Рис. 2: Схематическая дендрограмма для пяти объектов

Замечание 3.3. Одиночная связь склонна к «эффекту цепочки»; полная – чувствительна к выбросам; средняя – компромисс. В отличие от K -средних и ЕМ, агломеративная кластеризация детерминирована (нет случайной инициализации), но результат сильнее зависит от выбора метрики и linkage-функции.

Заключение

Замечание 3.4 (Информационные критерии). Число компонент K смеси можно выбирать не только скользящим контролем (Лекция 4), но и информационными критериями, штрафующими правдоподобие числом параметров без разбиения выборки: например, байесовский информационный критерий (BIC) выбирает $K = \arg \min_K (-2 \ln L(\hat{\Theta}_K, X^\ell) +$

$p_K \ln \ell$), где p_K – число свободных параметров модели с K компонентами. Это снова принцип структурной минимизации риска (определение 5.1 Лекции 4): штраф $p_K \ln \ell$ играет роль $\text{penalty}(\text{VCdim}, \ell)$ там, но получен из другой (асимптотической байесовской) теории, а не из VC-размерности.

Замечание 3.5. Вне рассмотрения остались: методы кластеризации по плотности (DBSCAN), находящие кластеры произвольной формы через связность областей высокой плотности, а не через расстояние до центра; скорость сходимости ЕМ; формальная связь с вариационным выводом (тот же приём с нижней оценкой $J(\Theta, q)$ работает не только для смесей, а для широкого класса байесовских моделей со скрытыми переменными). В следующей, последней лекции курса – метод главных компонент, снижающий размерность признакового пространства и, в отличие от всех методов Лекций 1–7, вовсе не использующий понятие обучающего сигнала (ни ответов y_i , ни скрытых переменных z_i).