

Машинное обучение

Лекция 8 — Метод главных компонент и сингулярное разложение

Мотивация

Метрические методы (Лекция 6) страдают от «проклятия размерности» при большом числе признаков n ; визуализировать выборку с $n > 3$ напрямую невозможно; наконец, признаки часто избыточны или коллинеарны (Лекция 2) – несколько исходных признаков фактически измеряют одно и то же. Метод главных компонент (РСА) решает эти проблемы одним и тем же способом: строит новые признаки – линейные комбинации исходных, – в определённом смысле наилучшим образом сохраняющие структуру данных при уменьшении их числа. Как и кластеризация (Лекция 7), РСА не использует ответы y_i – это метод понижения размерности признакового пространства $\mathcal{X}$, последний в курсе.

1 Постановка: максимизация дисперсии проекции

Пусть выборка $x_1, \dots, x_\ell \in \mathbb{R}^n$ центрирована, $\frac{1}{\ell} \sum_i x_i = 0$ (иначе вычитаем выборочное среднее). Матрица $X \in \mathbb{R}^{\ell \times n}$ составлена из $x_i^\top$ по строкам (без столбца единиц – свободный член не нужен, данные уже центрированы).

Определение 1.1 (Выборочная ковариационная матрица).

$$C = \frac{1}{\ell} \sum_{i=1}^{\ell} x_i x_i^\top = \frac{1}{\ell} X^\top X \in \mathbb{R}^{n \times n}.$$

C симметрична и положительно полуопределена (матрица Грама $X^\top X$ из Лекции 2, с точностью до $1/\ell$). Для единичного w ($\|w\| = 1$) проекция x_i на направление w равна $x_i^\top w$; выборка центрирована, поэтому среднее проекций равно нулю, а их дисперсия

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (x_i^\top w)^2 = \frac{1}{\ell} w^\top X^\top X w = w^\top C w.$$

Первая главная компонента – направление w , вдоль которого эта дисперсия максимальна.

Практический приём: стандартизация признаков. Дисперсия $w^\top C w$ зависит от единиц измерения: признак, измеренный в миллиметрах, имеет в 10^6 раз большую дисперсию, чем тот же признак в километрах. Если признаки $x^{(1)}, \dots, x^{(n)}$ имеют разную природу (например, рост в метрах и доход в рублях), РСА без предобработки попросту найдёт направление, совпадающее с признаком наибольшего масштаба – это артефакт единиц измерения, а не структуры данных. Поэтому перед РСА каждый признак принято стандартизировать: $x^{(j)} \mapsto (x^{(j)} - \bar{x}^{(j)})/s_j$, где s_j – выборочное стандартное отклонение признака j . После этого C – матрица корреляций, а не ковариаций, и все признаки входят в задачу на равных.

2 Вывод через собственные векторы

Теорема 2.1 (Первая главная компонента). $\arg \max_{\|w\|=1} w^T C w$ – собственный вектор C , отвечающий наибольшему собственному числу $\lambda_{\max}$, а максимум дисперсии равен $\lambda_{\max}$.

Доказательство. Максимизируем $w^T C w$ при $w^T w = 1$ (множители Лагранжа, Лекция 3): $L(w, \lambda) = w^T C w - \lambda(w^T w - 1)$. По формуле градиента квадратичной формы (предложение 6.2 Лекции 1, C симметрична), $\nabla_w L = 2Cw - 2\lambda w = 0$, откуда $Cw = \lambda w$ – w обязано быть собственным вектором C . В стационарной точке $w^T C w = \lambda \|w\|^2 = \lambda$; максимум среди всех собственных чисел – $\lambda_{\max}$. $\square$

Замечание 2.2 (Следующие компоненты). C симметрична, поэтому обладает ортонормированным базисом собственных векторов $w_1, \dots, w_n$ с $\lambda_1 \geq \dots \geq \lambda_n \geq 0$. Аналогично теореме 2.1 (максимизация $w^T C w$ при ортогональности уже выбранным $w_1, \dots, w_{m-1}$) показывается, что m -я главная компонента – это w_m . Проекция на первые k компонент, $x \mapsto (x^T w_1, \dots, x^T w_k) \in \mathbb{R}^k$, – понижение размерности с n до k .

Утверждение 2.3 (Некоррелированность главных компонент). Пусть $z^{(i)} = x^T w_i$, $z^{(j)} = x^T w_j$ – i -я и j -я главные компоненты, $i \neq j$. Тогда их выборочная ковариация равна нулю.

Доказательство. Так как обе центрированы (среднее проекции центрированных данных равно нулю), ковариация равна $\frac{1}{\ell} \sum_m z_m^{(i)} z_m^{(j)} = \frac{1}{\ell} \sum_m (x_m^T w_i)(x_m^T w_j) = w_i^T C w_j = w_i^T (\lambda_j w_j) = \lambda_j (w_i^T w_j) = 0$, так как w_i, w_j ортогональны. $\square$

Практический приём: отбеливание (whitening). Преобразование $z = \Lambda^{-1/2} W^T x$ (используются все n компонент, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$) даёт данные с единичной ковариационной матрицей: $\text{Cov}(z) = \Lambda^{-1/2} W^T C W \Lambda^{-1/2} = \Lambda^{-1/2} \Lambda \Lambda^{-1/2} = I$ (используем $C = W \Lambda W^T$ и ортогональность W). По предложению 2.3 компоненты уже некоррелированы; деление на $\sqrt{\lambda_j}$ дополнительно уравнивает их дисперсии. Отбеливание – стандартная предобработка перед градиентными методами: в Лекции 2 обсуждалось, что скорость сходимости градиентного спуска зависит от числа обусловленности $\lambda_{\max}/\lambda_{\min}$ матрицы вторых производных (зигзагообразная траектория на вытянутых эллипсах); после отбеливания это число обусловленности равно 1, и зигзаг исчезает.

Утверждение 2.4 (Эквивалентность: минимизация ошибки восстановления). Направление w ($\|w\| = 1$), максимизирующее $\sum_i (x_i^T w)^2$, одновременно минимизирует $\sum_i \|x_i - (x_i^T w)w\|^2$.

Доказательство. $\hat{x}_i = (x_i^T w)w$ – проекция x_i на $\text{span}(w)$; $(x_i - \hat{x}_i)^T \hat{x}_i = (x_i^T w)(x_i^T w - (x_i^T w)\|w\|^2) = 0$. По теореме Пифагора и суммированию по i , $\sum_i \|x_i\|^2 = \sum_i (x_i^T w)^2 + \sum_i \|x_i - \hat{x}_i\|^2$; левая часть от w не зависит, значит максимизация первого слагаемого справа равносильна минимизации второго. $\square$

2.1 Доля объяснённой дисперсии и выбор числа компонент

Утверждение 2.5 (Полная дисперсия). $\sum_{j=1}^n \lambda_j = \text{tr } C = \frac{1}{\ell} \sum_{i=1}^{\ell} \|x_i\|^2$ – сумма дисперсий всех n исходных признаков.

Доказательство. След инвариантен относительно ортогонального сопряжения: $C = W \Lambda W^T$ с ортогональной W , значит $\text{tr } C = \text{tr}(W \Lambda W^T) = \text{tr}(\Lambda W^T W) = \text{tr } \Lambda = \sum_j \lambda_j$ (циклическое свойство следа). С другой стороны, по определению $\text{tr } C = \frac{1}{\ell} \text{tr}(X^T X) = \frac{1}{\ell} \sum_i \text{tr}(x_i x_i^T) = \frac{1}{\ell} \sum_i \|x_i\|^2$. $\square$

Практический приём: доля объяснённой дисперсии. Величина $\lambda_1 / \sum_j \lambda_j$ – доля дисперсии, сохранённая первой компонентой; аналогично для первых k компонент – $(\lambda_1 + \dots + \lambda_k) / \sum_j \lambda_j$. На практике число компонент k выбирают наименьшим, при котором эта доля превышает порог (например, 0.9 или 0.95) – тот же принцип, что и скользящий контроль (Лекция 4): находим наименьшую модель, объясняющую «почти всё». Для примера 3.1 $\text{tr } C = 2.5 + 2.5 = 5 = \lambda_1 + \lambda_2$ (сходится с предложением 2.5), первая компонента объясняет $4.5/5 = 90\%$ дисперсии – уже одной координаты $x^\top w_1$ достаточно для хорошего приближения.

Algorithm 1 Метод главных компонент (PCA)

```

1: procedure PCA( $x_1, \dots, x_\ell$ , число компонент  $k$ )
2:    $\bar{x} \leftarrow \frac{1}{\ell} \sum_i x_i$ ;  $x_i \leftarrow x_i - \bar{x}$  для всех  $i$  ▷ центрирование
3:    $C \leftarrow \frac{1}{\ell} \sum_i x_i x_i^\top$ 
4:   найти собственные пары  $(\lambda_j, w_j)$  матрицы  $C$ , отсортировать по убыванию  $\lambda_j$ 
5:   return  $\{w_1, \dots, w_k\}$  и проекции  $z_i = (x_i^\top w_1, \dots, x_i^\top w_k)$ 
6: end procedure
  
```

3 Численный пример

Пример 3.1. Четыре центрированных точки в $\mathbb{R}^2$: $x_1 = (2, 1)$, $x_2 = (-1, -2)$, $x_3 = (1, 2)$, $x_4 = (-2, -1)$ (сумма – нулевой вектор). Вычисляем

$$C = \frac{1}{4} \sum_i x_i x_i^\top = \frac{1}{4} \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix} = \begin{pmatrix} 2.5 & 2 \\ 2 & 2.5 \end{pmatrix}.$$

Характеристическое уравнение: $\lambda^2 - 5\lambda + 2.25 = 0$ (след 5, определитель $6.25 - 4 = 2.25$), корни $\lambda = (5 \pm 4)/2 \in \{4.5, 0.5\}$. Для $\lambda = 4.5$: $(C - 4.5I)w = 0 \Rightarrow -2w_1 + 2w_2 = 0 \Rightarrow w_1 = w_2$, единичный вектор $w_1 = (1/\sqrt{2}, 1/\sqrt{2})$. Для $\lambda = 0.5$: $2w_1 + 2w_2 = 0 \Rightarrow w_1 = -w_2$, вектор $w_2 = (1/\sqrt{2}, -1/\sqrt{2})$. Первая главная компонента – направление $(1, 1)/\sqrt{2}$ (вдоль диагонали, где четыре точки различаются сильнее всего), вторая – $(1, -1)/\sqrt{2}$.




Рис. 1: Пример 3.1: точки и главные направления w_1 (наибольшая дисперсия), w_2 (наименьшая, ортогональна w_1)

Пример 3.2 (Проекция на первую компоненту). Понижаем размерность с 2 до 1, проецируя на $w_1 = (1, 1)/\sqrt{2}$: $z_i = x_i^\top w_1$. Для $x_1 = (2, 1)$: $z_1 = (2 + 1)/\sqrt{2} = 3/\sqrt{2} \approx 2.12$;

аналогично $z_2 = -3/\sqrt{2}$, $z_3 = 3/\sqrt{2}$, $z_4 = -3/\sqrt{2}$ (x_1, x_3 и x_2, x_4 дают одинаковую проекцию – они различаются только вдоль «слабого» направления w_2). Восстановление $\hat{x}_1 = z_1 w_1 = (3/\sqrt{2})(1/\sqrt{2}, 1/\sqrt{2}) = (1.5, 1.5)$; ошибка $\|x_1 - \hat{x}_1\|^2 = (2 - 1.5)^2 + (1 - 1.5)^2 = 0.5$. По предложению 2.4 суммарная ошибка по всем четырём точкам равна $\lambda_2 \cdot \ell = 0.5 \cdot 4 = 2$ (несохранённая дисперсия вдоль w_2) – проверка: по симметрии все четыре слагаемых равны 0.5, сумма $4 \cdot 0.5 = 2$, совпадает.

4 Сингулярное разложение: вывод через РСА

Теорема 2.1 даёт способ явно построить сингулярное разложение матрицы X , используя только собственные векторы C – инструмент, который мы уже вывели.

Теорема 4.1 (Сингулярное разложение). Пусть $w_1, \dots, w_n$ – ортонормированный базис собственных векторов C с собственными числами $\lambda_1 \geq \dots \geq \lambda_n \geq 0$, все $\lambda_j > 0$ (столбцы X линейно независимы). Положим $\sigma_j = \sqrt{\ell \lambda_j}$ и $u_j = X w_j / \sigma_j \in \mathbb{R}^\ell$. Тогда $u_1, \dots, u_n$ ортонормированы, и

$$X = \sum_{j=1}^n \sigma_j u_j w_j^\top.$$

Доказательство. Так как $X^\top X = \ell C$ и $C w_j = \lambda_j w_j$, верно $X^\top X w_j = \ell \lambda_j w_j = \sigma_j^2 w_j$. Тогда для любых i, j

$$u_i^\top u_j = \frac{(X w_i)^\top (X w_j)}{\sigma_i \sigma_j} = \frac{w_i^\top X^\top X w_j}{\sigma_i \sigma_j} = \frac{w_i^\top (\sigma_j^2 w_j)}{\sigma_i \sigma_j} = \frac{\sigma_j}{\sigma_i} w_i^\top w_j.$$

При $i = j$ это даёт $u_j^\top u_j = 1$; при $i \neq j$ – $w_i^\top w_j = 0$ (ортонормированность w), значит $u_i^\top u_j = 0$ – $u_1, \dots, u_n$ ортонормированы. Далее, оба линейных отображения X и $\sum_j \sigma_j u_j w_j^\top$ (из $\mathbb{R}^n$ в $\mathbb{R}^\ell$) совпадают на базисе $w_1, \dots, w_n$: применяя второе к w_k , $\sum_j \sigma_j u_j (w_j^\top w_k) = \sigma_k u_k = \sigma_k \cdot X w_k / \sigma_k = X w_k$ – совпадает с $X w_k$. Совпадая на базисе, отображения совпадают всюду, то есть равны как матрицы. $\square$

Замечание 4.2. В матричной форме $X = U \Sigma W^\top$, где $U \in \mathbb{R}^{\ell \times n}$ – матрица со столбцами u_j , $W \in \mathbb{R}^{n \times n}$ – со столбцами w_j (ортогональна), $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$. Величины σ_j называются сингулярными числами X , а u_j, w_j – левыми и правыми сингулярными векторами. На практике главные компоненты вычисляют через SVD матрицы X напрямую, не составляя $C = X^\top X / \ell$ явно (это устойчивее численно: вычисление $X^\top X$ возводит числа обусловленности в квадрат).

Пример 4.3 (Продолжение примера 3.1). Для той же выборки $\sigma_1 = \sqrt{4 \cdot 4.5} = \sqrt{18} = 3\sqrt{2}$, $\sigma_2 = \sqrt{4 \cdot 0.5} = \sqrt{2}$. Вычисляем $u_1 = X w_1 / \sigma_1$: скалярные произведения строк X с $w_1 = (1, 1) / \sqrt{2}$ дают $(3/\sqrt{2}, -3/\sqrt{2}, 3/\sqrt{2}, -3/\sqrt{2})^\top$, делим на $\sigma_1 = 3\sqrt{2}$: $u_1 = (1/2, -1/2, 1/2, -1/2)^\top$. Аналогично $u_2 = X w_2 / \sigma_2 = (1/2, 1/2, -1/2, -1/2)^\top$. Проверка: $u_1^\top u_2 = \frac{1}{4} - \frac{1}{4} - \frac{1}{4} + \frac{1}{4} = 0$ – ортогональны, как и предсказывает теорема 4.1.

Замечание 4.4 (Малоранговое приближение). Отбрасывая слагаемые с $j > k$ в разложении теоремы 4.1, получаем $X_k = \sum_{j=1}^k \sigma_j u_j w_j^\top$ – матрицу ранга k . Известный факт (теорема Эккарта–Юнга, приводим без доказательства) состоит в том, что X_k – наилучшее приближение X матрицей ранга k по норме Фробениуса; это в точности РСА-проекция на первые k компонент, записанная в матричной форме. Для нашего примера ранг-1 приближение $X_1 = \sigma_1 u_1 w_1^\top$: первая строка $\sigma_1 u_1^\top w_1 = (3\sqrt{2})(0.5)(1/\sqrt{2}, 1/\sqrt{2}) = (1.5, 1.5)$ – совпадает с восстановлением $\hat{x}_1$ из примера выше, как и должно быть.

Замечание 4.5 (Связь с нормальными уравнениями МНК). Теорема 4.1 даёт другой способ решать задачу наименьших квадратов из Лекции 1. Пусть $X = U\Sigma W^T$ – разложение из теоремы 4.1 (X полного столбцового ранга, U имеет ортонормированные столбцы, $U^T U = I$). Тогда $X^T X = W\Sigma U^T U \Sigma W^T = W\Sigma^2 W^T$, откуда $(X^T X)^{-1} = W\Sigma^{-2} W^T$, и решение теоремы 8.1 Лекции 1 переписывается как

$$\theta^* = (X^T X)^{-1} X^T y = W\Sigma^{-2} W^T W\Sigma U^T y = W\Sigma^{-1} U^T y = X^+ y,$$

где $X^+ := W\Sigma^{-1} U^T$ – псевдообратная матрица X . Как и отмечалось выше, вычисление θ^* через SVD (без явного построения $X^T X$ и обращения) численно устойчивее прямой формулы нормальных уравнений.

5 Многомерное шкалирование

Если вместо координат x_i известны только попарные расстояния $\rho(x_i, x_j)$ (например, экспертные оценки несходства без явных признаков), задача – найти $\tilde{x}_1, \dots, \tilde{x}_\ell \in \mathbb{R}^k$, приближённо воспроизводящие эти расстояния, $\|\tilde{x}_i - \tilde{x}_j\| \approx \rho(x_i, x_j)$.

Замечание 5.1 (Классическое многомерное шкалирование). Если исходные x_i существуют и центрированы, а ρ – евклидово расстояние, матрица Грама $B = XX^T \in \mathbb{R}^{\ell \times \ell}$ восстанавливается по матрице попарных квадратов расстояний через «двойное центрирование» (не выводим формулу), а искомые координаты $\tilde{x}_i$ получаются из k старших собственных векторов B – то же вычисление, что и PCA, но применённое к $B = XX^T$ ($\ell \times \ell$) вместо $C = X^T X / \ell$ ($n \times n$); по теореме 4.1, у $XX^T = U\Sigma^2 U^T$ и $X^T X = \ell C = W(\ell\Lambda)W^T$ одни и те же ненулевые собственные числа $\sigma_j^2 = \ell\lambda_j$. При $k = 2$ или 3 это – стандартный способ визуализации многомерных данных.




Рис. 2: Идея многомерного шкалирования: ℓ объектов, заданных только попарными несходствами, размещаются в $\mathbb{R}^k$ ($k = 2$) так, чтобы евклидовы расстояния между образами приближали исходные $\rho(x_i, x_j)$

Заключение

Замечание 5.2. Курс завершается на методе главных компонент, но список тем не исчерпан: вне рассмотрения остались ядерный PCA (нелинейное обобщение через ядра Лекции 3), факторный анализ, t -SNE и другие методы нелинейного понижения размерности, а также нейросетевые методы, изначально исключённые из программы курса.

Пройденный материал – от постановки задачи (Лекция 1) до обучения без учителя (Лекции 7–8) – образует общую картину классического обучения по прецедентам:

Общая нить: постановка задачи и модель $\rightarrow$ функция потерь и принцип ERM $\rightarrow$ конкретные модели $\rightarrow$ контроль переобучения (СМР как формальная рамка, применённая на практике в скользящем контроле, стрижке деревьев, бэггинге) $\rightarrow$ задачи без учителя, где ответов y_i нет вовсе, а структура данных ищется через плотность (ЕМ), сходство (кластеризация) или дисперсию (PCA).

Лекция	Содержание
1	Постановка задачи, ERM, МНК как частный случай ERM/MLE
2	Градиентные методы, скорость сходимости, регуляризация
3	Логистическая регрессия, MAP, SVM и двойственность, ядра
4	Переобучение, смещение–разброс, VC-размерность, СМР
5	Решающие деревья, бэггинг, случайный лес, бустинг
6	Метрические методы (k NN, Парзен, STOLP), байесовский классификатор, наивный Байес, LDA/QDA
7	Кластеризация: K -средних, EM, иерархическая
8	Понижение размерности: PCA, сингулярное разложение

Таблица 1: Структура курса